МИНОБРНАУКИ РОССИИ
федеральное государственное бюджетное образовательное учреждение высшего образования
«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ ПЕТРА ВЕЛИКОГО»

Физико-механический институт
Высшая школа прикладной математики и информатики

Отчет по лабораторной работе №1
«Анализ промптов и моделей для генерации аннотаций по тексту»

По дисциплине
«Автоматизация научных исследований»

Работу выполнили:
Булыгина Екатерина Сергеевна
Дылдина Татьяна Игоревна
Крутогузенко Ксения Сергеевна

Группа: 5040102/60201

Санкт-Петербург
2026 г.

СОДЕРЖАНИЕ

1. ЦЕЛЬ, ЗАДАЧИ И МЕТОДИКА 3

2. АНАЛИЗ РУССКОЯЗЫЧНОЙ СТАТЬИ 4

3. АНАЛИЗ АНГЛОЯЗЫЧНОЙ СТАТЬИ 8

4. СРАВНИТЕЛЬНЫЙ АНАЛИЗ РЕЗУЛЬТАТОВ 12

5. РАЗРАБОТКА ПРОМТА И АНАЛИЗ ЭФФЕКТИВНОСТИ 13

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 19

1. ЦЕЛЬ, ЗАДАЧИ И МЕТОДИКА

Цель лабораторной работы – сравнить качество автоматической генерации аннотаций научных статей на русском и английском языках при использовании трёх сервисов на основе больших языковых моделей и установить, насколько результаты соответствуют авторским аннотациям и исходным текстам статей.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Выбрать две статьи на английском и русском языках с опубликованными авторскими аннотациями.
2. Получить по одной аннотации каждой статьи с помощью трех языковых моделей.
3. Рассчитать показатели ROUGE-1 (F1) и ROUGE-L (F1).
4. Проверить фактическую достоверность утверждений, структуру и объём текстов.
5. Сопоставить результаты и сформулировать выводы.

Материал исследования составили две статьи: русскоязычная работа Р. Б. Прядеина и М. Е. Степанцова «Об одном подходе к имитационному моделированию спортивной игры с непрерывным временем» (2014) [1] и англоязычная работа Ruby C. Weng «A Bayesian Edgeworth Expansion by Stein’s Identity» (2010) [6]. В обоих случаях авторская аннотация была сохранена отдельно для использования в качестве эталона. Перед загрузкой статей в языковые модели из PDF удалялись авторские аннотации и ключевые слова. Основной текст, формулы, таблицы и библиографические сведения сохранялись.

Сравнивались три сервиса: ChatGPT (подписка Plus, GPT-6) [2], Perplexity (подписка Pro, автоматический выбор модели (Best). Конкретная модель и параметры алгоритма её выбора не установлены, так как скрыты языковой моделью) [5] и DeepSeek (бесплатный доступ) [3]. Для каждой статьи был применён одинаковый по содержанию запрос ко всем трём системам. Статья прикреплялась отдельным файлом PDF. Выходной язык задавался отдельно: русский для первой статьи и английский для второй.

2. АНАЛИЗ РУССКОЯЗЫЧНОЙ СТАТЬИ

Для эксперимента использована статья Р. Б. Прядеина и М. Е. Степанцова «Об одном подходе к имитационному моделированию спортивной игры с непрерывным временем». Статья содержит восемь математических формул и две таблицы, что позволяет дополнительно оценить корректность интерпретации языковыми моделями математических методов и результатов исследования.

На рисунке 1 представлен исходный промпт (с учетом тематики журнала, языка, а также количества слов в аннотации, для корректного сравнения с исходной аннотацией).

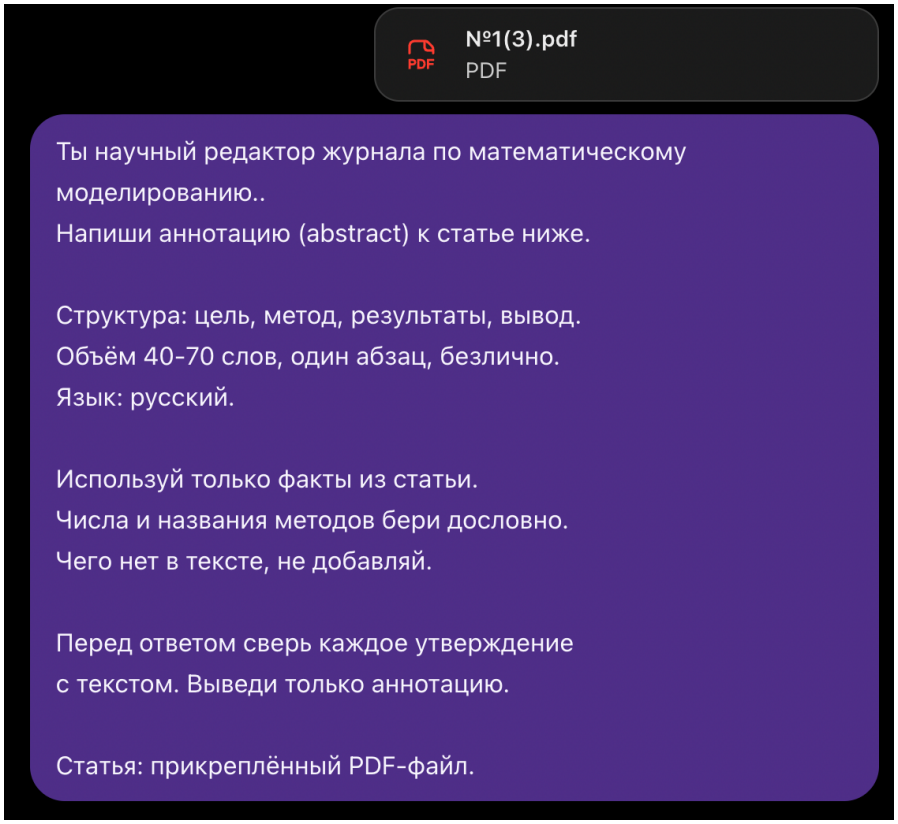


Рисунок 1 – Промпт для русскоязычной статьи

Полученные ответы представлены на рисунках 2-4.

Предложен подход к имитационному моделированию спортивной игры с непрерывным временем, представляющий матч в виде марковской цепи событий. Метод включает статистическую модель ожидаемого числа голов и исправленное распределение Пуассона с коэффициентом α. Для матча «Ньюкасл»–«Тоттенхем» моделирование дало результат 2:1, при разбиении матча на таймы – 1:1. Модель является предварительной и требует дальнейшей апробации и доработки.

Рисунок 2 – Аннотация, сгенерированная DeepSeek

DeepSeek указал основные методы исследования и конкретные результаты обоих вариантов моделирования. Ответ краток и фактически корректен, однако не включает подробности статистической проверки распределения забитых мячей.

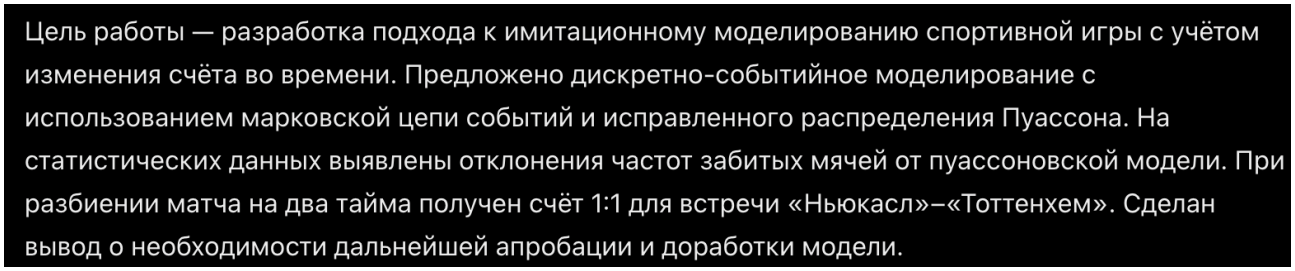


Рисунок 3 – Аннотация, сгенерированная ChatGPT

ChatGPT отразил выявленные отклонения фактических частот забитых мячей от пуассоновского распределения и результат 1:1 для моделирования с делением на таймы. При этом результат 2:1, полученный при первоначальном моделировании, в аннотации отсутствует.

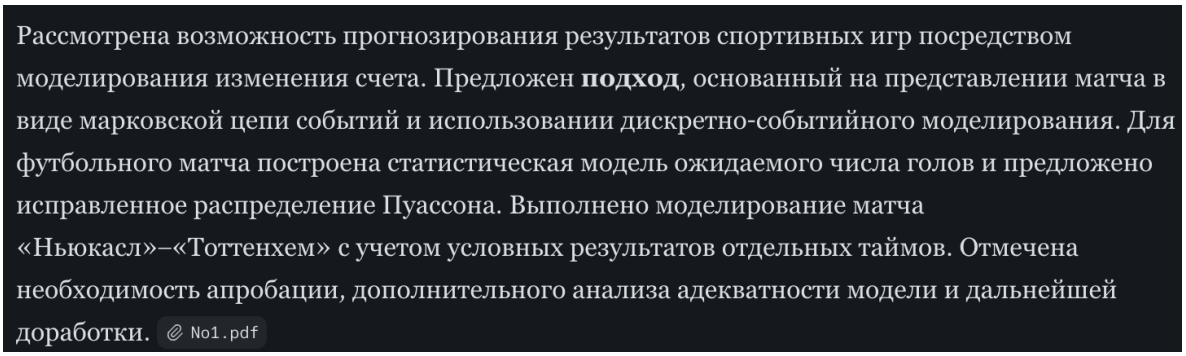


Рисунок 4 – Аннотация, сгенерированная Perplexity

Perplexity перечислил основные составляющие предложенного подхода, но не привёл конкретный счёт, полученный в эксперименте.

Для расчёта ROUGE использовалась опубликованная авторская аннотация, представленная на рисунке 5. Расчет производился с использованием [4].

Работа посвящена обсуждению методов статистического моделирования исходов спортивных соревнований вообще и спортивной игры с непрерывным временем в частности. Предложен основанный на имитационном моделировании хода такой игры подход к предсказанию результата игры, представляющий собой некоторый промежуточный вариант между чистым статистическим моделированием и агентным моделированием действий отдельных игроков, участвующих в матче. Приведен пример ретроспективного прогноза на основе предложенной модели.

Рисунок 5 – Исходная аннотация

Количественные результаты сравнения представлены в таблице 1.

Таблица 1 – Сравнительная оценка сгенерированных аннотаций

Показатель	**DeepSeek**	**ChatGPT**	**Perplexity**
ROUGE-1 (F1), %	23,01	15,13	20,34
ROUGE-L (F1), %	14,16	10,08	11,86
Объём слов	54	60	59
Структура из 4	4	4	4
Галлюцинации, шт.	0	0	0

Наибольшие значения ROUGE-1 и ROUGE-L получены у DeepSeek. Второе место по обоим показателям занимает Perplexity, третье – ChatGPT. При этом различия метрик характеризуют прежде всего лексическое сходство с авторской аннотацией и не позволяют самостоятельно определить содержательное качество результата.

Относительно невысокие значения ROUGE связаны с различиями в расстановке акцентов. В авторской аннотации основное внимание уделяется общему положению предложенного подхода между статистическим и агентным моделированием. В сгенерированных текстах чаще называются конкретные методы и результаты футбольного примера.

Все ответы уложились в заданный объём 40–70 слов. Основные сведения, включённые моделями, подтверждаются текстом статьи. Явных галлюцинаций не выявлено. Однако полнота передачи результатов различается: DeepSeek и ChatGPT приводят конкретные значения счёта, тогда как Perplexity ограничивается упоминанием самого моделирования.

Наличие в исходной статье восьми формул и двух таблиц не привело к заметным ошибкам в наименованиях или содержательном описании использованных методов. При этом модели не воспроизводили сами математические зависимости, а передавали их смысл в кратком виде. Сделать вывод о влиянии количества формул на качество аннотирования на основании одной статьи невозможно. Таким образом, в эксперименте с русскоязычной статьёй наиболее высокий результат по метрикам ROUGE показал DeepSeek. Его аннотация также сохранила результаты обоих вариантов моделирования при отсутствии обнаруженных фактических ошибок. ChatGPT корректно передал статистический аспект исследования, но опустил один из результатов моделирования. Perplexity отразил методологию, однако не указал численного результата и допустил небольшое нарушение формата ответа.

3. АНАЛИЗ АНГЛОЯЗЫЧНОЙ СТАТЬИ

Для эксперимента использована англоязычная статья Ruby C. Weng «A Bayesian Edgeworth Expansion by Stein's Identity». Работа посвящена построению байесовского разложения Эджворта для маргинальных апостериорных распределений. Статья содержит математические выкладки и два примера применения предложенного подхода: биномиальную модель и двумерную нормальную модель. Это позволяет оценить, насколько точно языковые модели передают теоретические методы и результаты исследования.

На рисунке 6 представлен исходный промпт (с учетом тематики журнала, языка, а также количества слов в аннотации, для корректного сравнения с исходной аннотацией).

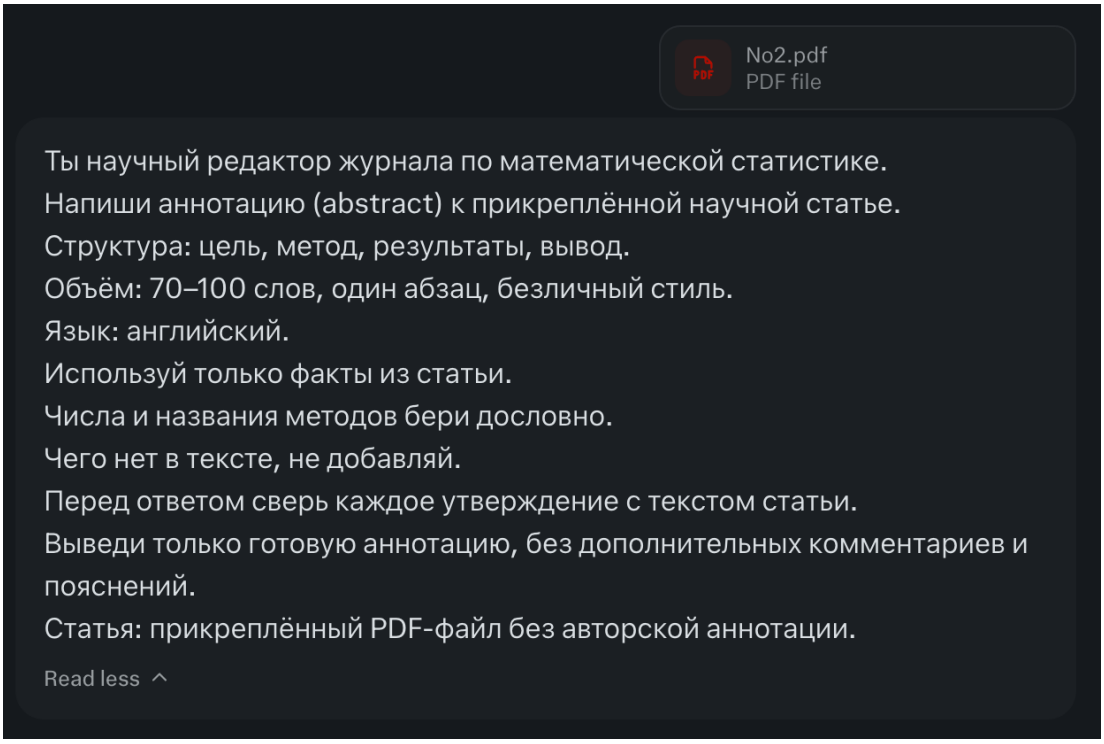


Рисунок 6 – Промпт для англоязычной статьи

Полученные ответы представлены на рисунках 7-9.

This paper develops a Bayesian Edgeworth expansion for marginal posterior distributions. By repeatedly applying Stein's Identity and Hermite polynomial properties, the marginal posterior density is expanded in Hermite orthogonal functions, with coefficients given by posterior moments of the normalized maximum likelihood estimator and terms ordered in powers of the sample size t. The expansion resembles the classical Edgeworth expansion and is compared with Johnson (1970). Examples for a binomial model and a bivariate normal model show that combining the expansion with numerical integration for moments yields reasonable approximations when the sample size is small or multiple modes are present.

Рисунок 7 – Аннотация, сгенерированная DeepSeek

DeepSeek подробно передал теоретическую составляющую работы. Указаны оба примера и сравнение с работой Johnson (1970). Вместе с тем выражение «moments of the normalized maximum likelihood estimator» неточно: в статье рассматриваются моменты нормированного параметра, центрированного относительно оценки максимального правдоподобия, а не моменты самой оценки.

The study aims to develop an Edgeworth expansion for marginal posterior distributions in terms of posterior moments. Repeated application of Stein’s Identity, together with properties of Hermite polynomials, is used to derive the expansion and establish the asymptotic orders of its terms. The proposed Bayesian Edgeworth expansion is illustrated using a binomial model and a bivariate normal model, with posterior moments approximated by numerical integration. The results show that incorporating more moments produces reasonable approximations for skewed or multimodal posterior densities, even with small sample sizes.

Рисунок 8 – Аннотация, сгенерированная ChatGPT

ChatGPT корректно сформулировал цель работы, основные методы и результаты. В ответе отражены использование численного интегрирования и возможность получать приемлемые приближения для асимметричных или многомодальных апостериорных плотностей. При этом модель не упомянула отдельное сравнение с подходом Johnson (1970). Аннотация связная и соответствует установленному формату.

A Bayesian Edgeworth expansion for marginal posterior distributions is developed to express corrections to posterior normality in terms of moments. Repeated application of Stein's Identity, combined with properties of Hermite polynomials, yields a posterior expansion whose terms are ordered by powers of the sample size. Comparisons with Johnson (1970) clarify the relationship between moment-based and derivative-based expansions. Two examples demonstrate that incorporating higher-order terms and numerical integration can provide reasonable approximations for small samples or multiple modes. The results support posterior density reconstruction from moments, while data-based selection of the expansion order remains unresolved. No2.pdf

Рисунок 9 – Аннотация, сгенерированная Perplexity

Perplexity отразил применение тождества Стейна, многочленов Эрмита и сравнение с Johnson (1970). В отличие от остальных ответов, отмечена нерешённая проблема выбора числа членов разложения на основе данных, о которой автор пишет в заключении. Выдуманных содержательных результатов не выявлено.

Для расчёта ROUGE использовалась опубликованная авторская аннотация, представленная на рисунке 10.

Abstract. The Edgeworth expansion is a series that approximates a probability distribution in terms of its cumulants. One can derive it by first expanding the probability distribution in Hermite orthogonal functions and then collecting terms in powers of the sample size. This paper derives an expansion for posterior distributions which possesses these features of an Edgeworth series. The techniques used are a version of Stein's Identity and properties of Hermite polynomials. Two examples are provided to illustrate the accuracy of our series.

Рисунок 10 – Исходная аннотация

Количественные результаты сравнения представлены в таблице 2.

Таблица 2 – Сравнительная оценка сгенерированных аннотаций

Показатель	**DeepSeek**	**ChatGPT**	**Perplexity**
ROUGE-1 (F1), %	43,96	44,97	43,09
ROUGE-L (F1), %	23,08	21,30	20,99
Объём слов	99	86	94
Структура из 4	4	4	4
Галлюцинации, шт.	0	0	0

Наибольшее значение ROUGE-1 получено у ChatGPT (44,97 %), а ROUGE-L – у DeepSeek (23,08 %). Perplexity имеет близкий к остальным результат по обеим метрикам. Следовательно, по лексическому совпадению с авторской аннотацией нельзя выделить однозначного лидера: модели используют разные формулировки и расставляют смысловые акценты по-разному.

Авторская аннотация прежде всего объясняет общую идею разложения Эджворта. Сгенерированные аннотации конкретизируют результаты. Такие дополнения подтверждаются текстом исследования, но уменьшают формальное совпадение с кратким авторским описанием. Все три аннотации соответствуют заданному диапазону и содержат четыре структурных элемента. Явных вымышленных численных результатов или методов не выявлено. Тем не менее в ответе DeepSeek имеется терминологическая неточность.

Таким образом, при анализе англоязычной статьи ChatGPT продемонстрировал наибольшее лексическое совпадение по ROUGE-1 и хорошо сохранил смысл основных результатов. DeepSeek наиболее подробно описал математическую конструкцию разложения, но допустил неоднозначную терминологию. Perplexity дал содержательно полный ответ, включая ограничения метода. Выбор лучшей модели требует учитывать не только ROUGE, но также фактическую корректность, полноту и соблюдение формата.

4. СРАВНИТЕЛЬНЫЙ АНАЛИЗ РЕЗУЛЬТАТОВ

В таблице 3 сопоставлены результаты трёх сервисов при аннотировании русскоязычной и англоязычной статей. Структура оценивалась по четырём элементам: цель, методы, результаты и выводы.

Таблица 3 – Сводное сравнение результатов генерации аннотаций

Статья	Сервис	ROUGE-1 (F1), %	ROUGE-L (F1), %	Структура (из 4)	Галлюцинации, шт.
Русская	DeepSeek	23,01	14,16	4	0
	ChatGPT	15,13	10,08	4	0
	Perplexity	20,34	11,86	4	0
Английская	DeepSeek	43,96	23,08	4	0
	ChatGPT	44,97	21,30	4	0
	Perplexity	43,09	20,99	4	0

На русскоязычной статье DeepSeek лидировал по обеим метрикам ROUGE и сохранил результаты двух вариантов моделирования. На англоязычной статье максимальный ROUGE-1 получил ChatGPT, а ROUGE-L – DeepSeek. Таким образом, универсального лидера по всем показателям нет.

Явных выдуманных фактов в шести аннотациях не выявлено. Однако ChatGPT пропустил один из результатов русской статьи, DeepSeek допустил терминологическую неточность в английской. Поэтому высокое значение ROUGE не гарантирует полноты и точности изложения.

Для проверки улучшенного промпта выбран DeepSeek. У него лучшие результаты по обеим метрикам для русской статьи и по ROUGE-L для английской. Оптимизация будет направлена на точность терминологии, отбор главных результатов и соблюдение формата. Эти выводы относятся только к двум исследованным статьям.

5. РАЗРАБОТКА ПРОМТА И АНАЛИЗ ЭФФЕКТИВНОСТИ

Результаты предыдущих экспериментов показали, что исходный промпт позволяет получать содержательно корректные аннотации, однако не исключает пропуска значимых результатов, неточного употребления специальных терминов и нарушений формата вывода. Выявленные особенности использованы при разработке двух вариантов усовершенствованного запроса.

Для изучения влияния формулировок выбран последовательный подход: исходный промпт рассматривается как базовый вариант (П0), первый улучшенный промпт (П1) дополняет его правилами отбора существенной информации, а второй (П2) сохраняет требования П1 и вводит более конкретную процедуру проверки фактов и терминологии.

Промпт 1. Приоритизация основного научного вклада и результатов.

Первый вариант направлен на повышение содержательной полноты без увеличения объёма аннотации. К исходным ограничениям добавлено требование сначала выявить главный научный вклад, затем выбрать наиболее важные результаты и не заменять их общими рассуждениями об актуальности. При наличии нескольких вариантов моделирования предлагается отмечать различия между ними только тогда, когда они существенны для вывода. Такое уточнение может уменьшить вероятность пропуска ключевых результатов и чрезмерной детализации второстепенных примеров.

Текст промпта П1 представлен на рисунке 11.

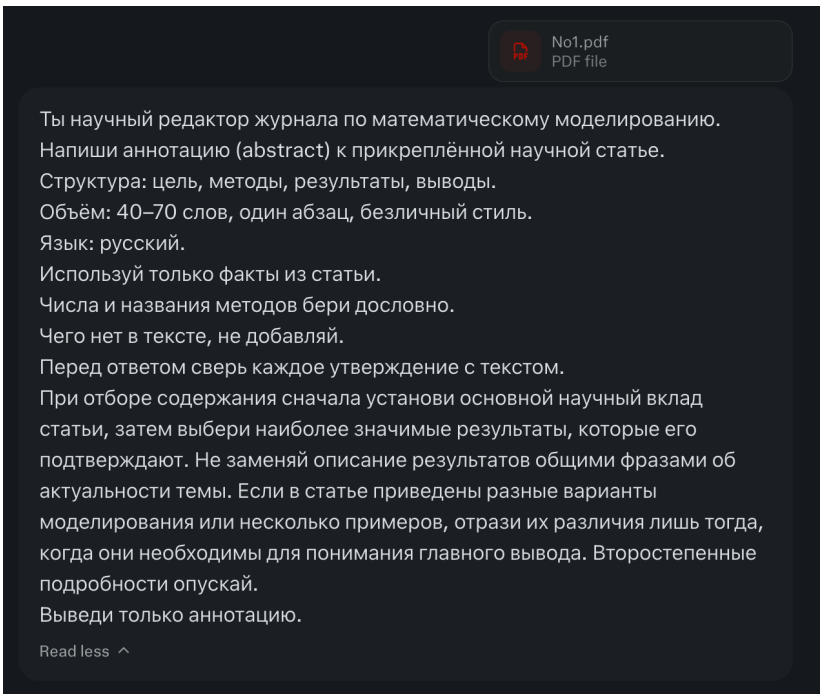


Рисунок 11 – Текст промпта П1

Промпт 2. Приоритизация содержания с конкретизированной проверкой фактов.

Второй вариант развивает П1 и добавляет проверочный перечень перед выдачей готовой аннотации. Отдельно закреплён запрет выводить ссылки на файлы и служебные комментарии. Предполагается, что такой вариант снизит число фактических и терминологических ошибок и повысит соблюдение формата.

Текст промпта П2 представлен на рисунке 12.

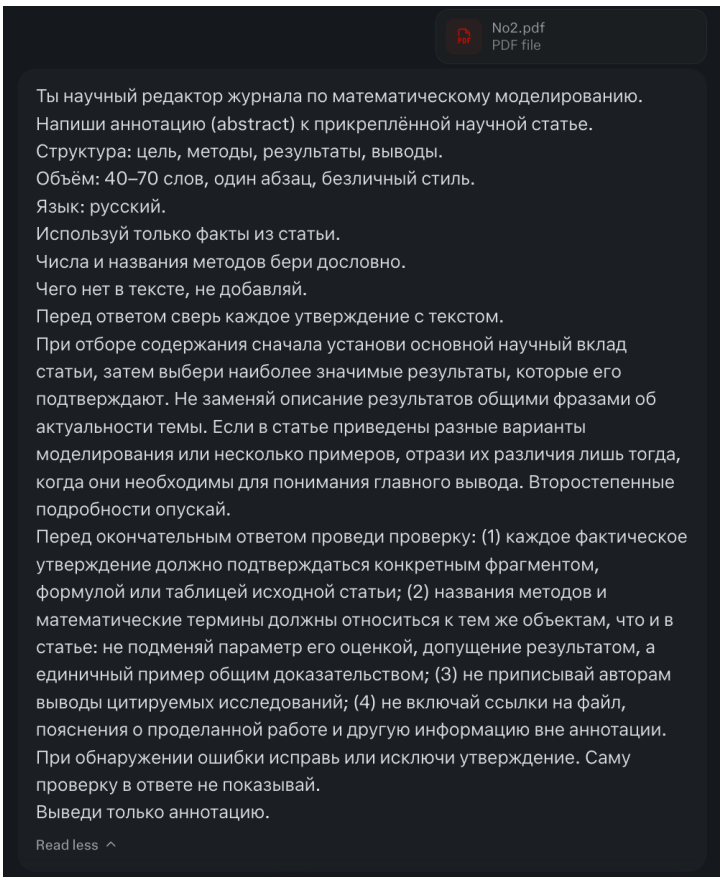


Рисунок 12 – Текст промпта П2

В работе представлены два варианта улучшенного промпта. Для обеих исследуемых статей сохраняются единая структура запросов, основные инструкции и ограничения. При этом отдельные параметры промптов адаптируются с учётом специфики исходного текста: изменяются тематическая специализация научного журнала, язык аннотации и требования к её объёму. Таким образом, для каждого этапа приводится один универсальный вариант промпта, который применяется к обеим статьям после соответствующей адаптации.

Оба улучшенных промпта были применены к двум ранее выбранным статьям в DeepSeek.

Полученные ответы представлены на рисунках 13-16.

Цель работы — предложить подход к имитационному моделированию спортивной игры с непрерывным временем, представляющий матч как марковскую цепь событий и моделирующий изменение счёта методами дискретно-событийного моделирования. Для футбола построена статистическая модель ожидаемого числа голов и исправленное распределение Пуассона; для учёта протяжённости матча применяются условные средние по таймам. Моделирование матча «Ньюкасл»–«Тотенхем» дало наиболее вероятный счёт 1:1, а по таймам — 0:0 и 1:1; реальный исход 2:1. Сделан вывод о предварительном характере модели, требующей апробации и доработки.

Рисунок 13 – Аннотация, сгенерированная DeepSeek по промпту П1(русскоязычная статья)

A Bayesian Edgeworth expansion for marginal posterior densities is developed using Stein's Identity and Hermite polynomials. Repeated application of Stein's Identity yields an asymptotic series whose coefficients depend on posterior moments; comparisons with Johnson (1970) are provided. Two examples, a binomial model with Beta prior and a bivariate normal correlation model with multiple MLEs, show that an O(t^{-3/2}) approximation can be unsatisfactory, whereas expansions using tens of posterior moments capture skewness and bimodality; Johnson's O(t^{-1}) approximation can take negative values in small samples. The expansion can store posterior information through moments and approximate skewed or non-unimodal densities.

Рисунок 14 – Аннотация, сгенерированная DeepSeek по промпту П1(англоязычная статья)

Рассматривается подход к имитационному моделированию спортивной игры, основанный на марковской цепи событий и дискретно-событийном моделировании. Для футбольного матча предложена статистическая модель ожидаемого числа голов с показателями силы атаки и защиты и исправленным распределением Пуассона; параметр α подбирается методом наименьших квадратов. На примере матча «Ньюкасл»–«Тоттенхем» наиболее вероятным оказался счёт 1:1; при разбиении матча на два тайма моделирование дало 0:0 и 1:1. Модель охарактеризована как предварительная, требующая апробации и доработки.

Рисунок 15 – Аннотация, сгенерированная DeepSeek по промпту П2(русскоязычная статья)

A Bayesian Edgeworth expansion for marginal posterior densities is developed by repeatedly applying Stein's Identity together with properties of Hermite polynomials. The expansion expresses posterior density as a Hermite orthogonal series with coefficients given by posterior moments of the normalized maximum likelihood estimator; terms are ordered in powers of sample size. Comparisons with Johnson (1970) and examples for a binomial model and a bivariate normal model with multiple MLEs show that incorporating posterior moments can capture skewed and non-unimodal posterior shapes where low-order approximations fail.

Рисунок 16 – Аннотация, сгенерированная DeepSeek по промпту П2(англоязычная статья)

В таблице 4 сопоставлены результаты.

Таблица 4 – Сравнение результатов DeepSeek при использовании П0, П1 и П2

Статья	**Промпт**	**ROUGE-1 (F1), %**	**ROUGE-L (F1), %**	**Объём, слов**
Русская	П0	23,01	14,16	54
Русская	П1	17,65	11,76	75
Русская	П2	16,92	10,77	68
Английская	П0	43,96	23,08	99
Английская	П1	30,85	13,83	97
Английская	П2	41,18	18,82	85

Для русскоязычной статьи оба улучшенных промпта снизили ROUGE по сравнению с П0. В П1 дополнительно нарушено ограничение по объёму. В П2 объём соответствует требованиям, но не приведён первоначальный результат отдельного моделирования 2:1, сохранённый в П0. Вместе с тем П1 различает реальный исход 2:1 и наиболее вероятный счёт 1:1 и приводит результаты по таймам.

Для англоязычной статьи П1 снизил ROUGE-1. В аннотации появились конкретные детали примеров, отсутствующие в кратком авторском реферате. П2 улучшил результаты относительно П1 до 41,18 % и 18,82 %, но не превысил П0.

При этом П2 повторил выявленную ранее неточную формулировку. Следовательно, дополнительная инструкция о проверке математических объектов не устранила данную ошибку в этом запуске.

Снижение ROUGE не следует отождествлять с ухудшением фактической достоверности. Метрика оценивает совпадение слов и их последовательностей с авторской аннотацией. Поэтому сравнительная оценка учитывает не только ROUGE, но и полноту, достоверность и выполнение ограничений.

Выводы по оптимизации:

Предположение, что последовательное усложнение промпта обязательно повысит качество аннотаций, оказалось неверным. По обеим статьям исходный П0 сохранил максимальные значения ROUGE. Промпт П1 привёл к существенному снижению лексического сходства. Промпт П2 частично восстановил показатели английской аннотации, но не улучшил их относительно П0 и не исправил терминологическую неточность.

В то же время П1 и П2 позволили получить дополнительные существенные детали, подтверждаемые исходными текстами. Поэтому результаты не позволяют признать один вариант безусловно лучшим по всем критериям. В рамках двух статей наиболее предпочтительным по сочетанию ROUGE и соблюдения требований оказался исходный П0. Следует учитывать, что каждый вариант проверялся однократно на каждой статье. Для вывода об устойчивом влиянии отдельных формулировок потребовались бы повторные запуски.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Прядеин, Р. Б. Об одном подходе к имитационному моделированию спортивной игры с непрерывным временем / Р. Б. Прядеин, М. Е. Степанцов // Компьютерные исследования и моделирование. – 2014. – Т. 6, № 3. – С. 455–460.– URL: https://crm.ics.org.ru/journal/article/2159/ (дата обращения: 26.10.2026).
2. ChatGPT : сервис искусственного интеллекта / OpenAI. – URL: https://chatgpt.com/ (дата обращения: 27.10.2026).
3. DeepSeek : сервис искусственного интеллекта / DeepSeek. – URL: https://chat.deepseek.com/ (дата обращения: 27.10.2026).
4. MetricGate. ROUGE Score Calculator : онлайн-калькулятор оценки качества текстовых аннотаций. – URL: https://metricgate.com/calculator/rouge-score (дата обращения: 27.10.2026).
5. Perplexity : поисково-аналитический сервис на основе искусственного интеллекта / Perplexity AI. – URL: https://www.perplexity.ai/ (дата обращения: 27.10.2026).
6. Weng, R. C. A Bayesian Edgeworth expansion by Stein’s identity / R. C. Weng // Bayesian Analysis. – 2010. – Vol. 5, № 4. – P. 741–764. –URL: https://doi.org/10.1214/10-BA526 (дата обращения: 26.10.2026).