Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчёт по лабораторной работе №1
по дисциплине «Автоматизация научных исследований»

# Генерация аннотаций к научным статьям с помощью больших языковых моделей: сравнение моделей и проверка фактов

Выполнили студенты группы
5040102/60201:
Дубровин Т. Г.
Крехов Д. А.
Цибиров М. А.

Преподаватель: Крашенинников С. В.

Санкт-Петербург
2026

## Содержание

1. Цель работы
2. Задание
3. Исходные данные и методика
4. Результаты: статья 1 (русский язык)
5. Результаты: статья 2 (английский язык)
6. Дополнительный эксперимент: простой промпт
7. Дополнительный эксперимент: модели одного семейства
8. Сравнение авторских и сгенерированных аннотаций
9. Сводная таблица
10. Выводы
11. Распределение работы в команде

## 1. Цель работы

Сравнить аннотации, которые генерируют большие языковые модели (LLM) разных производителей к научным статьям на русском и английском языках. Оценить их сходство с авторскими аннотациями по метрикам ROUGE, вручную проверить каждое утверждение по тексту статьи, найти галлюцинации и выбрать модель, которая справилась лучше.

## 2. Задание

По материалам темы 1 курса («Генерация аннотаций по тексту»):

1. Выбрать статью с авторской аннотацией. Работа выполнена командой из трёх человек, поэтому взяты две статьи (на русском и на английском языке) и три модели — по одной на участника.
2. Подготовить текст: удалить из статьи аннотацию и ключевые слова, авторскую аннотацию сохранить отдельно как эталон.
3. Сгенерировать аннотации одним и тем же промптом в нескольких моделях, каждую в новом чате.
4. Посчитать ROUGE-1 и ROUGE-L (F1) для каждой модели относительно авторской аннотации.
5. Проверить факты: каждое утверждение аннотации найти в статье, посчитать выдуманные.
6. Заполнить таблицу результатов и выбрать лучшую модель.

## 3. Исходные данные и методика

### 3.1. Статьи

Обе статьи выбраны по теме самой работы — автоматическое реферирование научных текстов с помощью языковых моделей. Это позволяет заодно сравнить выводы авторов с тем, что мы наблюдаем в своём эксперименте.

| № | Статья | Объём текста после подготовки |
|---|---|---|
| 1 (RU) | Голубинский А.Н., Толстых А.А., Толстых М.Ю. Автоматическая генерация аннотаций научных статей на основе больших языковых моделей // Информатика и автоматизация. 2025. Т. 24, № 1. С. 275–301. DOI: 10.15622/ia.24.1.10 | ≈ 4,6 тыс. слов |
| 2 (EN) | Jaaouine I., King R.D. Mitigating Hallucinations in Zero-Shot Scientific Summarisation: A Pilot Study. arXiv:2512.00931 [cs.CL], 2025 | ≈ 8,2 тыс. слов |

### 3.2. Подготовка текста

Текст извлечён из PDF (библиотека PyMuPDF; стандартный pdftotext ломал кириллицу). Удалены: авторская аннотация, ключевые слова, колонтитулы и номера страниц, список литературы. Из статьи 1 также удалён англоязычный блок в конце: это перевод аннотации, иначе модель увидела бы эталон. Подписи к рисункам и содержимое таблиц остались в тексте. При извлечении потерялись верхние индексы: «222 × $10^6$» превратилось в «222 × 106». Подготовку выполняет скрипт `tools/prepare_texts.py`, поэтому её можно повторить.

### 3.3. Модели

| Модель | Как запускалась |
|---|---|
| **DeepSeek** | Веб-чат chat.deepseek.com, режимы Deep thinking и Smart Search выключены (модель работает только с текстом из запроса). |
| **ChatGPT** | Веб-чат chatgpt.com, бесплатный тариф, модель по умолчанию, режим Think выключен. Длинный текст ChatGPT сам прикрепляет к сообщению как вложение «Pasted text»; содержимое вложения совпадает с промптом. |
| **Claude Opus 5.5** | Anthropic, отдельный чистый контекст без истории. |

Каждый запрос выполнялся в новом чате, параметры генерации — по умолчанию, по одному запуску на каждую комбинацию «статья × промпт». Дополнительно две младшие модели того же семейства — Claude Haiku 5.5 и Claude Sonnet 5.5 — использованы для сравнения моделей разного размера (раздел 7). Всего получено 20 аннотаций. Исходные ответы сохранены без изменений. Для подсчёта метрик из них убраны служебные части: вводная фраза («Вот аннотация…»), заголовок «Аннотация/Abstract», разметка Markdown и придуманные моделью ключевые слова.

### 3.4. Промпты

Основной промпт (v1) построен по шаблону из презентации темы (слайд 14): роль, структура из четырёх частей, объём, запреты на добавление фактов, самопроверка. Объём задан близким к объёму авторских аннотаций (280 и 237 слов). Текст статьи вставлялся вместо `{ARTICLE}`.

```
Ты научный редактор журнала по искусственному интеллекту и обработке
естественного языка.
Напиши аннотацию к научной статье ниже.
Структура: цель, методы, результаты, выводы.
Объём: 230–300 слов, один абзац, безличный стиль.
Язык: русский.
Используй только факты из статьи.
Числа и названия методов бери дословно.
Чего нет в тексте, не добавляй.
Перед ответом сверь каждое утверждение с текстом.
Выведи только аннотацию.

Статья:
"""
{ARTICLE}
"""
```

```
You are a scientific editor of a journal on natural language processing and
artificial intelligence.
Write an abstract for the scientific article below.
Structure: aim, methods, results, conclusions.
Length: 200–250 words, one paragraph, impersonal style.
Language: English.
Use only facts from the article.
Copy numbers and method names verbatim.
Do not add anything that is not in the text.
Before answering, check every statement against the text.
Output only the abstract.

Article:
"""
{ARTICLE}
"""
```

Для сравнения запущен простой промпт (v0) без ограничений — так видно, что именно дают запреты в промпте:

```
Напиши аннотацию к этой научной статье.

{ARTICLE}
```

```
Write an abstract for this scientific article.

{ARTICLE}
```

### 3.5. Метрики

**ROUGE-1 (F1)** — доля общих слов с авторской аннотацией, **ROUGE-L (F1)** — длина общей подпоследовательности слов в том же порядке. Перед подсчётом тексты приведены к нижнему регистру, убрана пунктуация, «ё» заменена на «е»; лемматизации и стоп-слов нет, как в онлайн-калькуляторе из задания. Готовые библиотеки (rouge-score) отбрасывают кириллицу, поэтому подсчёт реализован в скрипте `tools/rouge.py`. Скрипт проверен на примере из презентации («5 из 7» → 71,4 %).

**Проверка фактов** — вручную: каждое утверждение аннотации искали в тексте статьи. **Галлюцинация** — факт, число или вывод, которых в статье нет. Неточность — факт из статьи, но искажённый: усиленный, обобщённый или отнесённый не к тому объекту. Ниже такие фрагменты выделены цветом. Подробный протокол — в файле `factcheck.md`.

**Структура** — наличие четырёх частей: цель, методы, результаты, выводы. **Объём** — число слов и соблюдение требования промпта.

## 4. Результаты: статья 1 (русский язык), промпт v1

### 4.1. Авторская аннотация (эталон)

Предложена концепция автоматизации процесса аннотирования научных материалов (русскоязычных научных статей) и выполнена ее практическая реализация посредством технологий машинного обучения, дообучения больших языковых моделей. Обозначена актуальность корректного и рационального составления аннотаций, выделена проблематика, касающаяся установления баланса между затратами времени на аннотирование и обеспечением соблюдения ключевых требований к аннотации. Проанализированы основы аннотирования, представленные в семействе стандартов по информации, библиотечному и издательскому делу, приведены классификация аннотаций и требования к их наполнению и функционалу. Схемографически представлено существо и содержание процесса аннотирования, типовая структура объекта исследования. Проанализирован вопрос интеграции в процесс аннотирования цифровых технологий, особое внимание уделено преимуществам внедрения машинного обучения и технологий искусственного интеллекта. Кратко описан цифровой инструментарий, применяемый для генерации текста в приложениях обработки естественного языка. Отмечены его недостатки для решения поставленной в данной научной статье задачи. В исследовательской части обоснован выбор модели машинного обучения, применяемый для решения задачи условной генерации текста. Проанализированы существующие предобученные большие языковые модели и с учетом постановки задачи и имеющихся ограничений вычислительных ресурсов выбрана модель ruT5-base. Приведено описание датасета, включающего научные статьи из журналов, включенных в перечень рецензируемых научных изданий, в которых должны быть опубликованы основные научные результаты диссертаций на соискание ученых степеней кандидата и доктора наук. Охарактеризована методика разметки данных, основанная на работе токинезатора предобученной большой языковой модели, графически и таблично приведены численные характеристики распределений датасета и параметры конвейера обучения. Для оценки модели использована метрика качества ROUGE, для оценки результатов – метод экспертных оценок, включающий грамматику и логику в качестве базовых критериев. Качество автоматической генерации аннотаций сопоставимо с реальными текстами, отвечает требованиям информативности, структурированности и компактности. Статья может представлять интерес для аудитории ученых и исследователей, стремящихся оптимизировать свою научную деятельность в части интеграции в процесс написания статей инструментов цифровизации, а также специалистам, занимающимся обучением больших языковых моделей.

Ключевые слова: аннотация, генерация, большие языковые модели, цифровизация, машинное обучение.

### 4.2. Таблица результатов

| Метрика | DeepSeek | ChatGPT | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 28.8 | **29.7** | 26.9 |
| ROUGE-L (F1), % | **14.6** | 11.2 | 12.9 |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 0 | 0 | 0 |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (требование 230–300) | 238 | 274 | 275 |

Объём авторской аннотации: 280 слов. Жирным — лучшее значение ROUGE в строке.

### 4.3. Сгенерированные аннотации

Обозначения: **красным — галлюцинация**, оранжевым — неточность.

**DeepSeek — 238 слов**

Цель работы состояла в решении задачи автоматической генерации аннотаций к научным статьям и совершенствовании процесса аннотирования за счёт применения предобученных больших языковых моделей. Для этого был подготовлен датасет из 825 научных статей, после первичной обработки которого исходный датасет составил 810 пар «текст статьи» – «аннотация»; исходный датасет разбит на обучающую и валидационную выборки в соотношении 80/20 (648 и 162 пары соответственно). Из семейства LLM T5 выбрана модель ruT5-base, содержащая 222 × 106 параметров, дообучение которой выполнялось с максимальной длиной входа 3000 токенов и максимальной длиной аннотации 128 токенов; время обучения модели составило 53 часа. Мониторинг обучения проводился с помощью метрики ROUGE, дополнительно каждую эпоху выполнялась субъективная оценка на основе 5 сгенерированных пар «текст – аннотация». Для верификации результатов использована экспертная оценка по двум критериям — грамматика и логика — по 10-балльной шкале; в оценке принимал участие 51 эксперт, каждый из которых оценивал 40 пар «статья-аннотация», при этом общий набор данных для оценки содержал 200 пар «статья-аннотация». Результаты оценки модели до дообучения по критерию «грамматика» составили 7,8±1,33 балла, по логике – 1,52±0,79 балла; распределения оценок для реальных и сгенерированных аннотаций практически неотличимы, что подтверждено статистическим тестом Колмогорова-Смирнова (p-value 0,842 для грамматики и 0,941 для логики). Сделан вывод, что качество генерации сопоставимо с реальными аннотациями и отвечает требованиям информативности, структурированности и компактности действующих стандартов; разработка внедрена в учебный процесс государственного вуза в виде веб-приложения, а дальнейшее исследование предполагает дообучение моделей и оценку сгенерированных аннотаций с точки зрения требований нормативных документов.

**ChatGPT — 274 слов**

Цель исследования заключается в разработке и оценке модели автоматической генерации аннотаций к научным статьям на основе дообучения предобученной большой языковой модели с учетом требований к информативности, структурированности и компактности аннотаций. Методы исследования включают сбор и разметку датасета пар «текст статьи» – «аннотация», дообучение модели ruT5-base архитектуры T5 и оценку качества генерации с использованием метрики ROUGE и экспертного оценивания по двум критериям: грамматика и логика. Исходный датасет сформирован на основе 825 научных статей из 22 томов трех научно-практических журналов; после исключения 15 статей без аннотаций для обучения использовано 810 пар, разделенных на обучающую выборку из 648 пар и валидационную выборку из 162 пары в соотношении 80/20. Дообучение модели проводилось при максимальной длине входа 3000 токенов и максимальной длине аннотации 128 токенов; время обучения составило 53 часа. Качество генерации оценивалось экспертами по 10-балльной шкале, а статистическая неразличимость оценок реальных и сгенерированных аннотаций проверялась тестом Колмогорова-Смирнова. Результаты исследования показали, что дообученная модель формирует аннотации, качество которых сопоставимо с качеством реальных аннотаций. Для оценок грамматики получено p-value 0,842, для оценок логики — 0,941, что подтверждает статистическую неразличимость распределений оценок. Оценка на дополнительных тестовых данных, включающих 112 пар «аннотация – текст», практически не отличается от оценки на валидационной выборке, что свидетельствует о способности модели к обобщению. Установлено, что модель генерирует аннотации сопоставимого качества для различных областей науки, представленных в валидационных данных. Выводы. Разработанная модель обеспечивает автоматическую генерацию кратких характеристик научных статей, соответствующих основным требованиям к содержанию аннотаций. Результаты подтверждают перспективность применения больших языковых моделей для оптимизации аннотирования научных публикаций. Практическая реализация представлена веб-приложением, внедренным в учебный процесс государственного вуза. Полученные аннотации рекомендуется использовать как инструмент поддержки принятия решений в сочетании с авторскими знаниями, критическим мышлением, анализом и интерпретацией данных.

**Claude Opus 5.5 — 275 слов**

Цель работы — автоматизация составления аннотаций научных статей путём дообучения предобученной большой языковой модели для задачи условной генерации текста. С учётом ограниченности вычислительных ресурсов (16 GB GPU) выбрана модель ruT5-base из семейства T5. Сформирован датасет пар «текст статьи» – «аннотация» на основе выпусков за последние 5 лет журналов Вестник Московского университета МВД России имени В.Я. Кикотя, Вестник Краснодарского университета МВД России и Вестник Воронежского института МВД России: из 825 размеченных статей 22 томов после исключения 15 статей без аннотаций получено 810 пар, разбитых на обучающую (648 пар) и валидационную (162 пары) выборки в соотношении 80/20. Длина входа ограничена 3000 токенами, выхода — 128 токенами; темп обучения составил 2 × 10−5, затухание весов — 0.01, время обучения — 53 часа. Ход обучения контролировался метрикой ROUGE и субъективной оценкой сгенерированных пар. Предложена методика экспертной оценки по двум критериям — грамматика и логика — по 10 бальной шкале: 51 эксперт оценивал по 40 пар «статья-аннотация» (20 реальных и 20 сгенерированных аннотаций в случайном порядке) из общего набора в 200 пар. До дообучения модель получила 7,8±1,33 балла по грамматике и 1,52±0,79 балла по логике. Тест Колмогорова-Смирнова показал статистическую неразличимость оценок реальных и сгенерированных аннотаций (p-value 0,842 для грамматики и 0,941 для логики). Качество генерации оказалось одинаковым для 6 областей науки валидационной выборки, а оценка на 112 дополнительных тестовых парах практически не отличалась от оценки на валидации, что указывает на способность модели к обобщению, а не только к заучиванию обучающих данных. Сделан вывод о сопоставимости качества сгенерированных и реальных аннотаций; разработка внедрена в учебный процесс государственного вуза в виде веб-приложения. Дальнейшие исследования предполагают дообучение мультиязычных больших языковых моделей и изучение качества генерации при расширении датасета текстами из различных предметных областей.

Выдуманных фактов нет ни у одной модели. Все числа — 825 статей из 22 томов, 15 исключённых, 810 пар, 648/162, 3000 и 128 токенов, 53 часа, 51 эксперт, 200 пар, p = 0,842 и 0,941, 112 тестовых пар — перенесены из статьи дословно. DeepSeek повторил искажённое при извлечении «222 × 106 параметров». Это ошибка нашего текста, а не модели: Claude Opus и ChatGPT это число просто не упомянули. ChatGPT единственный вынес «Выводы» отдельным предложением-заголовком. Требование объёма соблюдено всеми.

## 5. Результаты: статья 2 (английский язык), промпт v1

### 5.1. Авторская аннотация (эталон)

Large language models (LLMs) produce context inconsistency hallucinations, which are LLM-generated outputs that are misaligned with the user prompt. This research project investigates whether prompt engineering (PE) methods can mitigate context inconsistency hallucinations in zero-shot LLM summarisation of scientific texts, where zero-shot indicates that the LLM relies purely on its pre-training data. Across eight yeast biotechnology research paper abstracts, six instruction-tuned LLMs were prompted with seven methods: a baseline prompt, two levels of increasing instruction complexity (PE-1 and PE-2), two levels of context repetition (CR-K1 and CR-K2), and two levels of random addition (RA-K1 and RA-K2). Context repetition involved the identification and repetition of K key sentences from the abstract, whereas random addition involved the repetition of K randomly selected sentences from the abstract, where K ∈{1,2}. A total of 336 LLM-generated summaries were evaluated using six metrics: ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR, and cosine similarity, which were used to compute the lexical and semantic alignment between the summaries and the abstracts. Four hypotheses on the effects of prompt methods on summary alignment with the reference text were tested. Statistical analysis on 3744 collected datapoints was performed using bias-corrected and accelerated (BCa) bootstrap confidence intervals and Wilcoxon signed-rank tests with Bonferroni-Holm correction. The results demonstrated that CR and RA significantly improve the lexical alignment of LLM-generated summaries with the abstracts. These findings indicate that prompt engineering has the potential to impact hallucinations in zero-shot scientific summarisation tasks.

Keywords: Large Language Models · Prompt Engineering · Scientific Summarisation · Information Retrieval

### 5.2. Таблица результатов

| Метрика | DeepSeek | ChatGPT | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 52.3 | **60.1** | 59.0 |
| ROUGE-L (F1), % | 28.6 | **34.8** | 32.7 |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 0 | 0 | 0 |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (требование 200–250) | 218 | 251 ✗ | 234 |

Объём авторской аннотации: 237 слов. Жирным — лучшее значение ROUGE в строке.

### 5.3. Сгенерированные аннотации

**DeepSeek — 218 слов**

This pilot study aimed to investigate whether prompt engineering methods can mitigate context inconsistency hallucinations in zero-shot scientific summarisation, measured by proxy through the lexical and semantic alignment between LLM-generated summaries and reference text. Eight open-access yeast biotechnology paper abstracts were summarised by six instruction-tuned LLMs under seven prompt conditions (baseline, PE-1, PE-2, CR-K1, CR-K2, RA-K1, RA-K2), yielding 336 LLM-generated summaries; evaluation used ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, cosine similarity, and METEOR Score, with significance tested via Wilcoxon signed-rank tests with Bonferroni-Holm correction and bias-corrected and accelerated (BCa) bootstrap 95% confidence intervals, considering only combinations significant across both tests. The results showed that context repetition (CR-K1 and CR-K2) significantly improved lexical alignment with the abstract, supporting H1, and random addition (RA-K1 and RA-K2) achieved the highest improvement in lexical alignment, supporting H2; increased instruction complexity did not significantly improve alignment, with PE-1 causing a decline in semantic alignment across BERTScore, cosine similarity, and METEOR score, so H3 was not supported; and H4 was partially supported, as CR-K2 significantly improved lexical alignment with repeated key sentences only across ROUGE-2 for K = 2. It is concluded that prompt method can have a significant effect on lexical and semantic alignment in zero-shot scientific summarisation, and that prompt engineering presents a practical tool for reducing context inconsistency hallucinations within LLM-based scientific summarisation.

**ChatGPT — 251 слов**

This study aimed to investigate whether prompt engineering methods could mitigate context inconsistency hallucinations in zero-shot scientific summarisation. A systematic framework was developed to evaluate seven prompt methods across six instruction-tuned large language models (LLMs) using abstracts from eight open-access yeast biotechnology papers. The methods comprised a baseline prompt, two levels of prompt engineering (PE-1 and PE-2), two context repetition methods (CR-K1 and CR-K2), and two random addition methods (RA-K1 and RA-K2). A total of 336 LLM-generated summaries were evaluated using six metrics: ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, cosine similarity, and METEOR Score. Statistical significance was assessed using the Wilcoxon signed-rank test with Bonferroni-Holm correction and the bias-corrected and accelerated (BCa) bootstrap method to estimate 95% confidence intervals. The results demonstrated that context repetition significantly improved lexical alignment with the abstract across ROUGE-1, ROUGE-2, and ROUGE-L, supporting H1. Random addition significantly improved lexical alignment with the abstract and alignment with repeated key sentences across multiple evaluation metrics, supporting H2. Increasing instruction complexity did not improve semantic alignment: PE-1 significantly reduced alignment across BERTScore, cosine similarity, and METEOR score, while PE-2 showed no significant performance effects, leading to the rejection of H3. H4 was partially supported, as CR-K2 significantly improved alignment with repeated key sentences only across ROUGE-2, whereas CR-K1 showed no significant improvement. These findings indicate that context repetition and random addition can improve alignment in zero-shot scientific summarisation, while increased instruction complexity may negatively affect semantic alignment. The limited dataset and absence of human validation constrain the generalisability of the findings.

**Claude Opus 5.5 — 234 слов**

The study investigates whether prompt methods can mitigate context inconsistency hallucinations in zero-shot large language model (LLM) summarisation of yeast biotechnology abstracts. Seven prompt methods were evaluated: a simple baseline prompt, two prompts of increasing instruction complexity (PE-1 and PE-2), context repetition of key sentences (CR-K1, CR-K2) and random addition of abstract sentences (RA-K1, RA-K2). Abstracts of eight open-access papers were summarised by six instruction-tuned LLMs via the Hugging Face Inference API, yielding 336 summaries. Lexical and semantic alignment with the abstract and with repeated key sentences was measured using ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR score and cosine similarity, giving 3744 evaluation metrics. Paired differences from the baseline were tested with the Wilcoxon signed-rank test with Bonferroni-Holm correction and the bias-corrected and accelerated (BCa) bootstrap method with 10000 replicates. Context repetition significantly improved lexical alignment with the abstract across ROUGE-1, ROUGE-2 and ROUGE-L for K = 1,2. Random addition significantly improved lexical and semantic alignment with both the abstract and the key sentences and achieved the highest improvement in lexical alignment. PE-1 significantly reduced semantic alignment across BERTScore, cosine similarity and METEOR score, while PE-2 effects were not significant. Context repetition improved alignment with repeated key sentences only across ROUGE-2 for K = 2. It is concluded that prompt methods can significantly affect lexical and semantic alignment in zero-shot scientific summarisation and that prompt engineering is a practical tool for reducing context inconsistency hallucinations.

Галлюцинаций нет ни у одной модели. Все три модели верно передали исход четырёх гипотез, отрицательный эффект PE-1 и то, что значимыми считались только результаты, подтверждённые обоими тестами. ChatGPT превысил лимит объёма на одно слово (251 при максимуме 250). Все модели указали исход гипотезы H4 как «partially supported», по таблице 4 статьи. Сама статья здесь себе противоречит: в разделе Conclusions сказано, что H4 не подтверждена. Ни одна модель это противоречие не отметила.

## 6. Дополнительный эксперимент: простой промпт v0

Те же статьи и модели, но промпт без структуры, объёма и запретов («Напиши аннотацию к этой научной статье»).

### 6.1. Статья 1 (RU)

| Метрика | DeepSeek | ChatGPT | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | **28.8** | 27.7 | 24.8 |
| ROUGE-L (F1), % | 12.6 | **14.1** | 13.8 |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 0 | 0 | 0 |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (не задан) | 163 | 148 | 141 |

Объём авторской аннотации: 280 слов. Жирным — лучшее значение ROUGE в строке.

**DeepSeek — 163 слов**

Статья посвящена решению актуальной задачи автоматической генерации аннотаций к научным статьям с использованием больших языковых моделей (LLM). Авторы обосновывают необходимость автоматизации процесса аннотирования, указывая на его трудоемкость, субъективность и отсутствие универсальных методик, а также на возрастающие объемы научной информации. В работе проведен анализ нормативных требований к составлению аннотаций (ГОСТ 7.9-95, ГОСТ Р 7.0.99-2018), рассмотрены аспекты цифровизации аннотирования и связанные с ней этические риски. Практическая часть исследования включает подготовку датасета из 810 пар «текст статьи – аннотация» на основе научных журналов ведомственных вузов МВД России (экономика, юриспруденция, педагогика, технические науки) и дообучение предобученной модели ruT5-base архитектуры T5. Для оценки качества генерации предложена методика экспертной оценки по критериям «грамматика» и «логика» с привлечением 51 эксперта. Результаты статистического анализа (тест Колмогорова-Смирнова) показали, что распределения оценок сгенерированных и реальных аннотаций статистически неразличимы, что свидетельствует о высоком качестве генерации. Разработка внедрена в учебный процесс в виде веб-приложения, позиционируемого как система поддержки принятия решений при написании научных работ. Обозначены направления дальнейших исследований, включая расширение датасета и дообучение мультиязычных моделей.

**ChatGPT — 148 слов**

Статья посвящена исследованию возможностей автоматической генерации аннотаций научных статей с использованием больших языковых моделей. Рассматриваются нормативные требования к составлению аннотаций, особенности применения цифровых технологий и проблемы обеспечения качества генерируемых текстов. Для решения поставленной задачи выполнено дообучение языковой модели ruT5-base на корпусе научных публикаций, включающем 810 пар «текст статьи — аннотация». Разработана методика оценки качества генерации, основанная на экспертном анализе грамматической корректности и логической согласованности аннотаций, а также использовании метрики ROUGE. Экспериментальные результаты показали статистическую неразличимость оценок сгенерированных и авторских аннотаций по исследуемым критериям, что свидетельствует о сопоставимости их качества. Проведена дополнительная проверка модели на независимой тестовой выборке, подтвердившая способность обобщать полученные при обучении закономерности. Практическая значимость исследования заключается в возможности сокращения временных затрат на подготовку аннотаций и повышения эффективности обработки научной информации. Разработанное решение реализовано в виде веб-приложения и внедрено в учебный процесс вуза. Подчеркивается необходимость экспертной проверки результатов генерации и сохранения авторского контроля над содержанием научных публикаций.

**Claude Opus 5.5 — 141 слов**

В статье рассматривается автоматическая генерация аннотаций к научным статьям с помощью больших языковых моделей. Авторы анализируют требования ГОСТ 7.9-95 и ГОСТ Р 7.0.99-2018 к содержанию и структуре аннотации, обзор цифровых инструментов аннотирования и связанные с ними этические риски. Для решения задачи дообучена русскоязычная модель ruT5-base на собранном датасете из 810 пар «текст статьи – аннотация» из ведомственных журналов вузов МВД России (юриспруденция, экономика, педагогика, технические науки). Описаны подготовка данных, ограничение длины входа и выхода модели в токенах и параметры обучения. Предложена методика экспертной оценки по двум критериям — грамматике и логике — с вслепую перемешанными реальными и сгенерированными аннотациями. Тест Колмогорова-Смирнова показал, что оценки сгенерированных и реальных аннотаций статистически неразличимы; на дополнительной тестовой выборке качество сохраняется, а по разным областям науки оно одинаково. Разработка внедрена в учебный процесс вуза в виде веб-приложения и рассматривается как система поддержки принятия решений для авторов.

### 6.2. Статья 2 (EN)

| Метрика | DeepSeek | ChatGPT | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | **58.5** | 54.8 | 54.4 |
| ROUGE-L (F1), % | **38.0** | 33.9 | 30.5 |
| Галлюцинации, шт. | 0 | 0 | **1** |
| Неточности, шт. | 0 | 0 | **1** |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (не задан) | 305 | 268 | 314 |

Объём авторской аннотации: 237 слов. Жирным — лучшее значение ROUGE в строке.

**DeepSeek — 305 слов**

Background: Large language models (LLMs) increasingly support scientific workflows, including automatic summarisation. However, LLMs frequently produce context inconsistency hallucinations—outputs misaligned with the provided source material—which threaten the integrity of LLM-generated scientific information, particularly for publications outside their training knowledge boundaries.

Objective: This pilot study investigates whether prompt engineering can mitigate context inconsistency hallucinations in zero-shot scientific summarisation of yeast biotechnology abstracts. Specifically, it examines the effects of increasing instruction complexity, repetition of semantically key sentences, and random sentence addition on the lexical and semantic alignment between LLM-generated summaries and reference texts.

Methods: Eight open-access yeast biotechnology abstracts were summarised by six instruction-tuned LLMs (7B–72B parameters) under seven prompt conditions: a baseline prompt, two prompts of increasing instruction complexity (PE-1, PE-2), two levels of key-sentence repetition (CR-K1, CR-K2), and two levels of random sentence addition (RA-K1, RA-K2), yielding 336 summaries. Alignment was evaluated using six metrics: ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR, and cosine similarity. Statistical significance was assessed using Wilcoxon signed-rank tests with Bonferroni-Holm correction and bias-corrected and accelerated (BCa) bootstrap confidence intervals.

Results: Context repetition significantly improved lexical alignment with the abstract (H1 supported), and random addition improved both lexical and semantic alignment (H2 supported). Increased instruction complexity did not improve semantic alignment; PE-1 significantly reduced it (H3 not supported). Context repetition improved alignment with repeated key sentences only for K=2 under ROUGE-2 (H4 partially supported). Random addition yielded the largest gains, with variance differences between CR-K2 and RA-K2 non-significant.

Conclusions: Prompt engineering can significantly affect the lexical and semantic alignment of zero-shot scientific summaries, with context repetition and random sentence addition improving alignment while increased instruction complexity can impair it. These findings present prompt engineering as a practical, low-cost approach to mitigating context inconsistency hallucinations in LLM-based scientific summarisation. Limitations include the small corpus, reliance on automatic metrics without human validation, and zero-shot-only evaluation.

**ChatGPT — 268 слов**

Large language models (LLMs) offer potential for scientific summarisation but may generate hallucinations when summaries are inconsistent with their source material. This pilot study investigates whether prompt engineering can mitigate context inconsistency hallucinations in zero-shot scientific summarisation by improving the lexical and semantic alignment of generated summaries with source abstracts. Eight open-access yeast biotechnology abstracts were summarised using six instruction-tuned LLMs under seven prompt conditions: a baseline prompt, two levels of increasing instruction complexity, and four methods involving the repetition of semantically relevant or randomly selected sentences. In total, 336 summaries were generated and evaluated using six automatic metrics: ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR, and cosine similarity. Statistical significance was assessed using Wilcoxon signed-rank tests with Bonferroni–Holm correction and bias-corrected and accelerated bootstrap confidence intervals. The results demonstrate that repeating key sentences significantly improved lexical alignment with the source abstracts, while random sentence addition produced the strongest improvements in lexical alignment and also improved semantic alignment in several experimental conditions. In contrast, increasing instruction complexity did not consistently improve alignment, and the simplest engineered prompt significantly reduced semantic alignment. Repetition of key sentences produced only limited improvements when the repeated sentences themselves served as the evaluation reference. These findings suggest that incorporating additional source text into prompts may be more effective than increasing instruction complexity for improving alignment in zero-shot scientific summarisation. However, the small corpus and reliance on automatic evaluation metrics limit the generalisability of the findings. This pilot study provides preliminary evidence that simple prompt modifications may help mitigate context inconsistency hallucinations in LLM-generated scientific summaries, motivating further investigation across larger and more diverse scientific datasets.

**Claude Opus 5.5 — 314 слов**

Large language models (LLMs) often hallucinate, and in scientific summarisation that can distort knowledge and erode trust in scientific information. This pilot study tests whether prompt design can reduce context inconsistency hallucinations, a type of faithfulness hallucination, in zero-shot summarisation of scientific abstracts. Abstracts from eight open-access yeast biotechnology papers were summarised by six instruction-tuned LLMs (7B to 72B parameters) under seven prompt conditions. The conditions were a minimal baseline prompt, two prompts with increasing instruction complexity (PE-1 and PE-2), context repetition of one or two semantically key sentences chosen by embedding similarity (CR-K1 and CR-K2), and random addition of one or two abstract sentences (RA-K1 and RA-K2). This produced 336 summaries. Hallucination was measured by proxy as the lexical and semantic alignment between each summary and its source abstract, and also its alignment with the repeated key sentences. Six metrics were used: ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR and cosine similarity. Each prompt method was compared with the baseline using paired differences. Significance was tested with Holm-Bonferroni-corrected Wilcoxon signed-rank tests and BCa bootstrap 95% confidence intervals, and only effects significant under both tests were accepted. Context repetition significantly improved lexical alignment with the abstract on all ROUGE metrics, and random addition gave the largest gains in both lexical and semantic alignment. Greater instruction complexity did not improve semantic alignment. PE-1 significantly reduced BERTScore, METEOR and cosine similarity, and PE-2 had no significant effect. Context repetition increased alignment with the repeated key sentences only on ROUGE-2 for K = 2. These results suggest that repeating source content in the prompt is a simple, low-cost way to improve the faithfulness of LLM-generated scientific summaries, while extra instructions can be counterproductive. **Because random sentences outperformed semantically selected ones, prompt length and repetition itself, rather than semantic relevance, may drive the effect**. The main limitations are the small corpus, the lack of human validation and possible length confounds.

Без запретов Claude Opus дописал в английскую аннотацию собственный вывод, которого в статье нет: эффект «возможно, вызван длиной промпта и самим повтором, а не семантической релевантностью». Авторы такого вывода не делают, они лишь предлагают изучить роль релевантности в будущих работах. Это типичная галлюцинация «вывода»: правдоподобная, логичная, но не принадлежащая авторам. DeepSeek и ChatGPT фактов не выдумали, но вольно обошлись с форматом. DeepSeek начал ответ с фразы «Вот аннотация…», а английскую аннотацию оформил как структурированный реферат с подзаголовками Background / Objective / Methods / Results / Conclusions. ChatGPT без запроса добавил собственный список ключевых слов. В русских аннотациях v0 у всех моделей почти нет чисел: модели описывают, *что* сделано, а не *что получено*.

## 7. Дополнительный эксперимент: модели одного семейства

Чтобы отделить влияние производителя от влияния размера модели, тот же эксперимент повторён на трёх моделях Claude разного размера: Haiku 5.5 (компактная), Sonnet 5.5 (средняя), Opus 5.5 (старшая; её тексты приведены в разделах 4–6).

### 7.1. Промпт v1

**Статья 1 (RU)**

| Метрика | Claude Haiku 5.5 | Claude Sonnet 5.5 | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 24.2 | 25.9 | **26.9** |
| ROUGE-L (F1), % | **13.9** | 10.4 | 12.9 |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 2 | 0 | 0 |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (требование 230–300) | 217 ✗ | 263 | 275 |

Объём авторской аннотации: 280 слов. Жирным — лучшее значение ROUGE в строке.

**Статья 2 (EN)**

| Метрика | Claude Haiku 5.5 | Claude Sonnet 5.5 | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 54.6 | 56.2 | **59.0** |
| ROUGE-L (F1), % | **33.0** | 31.7 | 32.7 |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 1 | 0 | 0 |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (требование 200–250) | 216 | 234 | 234 |

Объём авторской аннотации: 237 слов. Жирным — лучшее значение ROUGE в строке.

### 7.2. Промпт v0

**Статья 1 (RU)**

| Метрика | Claude Haiku 5.5 | Claude Sonnet 5.5 | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 20.3 | **25.2** | 24.8 |
| ROUGE-L (F1), % | 11.8 | 12.4 | **13.8** |
| Галлюцинации, шт. | 0 | 0 | 0 |
| Неточности, шт. | 0 | 0 | 0 |
| Структура, из 4 | 3 | 4 | 4 |
| Объём, слов (не задан) | 91 | 173 | 141 |

Объём авторской аннотации: 280 слов. Жирным — лучшее значение ROUGE в строке.

### Статья 2 (EN)

| Метрика | Claude Haiku 5.5 | Claude Sonnet 5.5 | Claude Opus 5.5 |
|---|---|---|---|
| ROUGE-1 (F1), % | 59.7 | **59.8** | 54.4 |
| ROUGE-L (F1), % | **37.0** | 32.4 | 30.5 |
| Галлюцинации, шт. | 0 | **1** | **1** |
| Неточности, шт. | 0 | 0 | **1** |
| Структура, из 4 | 4 | 4 | 4 |
| Объём, слов (не задан) | 222 | 283 | 314 |

Объём авторской аннотации: 237 слов. Жирным — лучшее значение ROUGE в строке.

## 7.3. Аннотации Haiku и Sonnet

Промпт v1, RU:

**Claude Haiku 5.5 — 217 слов**

Цель работы — автоматизировать генерацию аннотаций к научным статьям на основе большой языковой модели, что позволяет сократить время на составление аннотаций и повысить качество результата. Исследование ограничено выпусками журналов МВД России за последние 5 лет в областях экономики и юриспруденции, педагогики и технических наук в контексте правоохранительной деятельности. Для решения задачи выбрана модель ruT5-base, дообученная на датасете пар «текст статьи – аннотация». Исходный датасет включал 825 статей из 22 томов; после исключения 15 статей без аннотаций (2%) получено 810 пар, разбитых на обучающую (648) и валидационную (162) выборки в соотношении 80/20. Длина входа ограничена 3000 токенами, выход – 128 токенами; темп обучения $2\times10^{-5}$, затухание весов 0,01, время обучения 53 часа. Обучение контролировалось метрикой ROUGE, качество оценивалось экспертами по грамматике и логике на 10-балльной шкале. В оценке участвовали 51 эксперт, каждый оценивал 40 пар, всего 200 пар «статья–аннотация». До дообучения результаты были неудовлетворительными: грамматика 7,8±1,33 балла, логика 1,52±0,79 балла. Тест Колмогорова–Смирнова показал статистическую неразличимость оценок реальных и сгенерированных аннотаций (p-value 0,842 для грамматики, 0,941 для логики). Оценки на дополнительных тестовых данных (112 пар) практически не отличаются от валидационных. Вывод: качество генерации сопоставимо с реальными аннотациями, модель соответствует требованиям информативности, структурированности и компактности; разработка внедрена в учебный процесс государственного вуза в виде веб-приложения. Дальнейшие задачи — оценка по нормативным требованиям, дообучение мультиязычных моделей и расширение датасета другими предметными областями.

**Claude Sonnet 5.5 — 263 слов**

Цель работы — разработка метода автоматической генерации аннотаций к научным статьям на русском языке на основе больших языковых моделей. Задача рассмотрена как условная генерация текста и решена дообучением предобученной модели ruT5-base, содержащей 222 × 10^6 параметров, с учётом доступных 16 GB GPU. Для дообучения собран датасет пар «текст статьи» – «аннотация» из научных журналов за последние 5 лет по экономике и юриспруденции, педагогике и техническим наукам в контексте правоохранительной деятельности: размечено 825 статей, после исключения 15 статей без аннотаций осталось 810 пар, разбитых на обучающую (648 пар) и валидационную (162 пары) выборки в соотношении 80/20. Длина входа ограничена 3000 токенов, выхода — 128 токенов; темп обучения составил 2 × 10−5, затухание весов — 0.01, время обучения — 53 часа. Ход обучения контролировался метрикой ROUGE. Качество оценивалось экспертами по 10-балльной шкале по двум критериям: грамматика и логика. В оценке участвовали 51 эксперт, каждый оценивал 40 пар, содержащих 20 реальных и 20 сгенерированных аннотаций в случайном порядке без информации об источнике; общий набор включал 200 пар, и каждую пару оценивали в среднем 20 экспертов. Распределения оценок реальных и сгенерированных аннотаций оказались практически неотличимы: критерий Колмогорова-Смирнова дал p-value 0,842 для грамматики и 0,941 для логики. Модель генерирует аннотации с одинаковым качеством для разных областей науки, а на дополнительных тестовых данных объёмом 112 пар оценка практически не отличается от оценки на валидации, что указывает на способность к обобщению. Сделан вывод, что качество генерации сопоставимо с реальными аннотациями. Разработка внедрена в учебный процесс государственного вуза в виде веб-приложения и позиционируется как система поддержки принятия решений. Дальнейшие исследования предполагают дообучение мультиязычных моделей и изучение поведения модели при расширении датасета.

Промпт v1, EN:

**Claude Haiku 5.5 — 216 слов**

The aim of this pilot study was to determine whether prompt engineering can mitigate context inconsistency hallucinations in zero-shot summarisation of yeast biotechnology abstracts. Eight open-access abstracts from arXiv were summarised by six instruction-tuned LLMs under seven prompt conditions: a baseline prompt, two prompt engineering levels (PE-1, PE-2), two context repetition methods (CR-K1, CR-K2) that repeated key sentences, and two random addition methods (RA-K1, RA-K2). This produced 336 summaries, evaluated against the abstracts using ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, cosine similarity and METEOR, and against key sentences for context repetition and random addition. Paired differences from the baseline were analysed using BCa bootstrap confidence intervals and Wilcoxon signed-rank tests with Bonferroni-Holm correction, and only combinations significant under both tests were considered. Hypotheses H1 and H2 were supported: context repetition and random addition improved lexical alignment with the abstract. H3 was not supported, as PE-1 significantly reduced semantic alignment and PE-2 showed no significant effect. H4 was partially supported, as CR-K2 improved lexical alignment with key sentences only for ROUGE-2. The prompt method significantly affected alignment, with RA-K2 achieving the highest lexical improvement. Increased instruction complexity did not significantly improve alignment. Prompt engineering was therefore presented as a practical tool for reducing context inconsistency hallucinations, although the small corpus, zero-shot setting and absence of human validation limit generalisation.

**Claude Sonnet 5.5 — 234 слов**

This study investigated whether prompt engineering can mitigate context inconsistency hallucinations in zero-shot scientific summarisation, quantified by proxy through the lexical and semantic alignment between LLM-generated summaries and reference texts. Abstracts of eight open-access yeast biotechnology papers were summarised by six instruction-tuned LLMs under seven prompt conditions: a baseline, two prompts of increasing instruction complexity (PE-1 and PE-2), context repetition of key sentences (CR-K1 and CR-K2), and random addition of sentences (RA-K1 and RA-K2), producing 336 summaries. Summaries were evaluated using ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR and cosine similarity. Paired differences from the baseline were tested using the Wilcoxon signed-rank test with Bonferroni-Holm correction and BCa bootstrap 95% confidence intervals (10000 replicates); only combinations significant in both tests were considered. CR-K1 and CR-K2 significantly improved lexical alignment with the abstract across ROUGE-1, ROUGE-2 and ROUGE-L (H1 supported). Random addition also significantly improved alignment (H2 supported), and RA-K2 obtained the highest mean score against the abstract (0.680, compared with 0.545 for the baseline). PE-1 significantly reduced semantic alignment across BERTScore, cosine similarity and METEOR, while PE-2 effects were not significant (H3 not supported). Context repetition improved alignment with the repeated key sentences only for K = 2 on ROUGE-2 (H4 partially supported). Context repetition and random addition can improve summary alignment, whereas increased instruction complexity did not. Limitations include the dataset of eight abstracts, the absence of human validation, and the use of zero-shot prompting.

Промпт v0, RU:

**Claude Haiku 5.5 — 91 слов**

В статье рассматривается автоматическая генерация аннотаций научных статей с помощью большой языковой модели. Проанализированы требования ГОСТ 7.9-95 и ГОСТ Р 7.0.99-2018 к аннотациям и типовая структура аннотации. Для дообучения выбрана модель ruT5-base, дообученная на датасете из 810 пар «текст статьи – аннотация» по журналам МВД России (экономика, юриспруденция, педагогика, технические науки в контексте правоохранительной деятельности). Качество оценивалось экспертами по грамматике и логике: распределения оценок реальных и сгенерированных аннотаций статистически неразличимы (критерий Колмогорова–Смирнова, p = 0,842 для грамматики и 0,941 для логики). Разработка внедрена в учебный процесс государственного вуза в виде веб-приложения.

**Claude Sonnet 5.5 — 173 слов**

Рассматривается задача автоматической генерации аннотаций к научным статьям на русском языке. Описаны требования российских стандартов (ГОСТ 7.9-95, ГОСТ Р 7.0.99-2018) к содержанию и структуре аннотации, а также возможности и ограничения цифровых инструментов аннотирования, включая вопросы академической этики. Для решения задачи условной генерации текста дообучена предобученная модель ruT5-base на собранном датасете из 810 пар «текст статьи – аннотация» по экономике, юриспруденции, педагогике и техническим наукам в контексте правоохранительной деятельности. Выбор модели обусловлен ограниченными вычислительными ресурсами (16 GB GPU); длина входа ограничена 3000 токенами, выхода – 128 токенами. Качество оценивалось по метрике ROUGE и методике экспертной оценки по критериям «грамматика» и «логика», в которой 51 эксперт-обучающийся оценивал смешанные наборы реальных и сгенерированных аннотаций. Тест Колмогорова-Смирнова показал статистическую неразличимость оценок реальных и сгенерированных аннотаций; качество сохраняется в разных областях науки и на новых тестовых данных (112 пар). Разработка внедрена в учебный процесс вуза в виде веб-приложения и рассматривается как система поддержки принятия решений, результаты которой следует сочетать с авторской экспертизой. Перспективы включают дообучение мультиязычных моделей и изучение поведения модели при расширении датасета на новые предметные области.

Промпт v0, EN:

**Claude Haiku 5.5 — 222 слов**

Large language models (LLMs) are increasingly used in academic work, but they can confidently produce hallucinations, including context inconsistency, where a summary diverges from its source text. This pilot study tests whether prompt engineering can reduce context inconsistency hallucinations in zero-shot summarisation of scientific text. Abstracts from eight open-access yeast biotechnology papers were summarised by six instruction-tuned LLMs under seven prompt conditions: a baseline prompt, two prompt engineering levels of increasing instruction complexity (PE-1, PE-2), two context repetition conditions that repeat one or two key sentences (CR-K1, CR-K2), and two random addition controls (RA-K1, RA-K2). The 336 summaries were evaluated against the abstract, and the repetition conditions also against the key sentences, using ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR and cosine similarity. Significance was assessed with the Wilcoxon signed-rank test with Bonferroni-Holm correction and with BCa bootstrap confidence intervals. Context repetition and random addition significantly improved lexical alignment with the abstract, and random addition also improved alignment with the repeated sentences. Increased instruction complexity did not improve semantic alignment: PE-1 significantly reduced it, and PE-2 had no significant effect. Context repetition improved lexical alignment with the key sentences only for ROUGE-2 at K = 2, so that hypothesis was partially supported. Prompt design can significantly affect zero-shot scientific summarisation, although the small corpus and reliance on automatic metrics without human validation limit generalisation.

**Claude Sonnet 5.5 — 283 слов**

Large language models (LLMs) are increasingly used to summarise scientific literature, but they can produce context inconsistency hallucinations, where summaries are unfaithful to the provided source text. This pilot study investigates whether prompt engineering can mitigate such hallucinations in zero-shot summarisation of scientific abstracts. Eight open-access yeast biotechnology abstracts were summarised by six instruction-tuned LLMs (DeepSeek-R1-Distill-Qwen-32B, Mistral-7B-Instruct-v0.3, Llama-3.3-70B-Instruct, Llama-3.1-8B-Instruct, Qwen2.5-72B-Instruct and Llama-3.1-Nemotron-70B-Instruct-HF) under seven prompt methods, giving 336 summaries. The methods were a minimal baseline prompt, two prompts of increasing instruction complexity (PE-1, PE-2), context repetition of one or two key sentences selected by embedding similarity (CR-K1, CR-K2), and a control that repeated one or two randomly chosen abstract sentences (RA-K1, RA-K2). Alignment between summaries and the reference text was used as a proxy for hallucination and was measured with ROUGE-1, ROUGE-2, ROUGE-L, BERTScore, METEOR and cosine similarity. Differences from the baseline were tested using Wilcoxon signed-rank tests with Bonferroni-Holm correction and BCa bootstrap confidence intervals, and only results significant under both tests were retained. Context repetition significantly improved lexical alignment with the abstract. Random sentence addition improved lexical alignment as well, and by more than context repetition, **so the gain cannot be attributed to the semantic relevance of the repeated content**. Increased instruction complexity did not improve semantic alignment: PE-1 significantly reduced it and PE-2 had no significant effect. Context repetition increased alignment with the repeated key sentences only for K = 2 and only under ROUGE-2. These findings suggest that simple prompt modifications can affect summary alignment, but the small corpus, the use of automatic metrics without human validation and the zero-shot setting limit generalisation, and further work is needed to separate the effects of repetition, prompt length and sentence relevance.

Младшая модель Haiku со строгим промптом единственная допустила неточности. Она выдала экономию времени за результат работы, хотя авторы её не измеряли. Ограничение предметной области датасета отнесла ко всему исследованию. Наибольший прирост приписала одному RA-K2 вместо random addition в целом. Кроме того, в русской аннотации она не уложилась в объём (217 слов при минимуме 230). Старшие модели Sonnet и Opus со строгим промптом ошибок не сделали, но с простым промптом обе дописали собственные выводы (раздел 6). Компактная модель на простом промпте пишет короче и без интерпретаций: в русской аннотации всего 91 слово и нет блока выводов.

## 8. Сравнение авторских и сгенерированных аннотаций

**Статья 1 (RU).** Авторская аннотация — описательная (индикативная). Она перечисляет, что сделано в статье («проанализированы основы аннотирования», «схемографически представлено существо процесса», «кратко описан цифровой инструментарий»), и большая её часть посвящена обзорным разделам о стандартах и цифровых инструментах. Числовых результатов в ней нет. Модели с промптом v1 написали информативную аннотацию (реферат): цель → модель и данные → числа → вывод, а обзор стандартов почти опустили. Поэтому ROUGE-1 здесь не выше 30 %: совпадает мало слов, хотя аннотации верны по фактам. Дополнительно ROUGE занижает морфология: без лемматизации «аннотаций» и «аннотации» — разные слова. Показательно, что в авторской аннотации сказано «для оценки модели использована метрика ROUGE», но значений ROUGE в статье нет — и ни одна модель их не придумала. С простым промптом (v0) модели, наоборот, упоминают ГОСТы и этические риски, то есть ближе к авторской по содержанию, но короче.

**Статья 2 (EN).** Авторская аннотация информативная, построена по той же схеме, что и наш промпт, поэтому ROUGE-1 выше: 52–60 %. Модели полнее автора. Они перечисляют исход всех четырёх гипотез и упоминают, что PE-1 *ухудшил* семантическое совпадение. В авторской аннотации об этом отрицательном результате не сказано.

**ROUGE и правдивость.** Второй по величине ROUGE-1 среди всех десяти аннотаций к английской статье (59,8 %) получила аннотация Claude Sonnet с простым промптом — та самая, в которой есть галлюцинация. Она обошла все аннотации без ошибок, кроме ChatGPT v1. Это подтверждает тезис из презентации: ROUGE измеряет похожесть на эталон, но не проверяет правдивость, поэтому ручная проверка фактов обязательна.

## 9. Сводная таблица

| Промпт | Статья | Модель | ROUGE-1, % | ROUGE-L, % | Галлюц., шт. | Неточн., шт. | Структура, из 4 | Объём, слов |
|---|---|---|---|---|---|---|---|---|
| v1 | RU | DeepSeek | 28.8 | 14.6 | 0 | 0 | 4 | 238 |
| v1 | RU | ChatGPT | 29.7 | 11.2 | 0 | 0 | 4 | 274 |
| v1 | RU | Claude Opus 5.5 | 26.9 | 12.9 | 0 | 0 | 4 | 275 |
| v1 | RU | Claude Sonnet 5.5 | 25.9 | 10.4 | 0 | 0 | 4 | 263 |
| v1 | RU | Claude Haiku 5.5 | 24.2 | 13.9 | 0 | **2** | 4 | **217** |
| v1 | EN | DeepSeek | 52.3 | 28.6 | 0 | 0 | 4 | 218 |
| v1 | EN | ChatGPT | 60.1 | 34.8 | 0 | 0 | 4 | **251** |
| v1 | EN | Claude Opus 5.5 | 59.0 | 32.7 | 0 | 0 | 4 | 234 |
| v1 | EN | Claude Sonnet 5.5 | 56.2 | 31.7 | 0 | 0 | 4 | 234 |
| v1 | EN | Claude Haiku 5.5 | 54.6 | 33.0 | 0 | **1** | 4 | 216 |
| v0 | RU | DeepSeek | 28.8 | 12.6 | 0 | 0 | 4 | 163 |
| v0 | RU | ChatGPT | 27.7 | 14.1 | 0 | 0 | 4 | 148 |
| v0 | RU | Claude Opus 5.5 | 24.8 | 13.8 | 0 | 0 | 4 | 141 |
| v0 | RU | Claude Sonnet 5.5 | 25.2 | 12.4 | 0 | 0 | 4 | 173 |
| v0 | RU | Claude Haiku 5.5 | 20.3 | 11.8 | 0 | 0 | 3 | 91 |
| v0 | EN | DeepSeek | 58.5 | 38.0 | 0 | 0 | 4 | 305 |
| v0 | EN | ChatGPT | 54.8 | 33.9 | 0 | 0 | 4 | 268 |
| v0 | EN | Claude Opus 5.5 | 54.4 | 30.5 | **1** | **1** | 4 | 314 |
| v0 | EN | Claude Sonnet 5.5 | 59.8 | 32.4 | **1** | 0 | 4 | 283 |

| | | | | | | | | |
|---|---|---|---|---|---|---|---|---|
| v0 | EN | Claude Haiku 5.5 | 59.7 | 37.0 | 0 | 0 | 4 | 222 |

Оранжевым в столбце «Объём» — нарушение требования промпта v1 (RU 230–300, EN 200–250 слов).

## 10. Выводы

1. Со строгим промптом (v1) ни одна из пяти моделей не выдумала фактов ни в русской, ни в английской статье. Числа и названия методов перенесены дословно. Ошибки v1 — только неточности у компактной модели Claude Haiku и мелкие нарушения объёма: у Haiku в русской аннотации, у ChatGPT в английской (на одно слово).
2. С простым промптом (v0) галлюцинации появились у Claude Sonnet и Claude Opus: они дописывают правдоподобные собственные выводы. DeepSeek и ChatGPT фактов не выдумали, но нарушали формат: вводные фразы, подзаголовки, придуманные ключевые слова. Запреты в промпте v1 («используй только факты из статьи», «чего нет в тексте, не добавляй», «выведи только аннотацию») устранили оба типа проблем. Это согласуется с результатом статьи 2: формулировка промпта значимо влияет на верность пересказа.
3. ROUGE зависит прежде всего от типа авторской аннотации. Для описательной русской аннотации он низкий у всех моделей (20–30 %), для информативной английской — высокий (52–60 %). Аннотация с галлюцинацией может иметь ROUGE выше, чем аннотации без ошибок. Поэтому решающей метрикой для выбора модели была точность фактов, а ROUGE и соблюдение формата учитывались при равенстве.
4. **Лучшая модель — ChatGPT.** Ни одной галлюцинации и неточности ни с одним промптом, наибольший ROUGE-1 в серии v1 на обеих статьях (29,7 % и 60,1 %). Единственный недочёт — лишнее слово сверх лимита в английской аннотации. **DeepSeek** также без ошибок по фактам, но у него самый низкий ROUGE-1 на английской статье в серии v1 (52,3 %), а на простом промпте он свободнее всех обращается с форматом. **Claude Opus 5.5** со строгим промптом безупречен, но на простом промпте добавил собственный вывод.
5. Ни одна модель не заметила внутренних противоречий статей: в статье 2 гипотеза H4 одновременно «частично подтверждена» и «не подтверждена», в статье 1 корпус назван то 825 статьями (810 пар), то «тысячей публикаций». Модели аккуратно пересказывают, но не рецензируют текст.

**Ограничения.** Каждая комбинация запущена один раз, поэтому разброс между повторами не оценён. Точная версия моделей в веб-чатах DeepSeek и ChatGPT

интерфейсом не указывается. Проверка фактов выполнена вручную одной командой. ROUGE считается без лемматизации.

## 11. Распределение работы в команде

| Участник | Модель (прогоны, ROUGE, проверка фактов по обеим статьям, v1 и v0) | Общая часть работы |
|---|---|---|
| Дубровин Т. Г. | Claude Opus 5.5 и доп. эксперимент Haiku / Sonnet | Подбор статей, подготовка текстов и эталонов (скрипт `prepare_texts.py`), разделы 3.1–3.2 отчёта |
| Крехов Д. А. | ChatGPT | Составление промптов v1 и v0, реализация подсчёта ROUGE (`rouge.py`), разделы 3.3–3.5 и 6 |
| Цибиров М. А. | DeepSeek | Сводная таблица, сравнение с авторскими аннотациями, выводы, сборка отчёта (разделы 7–10) |

Все материалы (тексты статей, промпты, исходные и очищенные ответы моделей, скрипты, протокол проверки фактов) приложены в папке работы.