Причины искажения контента: анализ и классификация галлюцинаций в больших языковых моделях GPT

М. Ш. Маджумдер, Д. Д. Бегунова

Московский государственный лингвистический университет, Москва, Россия

Аннотация. В статье исследуются галлюцинации, возникающие в двух версиях большой языковой модели GPT – GPT-3.5-turbo и GPT-4. Основная цель работы заключается в изучении возможных источников и классификации галлюцинаций, а также в разработке стратегий для их решения. Выявлены проблемы, которые могут привести к генерации контента, не соответствующего фактологическим данным и вводящего пользователей в заблуждение. Результаты исследования имеют практическую значимость для разработчиков и пользователей языковых моделей, ввиду предоставленных подходов, повышающих качество и достоверность генерируемого контента.

Ключевые слова: галлюцинации ИИ-систем, GPT, большие языковые модели, искусственный интеллект.

DOI 10.14357/20718594240303 **EDN** KNHVPP

Введение

Искусственный интеллект (ИИ) в последние годы проделал впечатляющий путь развития, открывая перед нами новые горизонты и предлагая неограниченные перспективы. Тем не менее, возникают новые вызовы, среди которых особое внимание привлекает проблема галлюцинаций в ИИ. Галлюцинации – это явление, обычно ассоциируемое с мозговой деятельностью и психическим состоянием. Однако в последние годы этот термин стал использоваться и в контексте ИИ [1, с.1] при получении от моделей для генерации текста неправдивой информации.

В статье мы сосредоточимся на исследовании галлюцинаций, которые возникают в двух наиболее используемых версиях языковой модели GPT (Generative Pretrained Transformer – генеративный предобученный трансформер) – GPT-3.5-turbo и GPT-4 [2]. Выбор данных моделей обусловлен тем, что проблемы, с которыми сталкиваются даже самые передовые разработки, являются актуальными и для менее масштабных моделей. GPT – это языковая модель ИИ, разработанная компанией OpenAI на основе архитектуры Transformer. Архитектура была представлена в 2017 году в статье «Attention is All You Need» [3] и с тех пор стала одной из наиболее влиятельных и успешных моделей в области NLP (Natural Language Processing – обработка естественного языка), включающей машинный перевод, генерацию текста, вопросно-ответные системы и др.

Основным преимуществом трансформеров является их способность эффективно моделировать долгосрочные зависимости в тексте с помощью механизма самовнимания (selfattention), что не могли делать модели-предшественники, так как использовавшиеся рекуррентные нейронные сети имели проблемы затухающего или взрывающегося градиента [3, с.7]. Механизм самовнимания позволяет модели обращать внимание на различные части входного текста и параллельно обрабатывать информацию при генерации ответов, что способствует более точному пониманию контекста и семантики предложений, делая генерируемый текст более похожим на текст, созданный человеком.

Работа направлена на изучение возможных источников галлюцинаций в этих моделях,

разработку классификации различных типов галлюцинаций и рассмотрение гипотез, объясняющих их происхождение. Кроме того будут рассмотрены потенциальные стратегии и подходы для решения этой проблемы, которые могут быть полезны не только для ChatGPT, но и для других генеративных моделей. Важно отметить, что галлюцинации могут иметь серьезные последствия, особенно в контексте автоматической генерации контента для массового распространения, ведущего к снижению общего качества открытой информации. Разработчики и пользователи ИИ должны быть осведомлены о таких рисках и предпринимать меры для их минимизации. Рассмотренные проблемы и возможные пути их решения могут служить для усовершенствования LLM (англ. Large Language Model – большая языковая модель, основанная на глубоком обучении с большим количеством параметров для моделирования языка и выполнения различных задач обработки текста).

1. Определение и классификация галлюцинаций

В моделях ИИ ключевым компонентом обучения и оптимизации является функция потерь (loss function). Она измеряет разницу между предсказанными значениями модели и истинными значениями целевой переменной в обучающем наборе данных. Цель функции потерь состоит в том, чтобы минимизировать эту разницу и настроить модель на более точные предсказания. В LLM функция потерь помогает оценивать качество текста и приводит модель к генерации более «осмысленных» ответов. Недостаточная точность в выданных ответах воспринимается как «потеря», так как контент, не соответствующий исходным данным или лишенный смысла, не предоставляет полезной информации для пользователя.

В контексте генеративных моделей ИИ подобные «потери» или аномалии называют галлюцинациями. В настоящее время отсутствует достаточное, точное и закрепившееся определение для этого термина. Обычно, галлюцинациями в LLM предлагается называть сгенерированный контент, который не соответствует исходным данным или является лишенным смысла из-за ошибок в кодировании и декодировании между текстом и его векторными представлениями [4, с.1]. Галлюцинации также могут смешиваться с достоверной информацией, что усложняет их идентификацию. Это может привести к потенциально ложному восприятию информации и ввести в заблуждение пользователей. Возникновение галлюцинаций представляет особую проблему в сферах, требующих многокомпонентного логического рассуждения, так как даже одна логическая ошибка может нарушить всю последовательность решения. Обнаружение и устранение галлюцинаций играют важную роль в улучшении возможностей логического мышления ИИ [5, с.1]. Так можно сказать, что *галлюцинации в ИИ* – это не соответствующий реальности контент, который возникает в процессе генерации ответов на запросы пользователей из-за недостаточно корректного тренировочного массива, создания ошибочных связей в статистических данных, настройки гиперпараметров модели и неэффективной токенизации.

Галлюцинации могут быть разделены на открытые и закрытые [4, с.46]. В закрытых галлюцинациях модель использует только информацию из заданного контекста, но добавляет дополнительную информацию, которая не была в нем. Например, при аннотировании статьи модель может включать в нее информацию, которая отсутствовала в оригинальном тексте. Открытые галлюцинации, в свою очередь, проявляются, когда модель предоставляет ложную информацию без привязки к конкретному контексту. Галлюцинации связаны с рядом проблемных моментов, которые мы предлагаем классифицировать в следующие категории.

1. Межъязыковые галлюцинации:

- Перевод фактологической информации (названия, авторы, даты, пр.), т. е. трудности в переводе информации, когда она требует локализации (например, когда названия одного романа в оригинале и в переводной версии не в точности повторяют друг друга). Пример: ошибки в определении имени автора романа «Серебряные коньки» и причисление его к произведениям русской литературы, так как в оригинале он имеет более широкое название «Hans Brinker, or the Silver Skates» и написан Мэри Мэйпс Додж.
- Отказ в межъязыковом поиске, т. е. неэффективный поиск векторных представлений лексических единиц на определенном языке при выполнении запросов на других языках. Это проявляется, когда на идентичные запросы,

заданные, например, на русском и английском языках, ChatGPT в первом случае генерирует галлюцинацию, а во втором – предоставляет достоверную информацию. Примером является некорректное описание сюжета романа «Крысы» и определение его автора на русском языке, но безошибочный ответ на английском и испанском языках.

2. Семантические галлюцинации:

- «Ассоциации», т. е. некорректные предположения, основанные на интерпретации имеющихся данных. Пример: на запрос «Почему «бычок вздыхает на ходу»?» ответ о заболевании легких или усталости.
- Алогичность рассуждений, т. е. отсутствие эффективного алгоритма для последовательного решения математических и логических задач. Примером являются ошибочные ответы на любые математические или логические задачи: «Один кролик по дороге к реке увидел 6 слонов. Каждый слон видел 2 обезьян, идущих к реке. Каждая обезьяна держит в руках по одной черепахе. Сколько животных направляются к реке?» или «Ты на гонке, ты обогнал второго, какое место ты занял?».
- Фактологические аберрации, т. е. искажение фактов. Например, ответ «10 километров» вместо ~26.5 км на вопрос «Какую протяженность имела первая в России железная дорога?».
- «Фантасмагории» (например, наравне с устоявшимся значением этот термин может описать нереалистичные и порой абсурдные ответы ИИ), т. е. генерация абсолютно выдуманного и логически не обоснованного контента. Фантасмагории описывают нереалистичные и порой абсурдные ответы ИИ, когда модель генерирует полностью выдуманный и логически необоснованный контент. Например, на вопрос «Какого цвета могут быть дипломы об образовании в России?» ответ «Желтого у юристов, черного у филологов и лингвистов, а зеленого у математиков» является фантасмагорией, так как такие цвета дипломов не существуют и ответ не имеет под собой реальной основы. В отличие от этого, *ассоциативные* галлюцинации возникают, когда ИИ пытается установить связи между концепциями, опираясь на стереотипные или логически неправильные ассоциации. Например, ответ «Черный диплом выдается шахтерам, белый - врачам» относится к ассоциативным галлюцинациям, так как ИИ ассоциирует черный цвет с углем и шахтерами, а белый цвет с врачебным халатом и больницей. В этом случае связь между цветом диплома и профессией является ошибочной, но имеет под собой попытку логического обоснования на основе стереотипов.

3. Контекстуальные галлюцинации: замена пользовательского запроса вымышленным заданием, т. е. полное или частичное невыполнение первичных требований пользователя. Например, ответ ИИ в виде списка при четкой формулировке пользователя «Напиши свой ответ без списков, сплошным текстом», или ошибочное количество пунктов при запросе «Напиши 20 идей подарков на день рождения».

Также важно отметить, что ответ ИИ может одновременно относиться к нескольким типам галлюцинаций. Ярким примером является запрос «Кто написал роман «Принцесса Клевская»?» и следующий ответ: «Автором является Александр Сергеевич Пушкин». Такая галлюцинация относится к межъязыковой (отказ в межъязыковом поиске, так как при получении этого вопроса на английском языке ответ ИИ становится корректным), а также к семантической ассоциации (запрос о классическом романе на русском языке с упоминанием принцессы приводит ИИ к перечислению русских классиков). Другие примеры галлюцинаций на этот запрос включают предполагаемого автора по имени «Елена Ганжа», что не поддается логике ассоциирования и является абсурдным. Такой ответ относится к фантасмагориям.

2. Методология

В настоящее время изучение и понимание галлюцинаций ИИ находятся на начальной стадии, однако исследователи и специалисты предлагают некоторые гипотезы, объясняющие это явление [1, 4, 6]. Глубокое изучение данных гипотез приближает к развитию более полного понимания причин и механизмов галлюцинаций ИИ и последующему созданию более надежного и безопасного ИИ. В социальных медиа существуют разные мнения о причинах галлюцинаций, включая увеличение их числа в целях коммерческой выгоды или в зависимости от географического положения, а также наличие у ИИ разума. Также некоторые ученые предполагают, что работа OpenAI над повышением безопасности моделей негативно влияет на достоверность их ответов вследствие внедрения обновлений [7, с. 1]. Однако мы сосредоточимся

на других гипотезах, которые предлагают теоретические рамки и подходы к объяснению феномена галлюцинаций и представляют собой отправную точку для будущих исследований. В ходе проверки гипотез и выявления проблемных моментов в работе моделей был использован метод обучения с нулевым выстрелом (zeroshot learning – это парадигма обучения, в которой модель начинает обобщать и выполнять задачи без предварительной подготовки или тренировочных примеров). Вопросы о зарубежной культуре были заданы чату на английском языке для повышения достоверности ответов. Моделям не предоставлялась никакая дополнительная информация, инструкции или подсказки для решения конкретных задач. Вместо этого, модели были поставлены перед задачей ответить на вопросы на основе своих существующих знаний и умений.

3. Результаты исследования гипотез возникновения галлюцинаций

3.1.Загруженность сервера

Мы предположили, что на появление галлюцинаций в моделях ИИ может влиять интенсивность использования серверов. С целью подтверждения или опровержения этой гипотезы мы провели эксперимент, основанный на выявленных проблемных моментах, таких как алогичность рассуждений, перевод фактологической информации и др. Для проведения данного эксперимента был составлен опросник, содержащий 41 вопрос. Задания были направлены на оценку точности и достоверности ответов моделей ИИ.

Эксперимент проводился в течение двух дней, включая один будний и один выходной день, по московскому времени (UTC +3), с целью учесть возможные различия в загруженности сервера в рабочее и нерабочее время. Согласно данным OpenAI Status [8], в дни проведения исследования (25.06.2023 и 28.06.2023) не было зафиксировано технических неполадок.

Для эксперимента использовались два аккаунта: один с версией ChatGPT-3.5-turbo, второй – с ChatGPT-3.5-turbo и ChatGPT-4. Вопросы задавались каждые два часа в течение экспериментальных дней. Ответы записывались и оценивались на основе предварительно определенных критериев: точность и достоверность, полнота, релевантность.

Анализ полученных данных показал, что в разное время суток достоверность ответов LLM действительно может изменяться на ±0,15% (Рис. 1). Определенные временные промежутки демонстрировали более высокую точность ответов, что может быть связано с более низкой загруженностью сервера. Согласно предположению, низкая загруженность сервера может увеличивать вероятность того, что чат с большей точностью находит правильные ассоциации в тренировочном наборе данных и предлагает корректные решения.

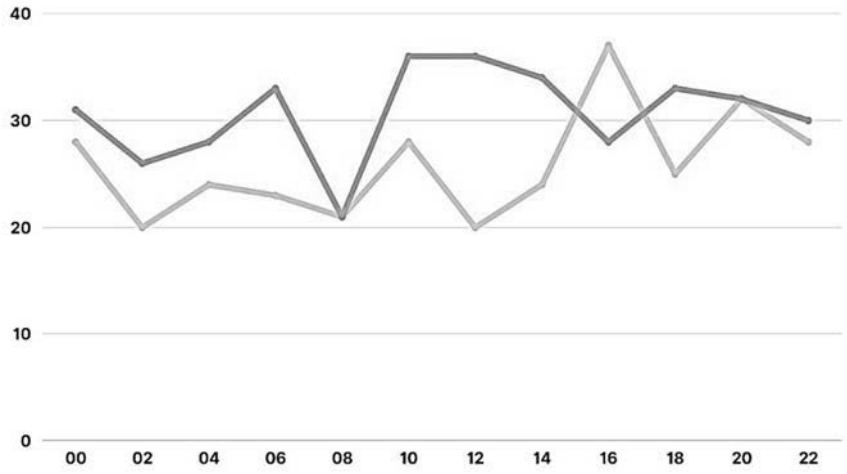


Рис. 1. Процент успешно выполненных заданий (ось *y)* в зависимости от времени суток (ось *x)*

Серая кривая отражает результаты за 25.06.2023 (выходной), темная - за 28.06.2023 (будний)

Исходя из значений среднеквадратичных ошибок (16,49 в первый экспериментальный день и 15,42 - во второй), можно сделать вывод, что данные демонстрируют некоторую изменчивость, разброс в точности ответов между экспериментальными днями. Однако на основании только этих значений стандартного отклонения, не удается выявить четкую закономерность. Кроме того, общая разница в ответах между экспериментальными днями составила всего 0,05%. Это говорит о том, что выбор определенного времени для отправки запросов не обеспечивает значительное улучшение достоверности ответов на проблемные вопросы. В среднем, точность ответов на проблемные для чата вопросы может варьироваться от 0,20 до 0,35%, независимо от времени отправки запросов. Это означает, что загруженность сервера, хоть и оказывает влияние на достоверность ответов, но не является единственной или основной причиной галлюцинаций ИИ.

3.2. Архитектура модели

Обучающий набор данных. На данный момент убедительность LLM обусловлена впечатляющим объемом тренировочных данных. Благодаря этому GPT обладает развитым языковым навыком и «чувством» языка, что позволяет убедительно генерировать контент. Модель имеет огромное количество весовых коэффициентов (175 миллиардов параметров у GPT-3 [9, с.9]) и знаний из различных областей. Она способна обобщать информацию, находить закономерности и генерировать тексты на основе своего обучения.

Тем не менее галлюцинации могут возникать из-за недостатка знаний, вызванного недообученностью, невозможностью актуализации знаний или низким качеством выбранных для обучения данных. Общий объем обучающих данных модели GPT-3 составляет порядка 500 миллиардов токенов [9, с.9]. Эти данные получены из нескольких ключевых источников – CommonCrawl, Books1 и Books2, WebText2 и Wikipedia. Они служат тренировочным набором для ChatGPT и обеспечивают модель «знаниями» о мире. Для улучшения качества данных были применены различные техники. В частности, для CommonCrawl был разработан автоматический метод фильтрации на основе логистической регрессии с использованием функций из стандартного токенизатора Spark и HashingTF для удаления низкокачественных документов [9, с.43].

Однако обучающие данные ChatGPT все равно имеют ограничения: они не охватывают полный спектр информации о мире, а также ограничены определенными тематиками, что приводит к недостатку разнообразия в генерируемых моделью ответах. Кроме того, данные, используемые для обучения ChatGPT, являются статичными и не обновляются с течением времени, что может сказываться на актуальности информации в ответах модели на текущие события или изменения. Обучение GPT-3 было завершено в сентябре 2021 года [4, с. 10], и ее знания ограничены данным временным периодом. Так, «незнание» модели может проявляться в форме ссылки на cut-off (cut-off – точка во времени, после которой модель ИИ не имеет доступа к информации), прямого ответа об отсутствии знаний или предоставления неверной информации по отношению к действительности.

Согласно данным OpenAI модели GPT-3 и GPT-4 проявляют низкую результативность в выполнении таких профессиональных тестов, как AP English Language and Composition[1], AP English Literature and Composition[2], AP Calculus BC[3] и AMC 10[4] [5, с.5]. К недостаточной способности моделей решать задачи, требующие высокого уровня знаний и логического рассуждения, может привести отсутствие подходящих примеров в обучающих данных. В случае AP Calculus BC показатели указывают на то, что модели не обладают способностью систематически и последовательно решать логические и математические задачи.

Ученые также заметили, что на достоверность ответов влияет не только набор обучающих данных, но и Reinforcement Learning from Human Feedback (RLHF – метод обучения, при котором люди предоставляют обратную связь для помощи ИИ в улучшении своих навыков). Исследователи провели эксперимент, который

[1] Экзамен, который проверяет навыки учащихся в чтении, письме и критическом мышлении.

[2] Экзамен, который проверяет навыки учащихся в анализе и интерпретации литературы.

[3] Экзамен по исчислению, который проверяет навыки учащихся в дифференциальном и интегральном исчислении.

[4] Олимпиада по математике, которая проверяет навыки учащихся в алгебре, геометрии и решении проблем.

показал влияние продолжительного взаимодействия с пользователями на снижения достоверности ответов на те вопросы, информация по которым изначально была в тренировочном массиве данных [10, с.530]. Примеры галлюцинаций:

1. Почему «Наша Таня» громко плачет? – *«Наша Таня громко плачет» – это начало знаменитого стихотворения «Наши» Владимира Маяковского. В этом стихотворении Маяковский описывает общественное неравенство, угнетение и страдание рабочего класса, выражая свое сочувствие и негодование по отношению к этим проблемам* («Наша Таня громко плачет...» – это стихотворение Агнии Барто, входящее в сборник детских стихов под названием «Игрушки», изданный в 1936 году. Данное стихотворение является наиболее известным и узнаваемым в русской поэзии и повествует о том, как Таня плачет из-за того, что уронила мяч в реку).

2. О чем книга В. Паперного «Мос-Анджелес»? – *Вероятно, эта книга была выпущена после моего последнего обновления в сентябре 2021 года. Мои данные обновляются периодически, и я не владею информацией о событиях, произошедших после этой даты* (книга «Мос-Анджелес» Владимира Паперного, выпущена в 2004 году и представляет собой многогранное произведение, которое охватывает различные аспекты культуры и искусства, а также отражает жизненный путь и опыт автора).

3. День, наступающий через два дня после позапрошлого, суббота. Какой день сегодня? – *Если суббота наступает через два дня после позапрошлого дня, то сегодня четверг. Позапрошлый день был вторник, следующий день – среда, а через два дня после среды наступает суббота* (Если суббота наступает через два дня после позапрошлого, то суббота наступит завтра. Таким образом, сегодня должен быть предшествующий день, то есть пятница).

Одним из способов решения этих проблем является доступ к Интернету или внешним источникам данных. Это может быть реализовано с помощью функциональности веб-поиска, например, в случае ChatGPT – Web-browsing в Bing, который позволяет модели получать актуальную информацию и дополнять свои знания в режиме реального времени. Кроме того, возможны и другие методы расширения базы знаний модели. Например, использование дополнительных плагинов, которые позволяют модели получать доступ к специфическим базам данных или наборам знаний, расширяющим ее способности в определенных областях.

Тем не менее можно сделать вывод, что галлюцинации в LLM не всегда вызваны именно недостатком знаний или неправильными данными. Нередко даже при наличии соответствующих знаний у модели, она может проявлять непоследовательный и несистематический подход к решению конкретной задачи.

Ассоциации. Аномалии, связанные с галлюцинациями, могут также возникать из-за кластеризации, то есть из-за процесса машинного обучения по организации данных в подгруппы со схожими атрибутами или элементами. Несмотря на огромный объем текстовых данных, на котором обучается модель GPT, она может столкнуться с вопросами, по которым не имеет предварительных знаний и ответов. В таких случаях ИИ использует имеющиеся данные для поиска связей, делает предположения и строит ассоциации. Однако если кластеризация данных выполнена некорректно модель может сделать ошибочные выводы и связать неподходящие или неверные элементы с поставленным вопросом. Такие закономерности могут быть просто случайными или ошибочными интерпретациями имеющихся статистических данных, и вместо того, чтобы признать отсутствие информации или недостаток знаний, модель генерирует ответ, основанный на неверном ассоциировании, что приводит к появлению галлюцинаций.

Примеры неправильного ассоциирования:

1. Кто является главным героем книги Франсуазы Саган «Волшебные облака»? Чат не обладает точной информацией о конкретной книге или ее главном персонаже. В результате модель предлагает ответы, основываясь на своих ассоциациях и статистических связях между словами. В данном случае ИИ предлагает имена, связанные с иными произведениями Франсуазы Саган, с французской культурой или литературой (Полин, Джули, Сисиль, Лу, Клод), однако, эти предположения не соответствуют фактической ситуации.

2. О чем фильм «Кавказская пленница»? Модель ИИ, имея информацию о его полном названии, может сразу обозначить имя главного персонажа и предположить, что сюжет основан на похищении девушки в районе Кавказа. Мы предполагаем, что именно из-за ошибок

в алгоритме кластеризации чат утверждает, что фильм снят на основе произведений известных русских писателей, таких как А.С. Грибоедов, А.С. Пушкин или М.Ю. Лермонтов. Жизни этих писателей, действительно, были связаны с Кавказом, но фильм «Кавказская пленница» не имеет никакого отношения к классикам русской литературы, поэтому ассоциации, найденные чатом, не являются отражением реальных фактов. Эта ошибка может быть вызвана неправильным сопоставлением различных факторов, таких как общие темы (Кавказ) и известные личности (русские писатели).

Однако в некоторых случаях предположения, построенные моделью ИИ на ассоциациях, могут быть верными. Например, если задать вопрос: «Кому А. С. Пушкин посвятил строки “Товарищ, верь: взойдет она, Звезда пленительного счастья...”?», чат пытается ассоциировать слово «товарищ» и автора «А. С. Пушкин» и приходит к выводу, что ответ на данный вопрос —имя друга А. С. Пушкина. Не имея точного ответа, он с разной вероятностью называет следующие варианты: В. А. Жуковский, В. Ф. Одоевский, П. А. Вяземский, П. Я. Чаадаев. Последний предложенный вариант «П. Я. Чаадаев» является верным, в таком случае чат сможет правильно дать и имя адресата, и название стихотворения («К Чаадаеву»). Однако вероятность получения правдивых ответов в результате ассоциирования сильно колеблется в зависимости от вопроса и количества знаний модели в сфере, к которой относится запрос.

Таким образом, GPT может в определенных случаях создать правильные ассоциации, но при недостатке информации надежность таких предсказаний низкая из-за ограниченности статистических связей и контекста, на основе которых модель работает. Для предотвращения таких ошибок важно проводить тщательный анализ и предварительную обработку данных перед обучением. Дополнительно внедрение методов оценки качества кластеризации и анализа выбросов может помочь выявить потенциальные проблемы и улучшить точность ассоциаций, что позволит снизить возможность формирования галлюцинаций.

Кодирование. Галлюцинации в модели могут быть обусловлены особенностями архитектуры, такими как сложная взаимосвязь между различными слоями модели, большое количество весовых коэффициентов или недостаточная структурированность внутренних векторных представлений. Галлюцинации могут возникать в процессе кодирования данных, в декодировании сгенерированных результатов, а также во внутренних слоях моделей глубокого обучения. ChatGPT использует стохастическое сэмплирование (stochastic sampling – процесс случайного выбора элементов из некоторого распределения с учетом их вероятностей) для выбора следующего токена, а также алгоритмы ранжирования для выбора наиболее вероятного или наилучшего продолжения из предложенных моделью альтернатив.

Во время кодирования галлюцинации могут проявляться в неправильном векторном представлении исходных данных. Например, если токенизация или другой метод кодирования некорректно обрабатывает текст, то это может привести к потере или искажению смысла слов или фраз. Это может произойти при использовании недостаточно эффективного или неподходящего токенизатора, который не учитывает особенности языка или контекста.

Модели семейства GPT имеют разное количество токенов, которые они способны запомнить и учесть при генерации ответов. Например, GPT-3 имеет ограничение до 4 000 токенов, что означает, что модель может учитывать только ближайший контекст, а GPT-4 предоставляет возможность работать с 8 000 или даже 32 000 токенов [11]. Это дополнительное количество токенов позволяет модели запоминать и использовать более длинные последовательности текста для лучшего понимания контекста и генерации более «осмысленных» ответов.

Было выявлено, что GPT-3 перестает соблюдать жестко прописанные важные промты раньше, чем GPT-4. Это связано с тем, увеличение объема токенов в GPT-4 позволяет модели обрабатывать более длинные последовательности текста, что снижает вероятность возникновения галлюцинаций из-за нехватки контекста. Например, при аннотировании текста GPT-3 скорее будет учитывать только начало и конец, тогда как GPT-4 равномерно запомнит весь текст, обеспечивая более точные и последовательные ответы.

Методом токенизации для GPT-моделей является Byte-Pair Encoding (BPE - это алгоритм, который основывается на разделении текста на подслова (subwords)) [12]. Преимущество использования BPE в токенизации заключается в

том, что он позволяет модели обрабатывать редкие или сложносоставные слова, которые она ранее не видела, разбивая их на известные подслова. Однако, как и любой метод, BPE не всегда дает идеальные результаты для всех языков и текстов. Некоторые языки, включая русский, имеют свои уникальные особенности и требуют специального подхода к токенизации. На русском языке часто возникает проблема, когда количество токенов превышает количество символов. Логично было бы использовать более эффективный «внешний» токенизатор, однако это не всегда возможно, так как требуется состыковка с эмбеддинговым слоем (embedding layer – слой в нейронных сетях, который преобразует токены в векторные представления, называемые эмбеддингами) модели. Важно отметить, что процедура токенизации имеет прямое влияние на перплексию (erplexity – вычисляемая «степень неопределенности», которую ИИ испытывает при попытке предсказать последовательность токенов; чем ниже значение перплексии, тем более точной является модель) и влияют на понимание входных данных. Поэтому рекомендуется использовать отдельные токенизаторы при обучении LLM, учитывающие особенности конкретного языка, с целью повышения вероятности правильных ответов на этом языке и снижения возможных галлюцинаций. Поскольку каждый язык имеет свои уникальные особенности в структуре слов и предложений, специализированные токенизаторы позволят более точно разбивать текст на токены, соответствующие особенностям конкретного языка. Такой подход способствует улучшению качества обработки текста на естественном языке и повышает точность ответов модели, уменьшая галлюцинации.

Декодирование. В процессе декодирования галлюцинации могут проявиться в неправильной генерации текста. Модель может создавать некорректные или нелогичные фразы, которые не соответствуют ожидаемым результатам или не имеют связи с исходными данными. Это может быть вызвано недостаточной обученностью модели, ограниченным набором данных или неправильной обработкой контекста и семантики во время кодирования. Можно использовать гиперпараметры, такие как температура, presence_penalty и frequency_penalty, top-p, top-k и пр.

Температура в моделях генерации текста регулирует разнообразие ответов – при низкой температуре модель склонна выбирать наиболее вероятные слова, а при высокой - более свободно выбирает из всех возможных слов. Presence_penalty и frequency_penalty – параметры, которые контролируют количество повторяющихся слов или фраз в ответе модели, с помощью которых можно снизить повторы и сделать ответы более разнообразными. Top-p и top-k – это методы контроля наиболее вероятных токенов. При использовании top-p модель выбирает из токенов, суммарная вероятность которых превышает заданный порог, а при использовании top-k модель выбирает только наиболее вероятные токены из заданного числа возможных вариантов. Эти методы позволяют сократить выбор возможных токенов, улучшая точность и снижая риск генерации галлюцинаций.

При декодировании важно отметить, что работа с параметрами, такими как presence_penalty, frequency_penalty, top-p и top-k, доступна только пользователям, которые используют API, таким как разработчики или интеграторы плагинов. Обычным пользователям доступ к таким параметрам не предоставляется. Это означает, что эти функции доступны лишь для тех, кто работает с программным интерфейсом приложения или разрабатывает дополнительные инструменты для модели.

Тем не менее, не всегда эти методы позволяют полностью избежать галлюцинаций. Их основной целью является снижение вероятности получения неправильного ответа, но для достижения полноценной «логической цепочки» этих параметров может оказаться недостаточно. В своих исследованиях разработчики OpenAI предлагают новую стратегию [5], которая заключается в обучении моделей ИИ вознаграждать себя за каждый правильный шаг рассуждений, а не только за окончательный вывод. Такой подход стимулирует модель следовать логической цепочке мыслей, аналогичной человеческой, и способствует более эффективному обнаружению и устранению галлюцинаций. Другой подход заключается в улучшении калибровки модели, чтобы она могла указывать свою неуверенность в выводах и, при необходимости, воздерживаться от предоставления ответа.

Заключение

Решение для борьбы с галлюцинациями в моделях генерации текста включает комбинацию нескольких подходов: с открытыми галлюцинациями можно предоставлять модели доступ к внешним источникам информации (например, путем использования поисковых систем или плагинов) а для закрытых - применять дополнительные проверки с помощью уточняющих вопросов. Важным аспектом является улучшение качества данных путем использования более разнообразных и проверенных источников, а также обновление и дополнение существующих данных. Помимо этого, разработка усовершенствованных архитектур моделей с улучшенными механизмами внимания и памяти и контролем генерации способствует созданию более точных и логичных ответов. Важными аспектами являются обратная связь и итеративное обучение моделей, а также присутствие человеческой модерации – размеченные данные могут использоваться в качестве массива для дообучения или донастройки модели, так как изучение правильных ответов и подстраивание под них помогает улучшить качество генерируемых ответов и снизить вероятность галлюцинаций. Комплексный подход, включающий все эти методы, способствует снижению галлюцинаций и повышению качества генерации текста моделями ИИ.

Сегодня галлюцинации становятся одной из ключевых проблем, которая не позволяет ИИ достичь своего полного потенциала. Важность решения проблемы галлюцинаций связана с негативными последствиями, которые они могут вызвать, например, привести к распространению дезинформации, наносящей ущерб как индивидуальным пользователям, так и обществу в целом. Пользователи могут потерять доверие к ИИ-системам, что скажется на снижении уровня их применения и ограничит потенциал автоматизации и оптимизации различных процессов. Однако вместо того чтобы рассматривать галлюцинации как неизбежную ошибку или негативное следствие, мы можем взглянуть на них как на возможность для дальнейшего развития и совершенствования языковых моделей. Исправление и устранение галлюцинаций – один из шагов к созданию безопасного общего ИИ.

Литература

1. Maynez J., Narayan Sh., Bohnet B., McDonald R. On Faithfulness and Factuality in Abstractive Summarization // arXiv eprints. 2020. 14 с. URL: https://arxiv.org/pdf/2005.00661.pdf (accessed 06.07.2023).
2. Introducing ChatGPT // OpenAI. URL: https://openai.com/blog/chatgpt (accessed 06.07.2023).
3. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A., Kaiser L., Polosukhin L. Attention Is All You Need // arXiv e-prints. 2017. 15 с. URL: https://arxiv.org/pdf/1706.03762.pdf (accessed 06.07.2023).
4. GPT-4 Technical Report / OpenAI // arXiv e-prints. 2023. 100 с. URL: https://arxiv.org/pdf/2303.08774.pdf (accessed 06.07.2023).
5. Lightman H., Kosaraju V., Burda Y., Edwards H., Baker B., Lee T., Leike J., Schulman J., Sutskever I., Cobbe K. Let's Verify Step by Step // arXiv e-prints. 2023. 29 с. URL: https://arxiv.org/pdf/2305.20050.pdf (accessed 06.07.2023).
6. Peng K., Ding L., Zhong Q., Shen L., Liu X., Zhang M., Ouyang Yu., Tao D. Towards Making the Most of ChatGPT for Machine Translation // Cornell University. 2023. URL: https://arxiv.org/abs/2303.13780 (accessed 10.07.2023).
7. Chen L., Zaharia M., Zou J. How Is ChatGPT's Behavior Changing over Time? // arXiv eprints. 2023. 8 с. URL: https://arxiv.org/pdf/2307.09009.pdf (accessed 29.07.2023).
8. All Systems Operational // OpenAI. URL: https://status.openai.com (accessed 06.07.2023).
9. Brown T. B., Mann B., Ryder N., Subbiah M., Kaplan J., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A., Agarwal S., Herbert-Voss A., Krueger G., Henighan T., Child R., Ramesh A., Ziegler D.M., Wu J., Winter C., Hesse C., Chen M., Sigler E., Litwin M., Gray S., Chess B., Clark J., Berner C., McCandlish S., Radford A., Sutskever I., Amodei D. Language Models are Few-Shot Learners // arXiv e-prints. 2020. URL: https://arxiv.org/pdf/2005.14165.pdf (accessed 06.07.2023).
10. Razzhigaev A., Salnikov M., Malykh V., Braslavski P., Panchenko A. A System for Answering Simple Questions in Multiple Languages // Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. 2023. С. 524-537. URL: https://aclanthology.org/2023.acl-demo.51/ (accessed 29.07.2023).
11. Models // OpenAI API. URL: https://platform.openai.com/docs/models/gpt-3-5 (accessed 06.07.2023).
12. OpenAI Platform. URL: https://platform.openai.com/tokenizer (accessed 06.07.2023).

Маджумдер Мадина Шамсуловна. Студентка кафедры информационно-аналитической деятельности, Московский государственный лингвистический университет. Области исследований: анализ данных, искусственный интеллект, большие языковые модели, обработка естественного языка. E-mail: mmadzhumder@gmail.com (ответственный за переписку).

Бегунова Диана Дмитриевна. Студентка кафедры информационно-аналитической деятельности, Московский государственный лингвистический университет. Области исследований: анализ данных, искусственный интеллект, большие языковые модели, обработка естественного языка. E-mail: dbegunova01@gmail.com.

Causes of Content Distortion: Analysis and Classification of Hallucinations in Large GPT Language Models

M. Sh. Madzhumder, D. D. Begunova

Moscow State Linguistic University, Moscow, Russia

Abstract. The article examines hallucinations produced by two versions of the GPT large language model – GPT-3.5-turbo and GPT-4. The primary aim of the study is to investigate the possible origins and classification of hallucinations as well as to develop strategies to address them. The work reveals the existing challenges that can lead to the generation of content that doesn't correspond to the factual data and misleads users. Detection and elimination of hallucinations play an important role in the development of artificial intelligence by improving natural language processing capabilities. The results of the study have practical relevance for developers and users of language models, due to the provided approaches that improve the quality and reliability of the generated content.
Keywords: AI system hallucinations, GPT, large language models, artificial intelligence.

DOI 10.14357/20718594240303 **EDN** KNHVPP

References

1. Maynez J., Narayan Sh., Bohnet B., McDonald R. On Faithfulness and Factuality in Abstractive Summarization // arXiv eprints. 2020. 14 c. URL: https://arxiv.org/pdf/2005.00661.pdf (accessed 06.07.2023).
2. Introducing ChatGPT // OpenAI. URL: https://openai.com/blog/chatgpt (accessed 06.07.2023).
3. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A., Kaiser L., Polosukhin L. Attention Is All You Need // arXiv e-prints. 2017. 15 c. URL: https://arxiv.org/pdf/1706.03762.pdf (accessed 06.07.2023).
4. GPT-4 Technical Report / OpenAI // arXiv e-prints. 2023. 100 c. URL: https://arxiv.org/pdf/2303.08774.pdf (accessed 06.07.2023).
5. Lightman H., Kosaraju V., Burda Y., Edwards H., Baker B., Lee T., Leike J., Schulman J., Sutskever I., Cobbe K. Let's Verify Step by Step // arXiv e-prints. 2023. 29 c. URL: https://arxiv.org/pdf/2305.20050.pdf (accessed 06.07.2023).
6. Peng K., Ding L., Zhong Q., Shen L., Liu X., Zhang M., Ouyang Yu., Tao D. Towards Making the Most of ChatGPT for Machine Translation // Cornell University. 2023. URL: https://arxiv.org/abs/2303.13780 (accessed 10.07.2023).
7. Chen L., Zaharia M., Zou J. How Is ChatGPT's Behavior Changing over Time? // arXiv eprints. 2023. 8 c. URL: https://arxiv.org/pdf/2307.09009.pdf (accessed 29.07.2023).
8. All Systems Operational // OpenAI. URL: https://status.openai.com (accessed 06.07.2023).
9. Brown T. B., Mann B., Ryder N., Subbiah M., Kaplan J., Dhariwal P., Neelakantan A., Shyam P., Sastry G., Askell A., Agarwal S., Herbert-Voss A., Krueger G., Henighan T., Child R., Ramesh A., Ziegler D.M., Wu J., Winter C., Hesse C., Chen M., Sigler E., Litwin M., Gray S., Chess B., Clark J., Berner C., McCandlish S., Radford A., Sutskever I., Amodei D. Language Models are Few-Shot Learners // arXiv e-prints. 2020. URL: https://arxiv.org/pdf/2005.14165.pdf (accessed 06.07.2023).
10. Razzhigaev A., Salnikov M., Malykh V., Braslavski P., Panchenko A. A System for Answering Simple Questions in Multiple Languages // Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. 2023. C. 524-537. URL: https://aclanthology.org/2023.acl-demo.51/ (accessed 29.07.2023).
11. Models // OpenAI API. URL: https://platform.openai.com/docs/models/gpt-3-5 (accessed 06.07.2023).
12. OpenAI Platform. URL: https://platform.openai.com/tokenizer (accessed 06.07.2023).

Madzhumder Madina Sh. Student, Department of Information and Analytical Activities, Moscow State Linguistic University. Research areas: data analysis, artificial intelligence, large language models, natural language processing.
E-mail: mmadzhumder@gmail.com.

Begunova Diana D. Student, Department of Information and Analytical Activities, Moscow State Linguistic University. Research areas: data analysis, artificial intelligence, large language models, natural language processing.
E-mail: dbegunova01@gmail.com