Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №1

по дисциплине «Автоматизация научных исследований»

Генерация аннотаций по тексту

Выполнили студенты:
Нгуен Тхи Хань Хуен
Юдин Пётр
Зубов Глеб
Наумович Лаврентий
Группа: 5040102/60201

Санкт-Петербург
2026

Содержание

1 Цель работы **2**

2 Задание **2**

3 Выбор и описание статей **2**

3.1 Статья на русском языке 2

3.2 Статья на английском языке 2

3.3 Подготовка эталонных данных 3

4 Промпт **3**

4.1 Промпт на английском языке 4

5 Результаты **4**

5.1 Анализ количественных метрик 4

5.2 Анализ качественных показателей (ручная оценка) 7

5.2.1 Детальный разбор неточных формулировок 8

5.2.2 Сравнение аннотаций моделей с авторским эталоном 10

6 Заключение **11**

1 Цель работы

Сравнить качество работы четырёх языковых моделей (ChatGPT, GigaChat, Gemini и DeepSeek) при составлении аннотаций к научным текстам на русском и английском языках, выявить ошибки и галлюцинации, а также определить преимущества и ограничения каждой модели.

2 Задание

1. Выбрать две научные статьи: одну на русском языке и одну на английском языке, опубликованные вместе с авторскими аннотациями.
2. Подготовить тексты статей, исключив из входных данных авторские аннотации и ключевые слова.
3. Передать одинаковые тексты четырём языковым моделям с одинаковым промптом для каждой языковой версии.
4. Сравнить результаты моделей с авторскими аннотациями по лексическим метрикам и содержательным критериям.
5. Проверить фактическую точность сгенерированных утверждений по полному тексту каждой статьи.
6. Определить преимущества и ограничения использованных моделей и выбранной методики оценки.

3 Выбор и описание статей

3.1 Статья на русском языке

Ма Ж. Искусственный интеллект как средства корректирующей обратной связи в обучении письменной речи в преподавании русского языка как иностранного // Мир науки. Педагогика и психология. 2024. Статья № 93PDMN524.

Полный текст и авторская аннотация доступны в PDF-версии публикации: `https://mir-nauki.com/PDF/93PDMN524.pdf`.

3.2 Статья на английском языке

Benali A. The Impact of Using Automated Writing Feedback in ESL/EFL Classroom Contexts // English Language Teaching. 2021. Vol. 14, No. 12. P. 189–195. DOI: 10.5539/elt.v14n12p189.

Полный текст статьи доступен по ссылке: `https://files.eric.ed.gov/fulltext/EJ1323912.pdf`.

3.3 Подготовка эталонных данных

Для каждой статьи подготавливаются отдельные файлы:

- `article_clean_rus.txt` — текст русскоязычной статьи без авторской аннотации, ключевых слов, заключения и списка литературы;
- `article_clean_eng.txt` — текст англоязычной статьи без авторской аннотации, ключевых слов, заключения и списка литературы;
- `abstract_rus.txt` — исходная авторская аннотация к русскоязычной статье, используемая в качестве эталона для сравнения;
- `abstract_eng.txt` — исходная авторская аннотация к англоязычной статье, используемая в качестве эталона для сравнения.

Авторская аннотация не передаётся языковым моделям. На этапе подготовки исходного текста были удалены следующие элементы: аннотации на русском и английском языках, ключевые слова, раздел «Для цитирования», заголовки и нижние колонтитулы, список литературы и заключение. Таблицы, числовые результаты и подписи, необходимые для понимания исследования, сохраняются. Если полный текст слишком велик для контекстного окна модели, одинаково сокращаются входные тексты для всех моделей; состав и объём сокращения фиксируются в отчёте.

4 Промпт

Для генерации аннотаций были подготовлены два запроса, различающиеся языком инструкции. Русскоязычный промпт требует аннотацию на русском языке, англоязычный — на английском. В обоих случаях требовалось составить аннотацию, включающую цель исследования, методы, результаты и выводы. Текст должен был быть представлен одним абзацем в безличном стиле.

Дополнительно в запросах указывалось, что необходимо использовать только факты, содержащиеся в исходной статье, точно передавать числовые значения и названия методов и библиотек, не добавлять неподтверждённую информацию и проверять каждое утверждение перед представлением результата.

Русскоязычный промпт

Ты — научный редактор журнала.
Напиши аннотацию к статье ниже.
Структура: цель, методы, результаты, выводы.
Объём: 150–250 слов, один абзац, безличный стиль.
Язык: русский.
Используй только факты из статьи.
Точно передавай числовые значения, названия методов и библиотек.
Не добавляй информацию, которой нет в тексте.
Перед ответом проверь каждое утверждение на соответствие исходному тексту.

4.1 Промпт на английском языке

English-language prompt

You are an academic editor for a scientific journal.
Write an abstract for the article provided below.
Structure: objective, methods, results, and conclusions.
Length: 80–150 words, one paragraph, impersonal style.
Language: English
Use only facts stated in the article.
Accurately reproduce numerical values, method names, and library names.
Do not add any information that is not present in the text.
Before submitting your answer, verify that every statement is supported by the original article.

5 Результаты

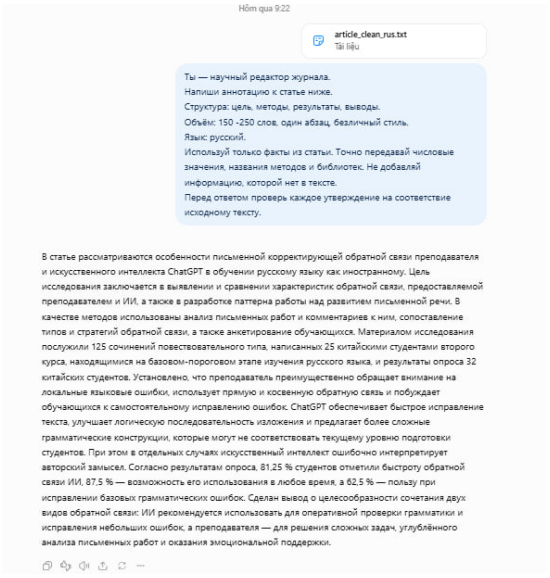
5.1 Анализ количественных метрик

Таблица 1: Результаты для русскоязычного текста (без лемматизации)

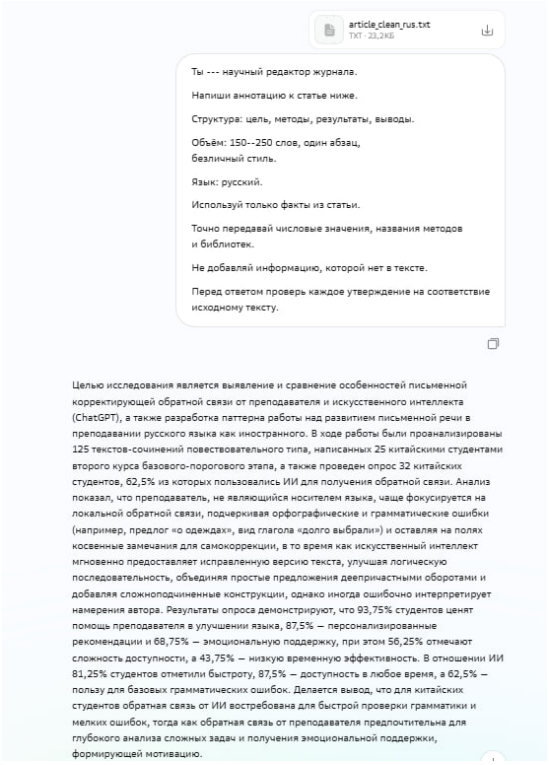
Метрика	ChatGPT	GigaChat	Gemini	DeepSeek
ROUGE-1 F1	**0.4098**	0.3419	0.3636	0.3852
ROUGE-2 F1	**0.1716**	0.1032	0.1062	0.1220
ROUGE-L F1	0.2293	0.1652	0.2463	**0.2691**
BERTScore F1	**0.7914**	0.7133	0.7327	0.7408

Примечание: лемматизация не применялась. Жирным выделены лучшие значения по каждой метрике среди всех четырёх моделей.

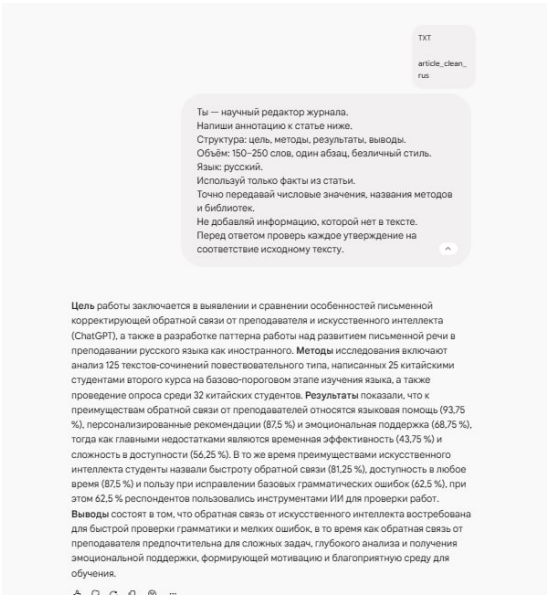
Согласно данным таблиц 1 и 2, картина лидерства зависит от языка и метрики.



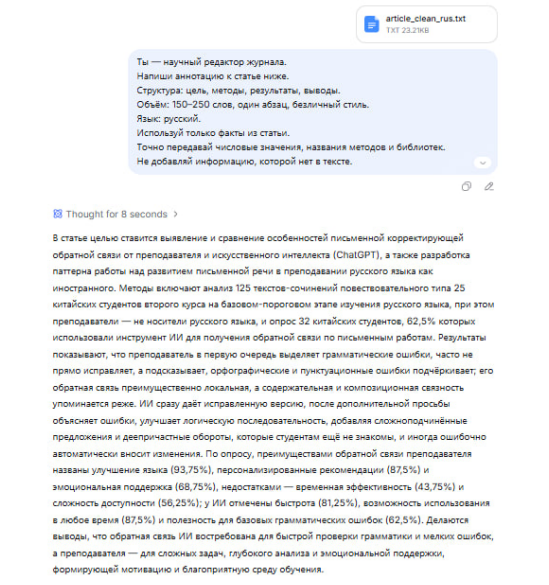
(a) Аннотация ChatGPT



(b) Аннотация GigaChat



(c) Аннотация Gemini



(d) Аннотация DeepSeek

Рис. 1: Примеры сгенерированных аннотаций четырьмя языковыми моделями

Таблица 2: Результаты для англоязычного текста

Метрика	ChatGPT	GigaChat	Gemini	DeepSeek
ROUGE-1 F1	**0.4384**	0.3838	0.4229	0.4028
ROUGE-2 F1	0.0690	0.0678	**0.0722**	0.0712
ROUGE-L F1	**0.1918**	0.1549	0.1720	0.1555
BERTScore F1	0.8590	0.8543	**0.8634**	0.8499

Примечание: жирным выделены лучшие значения по каждой метрике. Различия BERTScore F1 между всеми четырьмя моделями невелики (0.8499–0.8634), что указывает на близкое семантическое качество аннотаций.

Таблица 3: Сравнение аннотаций по формальным и содержательным критериям для **англоязычного** текста

Критерий	ChatGPT	GigaChat	DeepSeek	Gemini
Галлюцинации (искажённые факты), шт.	0	0	0	0
Неточные формулировки, шт.	1	2	0	2
Структура, из 4	4/4	4/4	4/4	4/4
Объём, слов (требование 80–150)	147	149	139	136
Один абзац	Да	Нет	Да	Да
Только аннотация, без лишних реплик	Да	Нет	Да	Да

Примечание: у Gemini зафиксированы 2 неточные формулировки — неверный термин «automated written evaluation» вместо «automated writing evaluation» и обобщение «inability to evaluate content and organization» (в статье речь идёт об ограничениях, а не о полной неспособности). У DeepSeek неточных формулировок не выявлено.

Таблица 4: Сравнение аннотаций для **русскоязычного** текста

Критерий	ChatGPT	GigaChat	DeepSeek	Gemini
Галлюцинации (искажённые факты), шт.	0	0	0	0
Неточные формулировки, шт.	0	2	4	4
Структура, из 4	4/4	4/4	4/4	3/4
Объём, слов (требование 150–250)	215	158	211	173
Один абзац	Да	Да	Да	Да
Только аннотация, без лишних реплик	Да	Да	Да	Да

Примечание: для DeepSeek и Gemini критерий «неточные формулировки» считался как «неопределённые / обобщённые / неоднозначные формулировки» (без учёта грамматических и стилистических погрешностей). У Gemini дополнительно зафиксирована структурная неполнота: блок «результаты» ограничен данными опроса и не отражает ключевое качественное сравнение обратной связи преподавателя и ИИ.

Русскоязычный текст. По ROUGE-1 (0.4098), ROUGE-2 (0.1716) и BERTScore F1 (0.7914) лидирует **ChatGPT**. Однако по ROUGE-L первое место занимает **DeepSeek** (0.2691), опережая Gemini (0.2463) и ChatGPT (0.2293). **Gemini** уступает DeepSeek по всем метрикам: ROUGE-1 (0.3636 против 0.3852), ROUGE-2 (0.1062 против 0.1220), ROUGE-L (0.2463 против 0.2691) и BERTScore F1 (0.7327 против 0.7408). **GigaChat** замыкает список по всем показателям (0.3419; 0.1032; 0.1652; 0.7133). Показательно, что разрыв между DeepSeek и ChatGPT по ROUGE-L больше, чем по ROUGE-1: DeepSeek лучше удерживает длинные совпадающие последовательности, хотя уступает по униграммам и биграммам.

Англоязычный текст. По ROUGE-1 (0.4384) и ROUGE-L (0.1918) лидирует **ChatGPT**; по ROUGE-2 — **Gemini** (0.0722, немного выше DeepSeek 0.0712 и ChatGPT 0.0690); по BERTScore F1 — также **Gemini** (0.8634), далее ChatGPT (0.8590), GigaChat (0.8543) и DeepSeek (0.8499). Различия BERTScore F1 между всеми четырьмя моделями невелики (в пределах 0.0135), что говорит о близком семантическом качестве аннотаций. **GigaChat** уступает остальным моделям по ROUGE-1, ROUGE-L и BERTScore, но по ROUGE-2 (0.0678) лишь немного отстаёт от лидера.

Сводка. ChatGPT остаётся самой сильной моделью на русском тексте по трём из четырёх метрик и на английском — по двум из четырёх. Gemini лидирует на английском по ROUGE-2 и BERTScore F1, а DeepSeek — на русском по ROUGE-L. GigaChat стабильно занимает последнее место по всем метрикам на русском тексте и предпоследнее — на английском.

5.2 Анализ качественных показателей (ручная оценка)

Результаты ручной проверки (таблицы 3 и 4) показывают, что все четыре модели не допускают галлюцинаций (выдуманных фактов). По структуре ChatGPT, GigaChat и DeepSeek стабильно дают 4/4 на обоих языках, тогда как у Gemini на русскоязычном тексте структура снижена до 3/4 из-за отсутствия блока качественных результатов (сравнение обратной связи преподавателя и ИИ). По точности формулировок лидирует ChatGPT (0–1 неточность), за ним следуют GigaChat (2) и Gemini (2–4), а DeepSeek демонстрирует разный результат: 0 неточностей на английском тексте и 4 — на русском.

- **Англоязычный текст.** ChatGPT строго выполнил все формальные требования: объём 147 слов, один абзац, без лишних реплик; выявлена 1 неточная формулировка. GigaChat допустил 2 неточные формулировки и добавил лишний текст в конце (формат «один абзац» и «только аннотация» не соблюдён). DeepSeek показал наилучший результат по точности: 0 неточностей, 139 слов, один абзац, без лишних реплик. Gemini дал 2 неточные формулировки, но соблюл формат: 136 слов, один абзац, без лишних реплик.

- **Русскоязычный текст.** ChatGPT создал наиболее информативную аннотацию (215 слов), сохранив все ключевые числовые данные (25 студентов, 125 сочинений, проценты опроса: 81.25%, 87.5%, 62.5%), и не допустил неточностей. GigaChat дал слишком краткую аннотацию (158 слов), упустив количество студентов и заменив точные проценты общими фразами (2 неточности). DeepSeek сохранил структуру 4/4 и объём 211 слов, но допустил 4 обобщающие формулировки (подробнее см. 5.2.1). Gemini также показал 4 неточные формулировки и, кроме того, не отразил качественные результаты сравнения обратной связи преподавателя и ИИ (структура 3/4), объём 173 слова — ближе к нижней границе.

5.2.1 Детальный разбор неточных формулировок

Несмотря на отсутствие галлюцинаций, при детальном сопоставлении были выявлены следующие неточности. Под «неточной формулировкой» понимается утверждение, которое не является ложным по факту, но неопределённо, обобщено или неоднозначно передаёт содержание исходной статьи (без учёта чисто грамматических и стилистических погрешностей).

- **Англоязычный текст (GigaChat — 2 ошибки):**

  1. В исходной статье говорится, что точность выявления ошибок в системе Criterion может падать ниже 50% *для некоторых типов ошибок*. GigaChat обобщил это и написал: «systems like Criterion demonstrated error flagging accuracy below 50%», что искажает масштаб проблемы.
  2. GigaChat назвал статью «синтезом литературы и *эмпирических данных*» (synthesis of literature and empirical data). Однако оригинальная работа является обзором литературы (literature review), автор не проводил собственных эмпирических исследований, а лишь анализировал труды других учёных.

- **Англоязычный текст (ChatGPT — 1 ошибка):**

  1. В аннотации ChatGPT используется фраза «The analysis reviews empirical studies...». Хотя это не является грубой ошибкой, формулировка может быть воспринята как заявление о проведении собственного эмпирического анализа, тогда как статья носит исключительно обзорный характер.

- **Англоязычный текст (DeepSeek):** неточных формулировок не выявлено. Все утверждения, включая числовое значение «below 50% for some Criterion errors», соответствуют тексту статьи.

- **Англоязычный текст (Gemini — 2 ошибки):**

1. **Неверный термин:** «automated written evaluation (AWE)» вместо «automated writing evaluation (AWE)». В статье и в авторской аннотации используется устойчивый термин «automated writing evaluation».
2. **Обобщение:** «an inability to evaluate content and organization» подаёт как полную неспособность то, что в статье описано как ограничение: AWE-системы не читают и не понимают смысл, а обратная связь по содержанию и организации оценивается как ограниченная и вызывающая неудовлетворённость, но не как полностью отсутствующая.

- **Русскоязычный текст (GigaChat — 2 ошибки):**

1. **Потеря данных о выборке:** в оригинале указано, что проанализированы 125 сочинений **25 китайских студентов**. GigaChat упустил количество студентов, что делает описание методологии неполным.
2. **Игнорирование числовых данных:** в тексте статьи приведены точные результаты опроса (81,25%, 87,5%, 62,5%). ChatGPT перенёс их в аннотацию дословно, а GigaChat заменил их общими фразами («ИИ признан полезным...»), что нарушает инструкцию промпта о точной передаче числовых значений.

- **Русскоязычный текст (ChatGPT):** неточных формулировок не выявлено. Модель точно передала все факты и числовые данные.

- **Русскоязычный текст (DeepSeek — 4 неточные формулировки):**

1. **Обобщение объёма ошибок:** формулировка «орфографические и пунктуационные ошибки подчёркивает» подаёт как общее правило то, что в статье сказано лишь о *некоторых простых* орфографических ошибках и неправильной пунктуации.
2. **Универсализация поведения ИИ:** фраза «ИИ сразу даёт исправленную версию» описывает единичный пример из статьи как общую характеристику модели.
3. **Неоднозначность «временная эффективность»:** в перечне недостатков преподавательской обратной связи формулировка «временная эффективность (43,75%)» не позволяет однозначно понять, имеется ли в виду своевременность или затраты времени.
4. **Неопределённость «сложность доступности»:** оборот «сложность доступности (56,25%)» не уточняет, о какой именно трудности идёт речь (запись на консультацию, ожидание ответа и т. п.).

- **Русскоязычный текст (Gemini — 4 неточные формулировки + структурная неполнота):**

  1. **Сужение смысла «языковая помощь» (93,75%):** в статье речь идёт о *помощи в улучшении языка*, тогда как формулировка «языковая помощь» шире и не передаёт содержания критерия.
  2. **Сужение цели использования ИИ:** указано «62,5% респондентов пользовались инструментами ИИ для проверки работ», тогда как в статье — «для получения обратной связи по письменным работам»; «проверка» уже и не тождественна «обратной связи».
  3. **Обобщение блока результатов:** оборот «Результаты показали, что к преимуществам. . . » создаёт впечатление, что все результаты сводятся к данным опроса, тогда как качественное сравнение обратной связи преподавателя и ИИ (ядро статьи) в аннотации не отражено.
  4. **Неопределённость «сложность в доступности» (56,25%):** аналогично DeepSeek, формулировка не уточняет, в чём именно состоит трудность доступа к преподавательской обратной связи.

  Дополнительно (структура): блок «результаты» у Gemini ограничен данными опроса, из-за чего структурная полнота аннотации снижена до 3/4.

Общий вывод по качеству. ChatGPT демонстрирует наиболее высокую способность следовать строгим инструкциям (соблюдение объёма, отсутствие лишних реплик) и сохранять фактические и числовые данные; у него минимум неточностей на обоих языках. GigaChat склонен к обобщению и потере деталей, а также к нарушению формата (в англоязычном тексте). DeepSeek точен на английском тексте (0 неточностей), но на русском допускает 4 обобщающие формулировки. Gemini даёт 2 неточности на английском и 4 на русском, а на русскоязычном тексте дополнительно теряет структурную полноту (3/4). По совокупности критериев ChatGPT остаётся наиболее надёжной моделью для задачи генерации научной аннотации.

5.2.2 Сравнение аннотаций моделей с авторским эталоном

Помимо сравнения моделей между собой, было проведено сопоставление их результатов с исходными аннотациями авторов.

Что модели передали лучше автора. По формальной информативности все четыре модели превосходят авторский эталон. В то время как авторские аннотации часто сливают цель с описанием проблемы (например, в русскоязычной статье), модели ChatGPT, GigaChat, DeepSeek и Gemini строго соблюдают структуру «цель — методы — результаты — выводы» (4/4; у Gemini на русском тексте — 3/4 из-за

отсутствия качественных результатов). Кроме того, в англоязычной статье автор лишь в общих чертах упоминает наличие обзора, тогда как все модели чётко перечислили конкретные исследовательские работы (Li et al., 2015; Wang et al., 2020; Chen and Cheng, 2008), на которые опирается статья.

Чего у моделей нет (по сравнению с эталоном). Ни одна из моделей не справилась со всеми нюансами оригинала.

- **Потеря статуса статьи (Английский текст).** В авторском эталоне чётко указано: «My discussion shows... I provide recommendations...», что подчёркивает обзорно-аналитический характер работы (author's review). GigaChat использовал фразу «synthesis of literature and *empirical data*», ChatGPT написал «reviews *empirical studies*», а Gemini — «the results indicate...», что создаёт ложное впечатление, будто автор статьи сам проводил эмпирические измерения. DeepSeek в этом отношении наиболее точен: он последовательно описывает работу как обзор (reviews literature and empirical studies), не приписывая автору собственных эмпирических исследований.

- **Потеря количественных данных (Русский текст).** В оригинале чётко указано количество проанализированных работ (125 сочинений **25 студентов**). GigaChat упустил число студентов, сделав описание методологии неполным. ChatGPT и DeepSeek сохранили точные проценты из опроса (81.25%, 87.5%, 62.5%), в то время как GigaChat и Gemini заменили их общими фразами, что снижает научную ценность аннотации. Кроме того, Gemini не отразил качественное сравнение обратной связи преподавателя и ИИ — ядро статьи.

6 Заключение

В ходе данной лабораторной работы была достигнута поставленная цель: проведено сравнение качества генерации научных аннотаций моделями ChatGPT, GigaChat, Gemini и DeepSeek на материале русскоязычных и англоязычных текстов. По результатам исследования можно сделать следующие итоговые выводы:

1. **По количественным метрикам** (ROUGE и BERTScore) **ChatGPT** демонстрирует лучшие результаты на русскоязычном тексте по ROUGE-1 (0.4098), ROUGE-2 (0.1716) и BERTScore F1 (0.7914); по ROUGE-L на русском лидирует DeepSeek (0.2691). На англоязычном тексте ChatGPT лидирует по ROUGE-1 (0.4384) и ROUGE-L (0.1918), а Gemini — по ROUGE-2 (0.0722) и BERTScore F1 (0.8634). GigaChat уступает остальным моделям по большинству метрик на обоих языках. Различия BERTScore F1 между моделями невелики (0.7133–0.7914 на русском и 0.8499–0.8634 на английском), что говорит о близком семантическом качестве сгенерированных аннотаций.

2. **По качественным показателям** (ручная оценка) все четыре модели продемонстрировали отсутствие галлюцинаций. ChatGPT показал себя как более надёжный инструмент, способный строго следовать формальным ограничениям (объём, формат) и сохранять ключевые числовые данные; у него минимум неточностей (1 на английском тексте, 0 на русском). GigaChat склонен к обобщению и потере деталей (2 неточности на каждом языке), а также к нарушению формата (в англоязычном тексте). DeepSeek точен на английском тексте (0 неточностей), но на русском допускает 4 обобщающие формулировки. Gemini даёт 2 неточности на английском и 4 на русском, а на русскоязычном тексте дополнительно теряет структурную полноту (3/4) из-за отсутствия качественных результатов.

3. **Итоговый вывод.** Для задач, требующих высокой точности и строгого соблюдения инструкций (например, составление научных аннотаций), **ChatGPT** является наиболее предпочтительной моделью: он лидирует по большинству количественных метрик на обоих языках и показывает минимум качественных ошибок. **DeepSeek** наиболее точен на англоязычном материале и занимает второе место на русском по большинству метрик, но требует дополнительной проверки обобщающих формулировок на русском тексте. **Gemini** силён на английском (лучший ROUGE-2 и BERTScore F1), но на русском теряет структурную полноту. **GigaChat** способен генерировать качественные тексты, однако требует наиболее тщательной ручной проверки на предмет упущенных фактов, числовых данных и соблюдения формата.

Таким образом, комплексное использование автоматических лексических/семантических метрик в сочетании с ручной фактчекинг-проверкой позволяет объективно оценить сильные и слабые стороны современных LLM-моделей. Ни одна из четырёх моделей не является универсальным лидером: выбор модели должен определяться языком текста и приоритетом задачи (точность фактов, соблюдение формата или лексическое совпадение с эталоном).