Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №1

по дисциплине «Автоматизация научных исследований»

Генерация аннотаций по тексту

Выполнил студент:
Нгуен Тхи Хань Хуен
Группа: 5040102/60201

Санкт-Петербург
2026

Содержание

1 Цель работы **2**

2 Задание **2**

3 Выбор и описание статей **2**

3.1 Статья на русском языке 2

3.2 Статья на английском языке 2

3.3 Подготовка эталонных данных 3

4 Промпт **3**

4.1 Промпт на английском языке 4

5 Результаты **4**

5.1 Анализ количественных метрик 6

5.2 Анализ качественных показателей (ручная оценка) 6

5.2.1 Детальный разбор неточных формулировок 6

5.2.2 Сравнение аннотаций моделей с авторским эталоном 7

6 Заключение **8**

1 Цель работы

Сравнить качество работы двух языковых моделей (ChatGPT и Gigachat) при составлении аннотаций к научно-популярным текстам на русском и английском языках, выявить ошибки и галлюцинации.

2 Задание

1. Выбрать две научные статьи: одну на русском языке и одну на английском языке, опубликованные вместе с авторскими аннотациями.
2. Подготовить тексты статей, исключив из входных данных авторские аннотации и ключевые слова.
3. Передать одинаковые тексты двум языковым моделям с одинаковым промптом для каждой языковой версии.
4. Сравнить результаты моделей с авторскими аннотациями по лексическим метрикам и содержательным критериям.
5. Проверить фактическую точность сгенерированных утверждений по полному тексту каждой статьи.
6. Определить преимущества и ограничения использованных моделей и выбранной методики оценки.

3 Выбор и описание статей

3.1 Статья на русском языке

Ма Ж. Искусственный интеллект как средства корректирующей обратной связи в обучении письменной речи в преподавании русского языка как иностранного // Мир науки. Педагогика и психология. 2024. Статья № 93PDMN524.

Полный текст и авторская аннотация доступны в PDF-версии публикации: `https://mir-nauki.com/PDF/93PDMN524.pdf`.

3.2 Статья на английском языке

Benali A. The Impact of Using Automated Writing Feedback in ESL/EFL Classroom Contexts // English Language Teaching. 2021. Vol. 14, No. 12. P. 189–195. DOI: 10.5539/elt.v14n12p189.

Полный текст статьи доступен по ссылке: `https://files.eric.ed.gov/fulltext/EJ1323912.pdf`.

3.3 Подготовка эталонных данных

Для каждой статьи подготавливаются отдельные файлы:

- `article_clean_rus.txt` — текст русскоязычной статьи без авторской аннотации, ключевых слов, заключения и списка литературы;
- `article_clean_eng.txt` — текст англоязычной статьи без авторской аннотации, ключевых слов, заключения и списка литературы;
- `abstract_rus.txt` — исходная авторская аннотация к русскоязычной статье, используемая в качестве эталона для сравнения;
- `abstract_eng.txt` — исходная авторская аннотация к англоязычной статье, используемая в качестве эталона для сравнения.

Авторская аннотация не передаётся языковым моделям. На этапе подготовки исходного текста были удалены следующие элементы: аннотации на русском и английском языках, ключевые слова, раздел «Для цитирования», заголовки и нижние колонтитулы, список литературы и заключение. Таблицы, числовые результаты и подписи, необходимые для понимания исследования, сохраняются. Если полный текст слишком велик для контекстного окна модели, одинаково сокращаются входные тексты для обеих моделей; состав и объём сокращения фиксируются в отчёте.

4 Промпт

Для генерации аннотаций были подготовлены два запроса, различающиеся языком инструкции. В обоих случаях требовалось составить аннотацию на русском языке, включающую цель исследования, методы, результаты и выводы. Текст должен был быть представлен одним абзацем в безличном стиле.

Дополнительно в запросах указывалось, что необходимо использовать только факты, содержащиеся в исходной статье, точно передавать числовые значения и названия методов и библиотек, не добавлять неподтверждённую информацию и проверять каждое утверждение перед представлением результата.

Русскоязычный промпт

Ты — научный редактор журнала.
Напиши аннотацию к статье ниже.
Структура: цель, методы, результаты, выводы.
Объём: 150–250 слов, один абзац, безличный стиль.
Язык: русский.
Используй только факты из статьи.
Точно передавай числовые значения, названия методов и библиотек.
Не добавляй информацию, которой нет в тексте.
Перед ответом проверь каждое утверждение на соответствие исходному тексту.

4.1 Промпт на английском языке

English-language prompt

You are an academic editor for a scientific journal.
Write an abstract for the article provided below.
Structure: objective, methods, results, and conclusions.
Length: 80–150 words, one paragraph, impersonal style.
Language: English
Use only facts stated in the article.
Accurately reproduce numerical values, method names, and library names.
Do not add any information that is not present in the text.
Before submitting your answer, verify that every statement is supported by the original article.

5 Результаты

Таблица 1: Результаты до и после лемматизации для русского текста

Метрика	ChatGPT — до	ChatGPT — после	GigaChat — до	GigaChat — после
ROUGE-1	0.4098	0.4878	0.3419	0.4217
ROUGE-2	0.1716	0.2304	0.1032	0.1261
ROUGE-L	0.2293	0.3024	0.1652	0.2108
BERTScore F1	0.7914	—	0.7133	—

Примечание: в текущих данных BERTScore представлен только до лемматизации; результатов после обработки для сравнения нет.

Таблица 2: Результаты для англоязычного текста

Метрика	ChatGPT	GigaChat
ROUGE-1 F1	0.4384	0.3838
ROUGE-2 F1	0.0690	0.0678
ROUGE-L F1	0.1918	0.1549
BERTScore F1	0.8590	0.8543

Примечание: значения BERTScore F1 для обеих моделей находятся в пределах статистической погрешности.

Таблица 3: Сравнение аннотаций по формальным и содержательным критериям для **англоязычного** текста

Критерий	ChatGPT	GigaChat
Галлюцинации (искажённые факты), шт.	0	0
Неточные формулировки, шт.	1	2
Структура, из 4	4/4	4/4
Объём, слов (требование 80–150)	147	149
Один абзац	Да	Нет
Только аннотация, без лишних реплик	Да	Нет

Таблица 4: Сравнение аннотаций для **русскоязычного** текста

Критерий	ChatGPT	GigaChat
Галлюцинации (искажённые факты), шт.	0	0
Неточные формулировки, шт.	0	2
Структура, из 4	4/4	4/4
Объём, слов (требование 150–250)	215	158
Один абзац	Да	Да
Только аннотация, без лишних реплик	Да	Да

5.1 Анализ количественных метрик

Согласно данным, представленным в таблицах 1 и 2, **ChatGPT** превосходит **GigaChat** по всем лексическим метрикам ROUGE на обоих языках. Лемматизация существенно улучшает показатели обеих моделей на русском языке. Однако лемматизация не сближает модели: разрыв в показателях сохраняется, а по метрике ROUGE-2 даже увеличивается. На английском языке разрыв между моделями менее выражен, а значения ROUGE-2 для обеих моделей близки к нулю (0.0690 и 0.0678), что указывает на активное использование синонимов и перефразирование в обеих аннотациях. Показатели BERTScore F1 очень близки (0.8590 и 0.8543), что не позволяет выявить явного лидера по семантической близости.

5.2 Анализ качественных показателей (ручная оценка)

Результаты ручной проверки (таблицы 3 и 4) показывают, что обе модели успешно справляются со структурой (4/4) и не допускают галлюцинаций (выдуманных фактов). Однако есть различия в точности и соблюдении инструкций.

- **Англоязычный текст.** ChatGPT строго выполнил все формальные требования: объём (147 слов), формат (один абзац, без лишних реплик). GigaChat допустил 2 неточные формулировки и добавил лишний текст в конце.
- **Русскоязычный текст.** ChatGPT создал более информативную аннотацию (215 слов), сохранив все ключевые числовые данные исследования (25 студентов, 125 сочинений, проценты опроса: 81.25%, 87.5%, 62.5%). GigaChat создал слишком краткую аннотацию (158 слов), упустив количество студентов и заменив точные проценты общими фразами. Это объясняет более низкий балл ROUGE у GigaChat.

5.2.1 Детальный разбор неточных формулировок

Несмотря на отсутствие галлюцинаций, при детальном сопоставлении были выявлены следующие неточности:

- **Англоязычный текст (GigaChat — 2 ошибки):**
  1. В исходной статье говорится, что точность выявления ошибок в системе Criterion может падать ниже 50% *для некоторых типов ошибок*. GigaChat обобщил это и написал: «systems like Criterion demonstrated error flagging accuracy below 50%», что искажает масштаб проблемы.
  2. GigaChat назвал статью «синтезом литературы и *эмпирических данных*» (synthesis of literature and empirical data). Однако оригинальная работа

является обзором литературы (literature review), автор не проводил собственных эмпирических исследований, а лишь анализировал труды других ученых.

- **Англоязычный текст (ChatGPT — 1 ошибка):**

  1. В аннотации ChatGPT используется фраза «The analysis reviews empirical studies...». Хотя это не является грубой ошибкой, формулировка может быть воспринята как заявление о проведении собственного эмпирического анализа, тогда как статья носит исключительно обзорный характер.

- **Русскоязычный текст (GigaChat — 2 ошибки):**

  1. **Потеря данных о выборке:** В оригинале указано, что проанализированы 125 сочинений **25 китайских студентов**. GigaChat упустил количество студентов, что делает описание методологии неполным.
  2. **Игнорирование числовых данных:** В тексте статьи приведены точные результаты опроса (81,25%, 87,5%, 62,5%). ChatGPT перенес их в аннотацию дословно, а GigaChat заменил их общими фразами («ИИ признан полезным...»), что нарушает инструкцию промпта о точной передаче числовых значений.

- **Русскоязычный текст (ChatGPT):** Неточных формулировок не выявлено. Модель точно передала все факты и числовые данные.

Общий вывод по качеству. ChatGPT демонстрирует более высокую способность следовать строгим инструкциям (соблюдение объёма, отсутствие лишних реплик) и сохранять фактические и числовые данные. GigaChat склонен к обобщению и потере деталей, а также к нарушению формата (в англоязычном тексте).

5.2.2 Сравнение аннотаций моделей с авторским эталоном

Помимо сравнения моделей между собой, было проведено сопоставление их результатов с исходными аннотациями авторов.

Что модели передали лучше автора. По формальной информативности обе модели превосходят авторский эталон. В то время как авторские аннотации часто сливают цель с описанием проблемы (например, в русскоязычной статье), модели ChatGPT и GigaChat строго соблюдают структуру «цель — методы — результаты — выводы» (4/4). Кроме того, в англоязычной статье автор лишь в общих чертах упоминает наличие обзора, тогда как модели четко перечислили конкретные исследовательские работы (Li et al., 2015; Wang et al., 2020; Chen and Cheng, 2008), на которые опирается статья.

Чего у моделей нет (по сравнению с эталоном). Ни одна из моделей не справилась со всеми нюансами оригинала.

- **Потеря статуса статьи (Английский текст).** В авторском эталоне четко указано: «My discussion shows... I provide recommendations...», что подчеркивает обзорно-аналитический характер работы (author's review). GigaChat использовал фразу «synthesis of literature and *empirical data*», а ChatGPT написал «reviews *empirical studies*». Это создает ложное впечатление, будто автор статьи сам проводил эмпирические измерения, хотя на самом деле это обзор чужих исследований.

- **Потеря количественных данных (Русский текст).** В оригинале четко указано количество проанализированных работ (125 сочинений **25 студентов**). GigaChat упустил число студентов в своей аннотации, сделав описание методологии неполным. Кроме того, ChatGPT сохранил точные проценты из опроса (81.25%, 87.5%), в то время как GigaChat заменил их общими фразами, что снижает научную ценность аннотации.

6 Заключение

В ходе данной лабораторной работы была достигнута поставленная цель: проведено сравнение качества генерации научных аннотаций моделями ChatGPT и GigaChat на материале русскоязычных и англоязычных текстов. По результатам исследования можно сделать следующие итоговые выводы:

1. **По количественным метрикам** (ROUGE и BERTScore) ChatGPT стабильно демонстрирует более высокие результаты на обоих языках. Применение лемматизации при оценке русского текста улучшает показатели обеих моделей, но не меняет расстановку сил. На английском языке семантическая метрика BERTScore показала практически равный результат, что говорит о высоком качестве перефразирования у обеих моделей.

2. **По качественным показателям** (ручная оценка) обе модели продемонстрировали отсутствие галлюцинаций. Однако ChatGPT показал себя как более надежный инструмент, способный строго следовать формальным ограничениям (объём, формат) и сохранять все ключевые числовые данные. GigaChat в свою очередь проявил склонность к чрезмерному обобщению, потере важных деталей и нарушению структуры (в англоязычном тексте).

3. **Итоговый вывод.** Для задач, требующих высокой точности и строгого соблюдения инструкций (например, составление научных аннотаций), **ChatGPT**

является более предпочтительной моделью. GigaChat способен генерировать качественные тексты, однако требует более тщательной ручной проверки на предмет упущенных фактов и числовых данных.

Таким образом, комплексное использование автоматических лексических/семантических метрик в сочетании с ручной фактчекинг-проверкой позволяет объективно оценить сильные и слабые стороны современных LLM-моделей.