Лабораторная работа №1. Генерация аннотаций по тексту

Дисциплина «Автоматизация научных исследований»
Выполнил: Поляков В., гр. 5040102/60201

Цель: сравнить аннотации трёх LLM к одной научной статье с авторской аннотацией по метрикам ROUGE и проверить их на фактическую точность.

1. Статья и подготовка текста

Наумов Р.К., Железков Н.Э. Сравнительный анализ форматов хранения текстовых данных для дальнейшей обработки методами машинного обучения // Научный результат. Информационные технологии. — 2021. — Т. 6, № 1. — С. 40–47. DOI: 10.18413/2518-1092-2021-6-1-0-5.

Из PDF извлечён текст. Из него удалены русская и английская аннотации, ключевые слова, блок «Для цитирования», колонтитулы и список литературы. Таблицы приведены к текстовому виду, и порядок столбцов сверен с оригиналом. Получился файл article.txt (≈1560 слов). Авторская аннотация (91 слово) сохранена отдельно в reference_abstract.txt и служит эталоном.

2. Модели и условия эксперимента

Модель	Разработчик	Доступ	Настройки
DeepSeek	DeepSeek	chat.deepseek.com, бесплатно	по умолчанию; DeepThink и Search выключены
GigaChat	Сбер	giga.chat, бесплатно	по умолчанию
Алиса AI	Яндекс	alice.yandex.ru, бесплатно	по умолчанию («Интеллект: Авто»)

Каждая модель запускалась в новом чате без истории. Всем трём моделям передавался один и тот же файл prompt_full.txt: промпт вместе с текстом статьи. Алиса после загрузки файла ответила «расскажите, что мне с ним сделать», поэтому ей было отправлено дополнительное сообщение «прочитай его. там задание».

3. Промпт (изменён относительно слайда 14)

Изменения: русский язык, журнал по ИТ, объём 80–100 слов (как у авторской аннотации), требование брать дословно названия форматов и библиотек.

```
Ты научный редактор журнала по информационным технологиям.
Напиши аннотацию к статье ниже.

Структура: цель, метод, результаты, вывод.
Объём 80–100 слов, один абзац, безлично.
Язык: русский.

Используй только факты из статьи.
Числа, названия форматов и библиотек бери дословно.
```

Чего нет в тексте, не добавляй.

Перед ответом сверь каждое утверждение с текстом.
Выведи только аннотацию.

Статья:
"""[текст статьи без аннотации и ключевых слов]"""

4. Таблица результатов

Метрика	DeepSeek	GigaChat	Алиса AI
ROUGE-1 (F1), %	**24.1**	14.4	22.3
ROUGE-L (F1), %	**16.1**	9.8	12.9
ROUGE-1 (F1) с лемматизацией, %	**31.0**	22.0	28.3
ROUGE-L (F1) с лемматизацией, %	**18.4**	12.1	16.3
Галлюцинации (искажённые факты), шт.	**0**	1	0
Неточные формулировки, шт.	**0**	2	2
Структура, из 4	4	4	4
Объём, слов (требование 80–100)	**82**	170	138
Один абзац, только аннотация	да	нет (лишняя реплика в конце)	нет (3 абзаца)

Как считался ROUGE. Перед подсчётом тексты приводились к нижнему регистру, пунктуация удалялась (как рекомендовано на слайде 15), в таблице указана F1-мера. Строки «с лемматизацией» получены после приведения слов к начальной форме, чтобы «формата» и «формат» считались одним словом: без этого ROUGE на русском языке занижен из-за падежных окончаний. Основными считаются строки без лемматизации.

5. Аннотации

Обозначения: **красным** — выдуманный или искажённый факт; жёлтым — неточная формулировка (близко к тексту, но смысл сдвинут); ~~зачёркнуто~~ — текст, не относящийся к аннотации.

Авторская аннотация (эталон), 91 слово

На сегодняшний день одним из перспективных направлений в области информационных технологий является машинное обучение. Оно используется во многих сферах деятельности, в том числе и в анализе текстовых данных. Между этапами сбора данных и их анализом располагается этап хранения данных. Одним из вопросов, требующих тщательного рассмотрения, является выбор формата хранения этих данных. Настоящая статья представляет собой обзор наиболее популярных форматов хранения текстовых данных, используемых в машинном обучении. Определены критерии, по которым произведено сравнение. Результатом работы является сравнительная таблица анализируемых форматов. Исходя из результатов, сделан вывод о наиболее эффективном способе хранения текстовых данных.

DeepSeek, 82 слова

Целью статьи является исследование наиболее популярных форматов хранения текстовых данных (CSV, JSON, XML) для последующего анализа методами машинного обучения на примере выгруженных чатов видеоконференций платформы Zoom. Сравнение проводилось по критериям размера файла, скорости парсинга, поддержки библиотеками Python и человекочитаемости. Установлено, что для одинаковых данных файлы CSV, JSON и XML занимают 81, 203 и 455 байт соответственно, а среднее время операции над данными составляет 45, 461,5 и 617 мс. Сделан вывод о целесообразности использования формата CSV для хранения текстовых данных из чата Zoom.

GigaChat, 170 слов

Целью исследования является сравнительный анализ форматов CSV, JSON и XML для хранения текстовых данных из чатов видеоконференций Zoom с целью их последующей обработки методами машинного обучения. Оценка проводилась по критериям размера файла, скорости сериализации-десериализации, поддержки библиотеками Python и человекочитаемости на основе работ различных авторов. Результаты показали, что для одинаковых данных формат CSV занимает наименьший объем (81 байт против 203 байт у JSON и 455 байт у XML) и обеспечивает минимальное среднее время операции над данными (45 мс против 461,5 мс и 617 мс соответственно). Все три формата поддерживаются языком Python, однако человекочитаемость оценена выше у CSV (5 баллов). Исследование скорости с использованием FastJSON и Microsoft XML Parser выявило **преимущество JSON в десериализации (644 мс против 773 мс)**, но XML

эффективнее при работе со сложными структурами. На примере добавления 10 000 записей CSV показал время 4,6 секунды. Сделан вывод о целесообразности использования формата CSV для хранения неструктурированных данных чатов Zoom ввиду их плоской структуры, обеспечивающей минимальные потери объема памяти и высокую эффективность обработки. Работа может быть дополнена внедрением новых критериев оценки.

~~Жду ваших указаний, чтобы продолжить обсуждение: мы можем разобрать методологию, углубиться в технические детали парсеров или перейти к практическим сценариям применения этих форматов.~~

Алиса AI, 138 слов

В статье проводится исследование популярных форматов хранения текстовых данных (CSV, JSON, XML) для их последующей обработки методами машинного обучения. Объектом исследования выступают выгруженные чаты видеоконференций Zoom. Анализ осуществлялся по критериям: размер файла, скорость парсинга, поддержка Python-библиотеками и удобство чтения.

Проведенное сравнение показало, что CSV-формат демонстрирует наименьший размер файлов (81 байт против 203 байт у JSON и 455 байт у XML) и высокую скорость операций (45 мс). JSON и XML показали более медленную обработку данных (461,5 и 617 мс соответственно), при этом обладая лучшей структурированностью. Все форматы имеют поддержку в Python.

Результаты исследования выявили прямую зависимость между объемом данных и скоростью их обработки: чем больше объем, тем ниже эффективность формата. На основании полученных данных сделан вывод о целесообразности использования CSV для хранения текстовых данных из Zoom-чатов ввиду их простой структуры, что обеспечивает оптимальное соотношение компактности хранения и скорости обработки.

6. Проверка фактов

Каждое утверждение аннотаций сверялось с текстом статьи. Ниже приведены только утверждения, которые не подтвердились или подтвердились частично. Все остальные утверждения найдены в статье: числа 81/203/455 байт, 45/461,5/617 мс, 4,6 с, оценка 5 баллов, критерии сравнения, вывод о CSV.

Модель	Утверждение	Что в статье	Оценка

GigaChat	«преимущество JSON в десериализации (644 мс против 773 мс)»	Табл. 1: десериализация JSON — 644 мс, XML — 461 мс; 773 мс — это *сериализация* XML. В десериализации быстрее XML, а преимущество JSON есть только в сериализации (279 против 773 мс).	**искажение факта: числа из разных столбцов, вывод обратный**
GigaChat	«XML эффективнее при работе со сложными структурами»	«при работе с более сложными структурами эффективность *сжатия* XML будет выше, чем у JSON»	неточность: частный тезис обобщён
GigaChat	«неструктурированных данных чатов Zoom ввиду их плоской структуры»	«Получаемые данные не имеют сложной структуры… можно организовать в простую плоскую таблицу»	неточность: «неструктурированные» противоречит «плоской структуре»
Алиса AI	«Объектом исследования выступают выгруженные чаты Zoom»	Объект — форматы хранения; чаты Zoom — тип данных, к которому применяется вывод. Сравнение в статье выполнено на чужом примере (таблица сетевых устройств) и данных других авторов.	неточность
Алиса AI	«прямую зависимость между объемом данных и скоростью их обработки»	«чем больше формат требует объема, тем медленнее происходит работа с данными»: речь об объёме, который требует формат, а зависимость со скоростью обратная.	неточность формулировки (пояснение после двоеточия при этом верное)

7. Сравнение с авторской аннотацией

Тип аннотации. Авторская аннотация описательная (индикативная). Первые четыре предложения из восьми — общий контекст: машинное обучение перспективно, есть этап хранения данных. В ней не названы ни сравниваемые форматы, ни критерии, ни итоговый вывод: сказано только, что «сделан вывод о наиболее эффективном способе». Все три модели написали информативные аннотации по схеме «цель — метод — результаты — вывод». В них названы CSV, JSON и XML, четыре критерия, конкретные числа и вывод в пользу CSV. По ГОСТ Р 7.0.99-2018 тексты моделей ближе к реферату.

Почему ROUGE низкий. Общих слов с эталоном мало, потому что модели пропустили вводную часть авторской аннотации и добавили конкретику, которой в эталоне нет. Самый высокий ROUGE у DeepSeek: её текст короче и ближе к эталону по объёму. У GigaChat ROUGE самый низкий из-за объёма: 170 слов против 91, и ROUGE-precision падает. Лемматизация поднимает ROUGE-1 на 6–8 п.п. и ROUGE-L на 2–3 п.п., но порядок моделей не меняет.

Что модели передали лучше автора. Цель, объект (чаты Zoom), критерии и результат статьи. По информативности все три модели превосходят эталон.

Чего у моделей нет. Ни одна модель, кроме GigaChat («на основе работ различных авторов»), не отметила, что статья обзорная и опирается на чужие данные. В авторской аннотации это сказано («представляет собой обзор»). DeepSeek и Алиса подают числа так, будто авторы сами провели измерения.

8. Вывод

Лучший результат показала **DeepSeek**. Ни одной ошибки в фактах, требования к объёму (82 слова) и формату (один абзац, только аннотация) соблюдены, все четыре части структуры на месте, ROUGE-1 и ROUGE-L самые высокие среди трёх моделей.

Алиса AI фактов не выдумала, но допустила две неточные формулировки, превысила объём (138 слов) и разбила текст на три абзаца. Задание она начала выполнять только после дополнительного сообщения.

GigaChat написал самую подробную аннотацию, но содержит единственную ошибку по фактам в эксперименте: перепутаны столбцы таблицы 1, из-за чего вывод о десериализации получился обратным. Кроме того, объём превышен почти вдвое, а в конце добавлена реплика, не относящаяся к аннотации.

Эксперимент подтверждает тезис доклада: ROUGE отражает близость к авторскому тексту, но не правдивость. Ошибку GigaChat с числами 644/773 метрика не заметила, её удалось найти только ручной сверкой с таблицей. Чем больше конкретных чисел в аннотации, тем выше риск подобной ошибки. Ограничения промпта по объёму и формату выполнила только DeepSeek.

Приложение. Скриншоты ответов моделей





