Санкт-Петербургский политехнический университет Петра Великого

Отчёт по лабораторной работе № 2

Перевод научного текста с использованием глоссария

По дисциплине «Автоматизация научных исследований»

Выполнил студент группы 5040102/60201
Сауков Дмитрий Валерьевич

Санкт-Петербург
2026

1 Материалы и ход работы

Цель работы — выяснить, помогает ли глоссарий точнее переводить термины из научной статьи. Для этого сравнивались ответы трёх языковых моделей на один и тот же русский текст. Также оценивалось сходство переводов с опубликованным английским вариантом.

Для эксперимента выбрана статья А. П. Копытова и Д. А. Кузина «Методы машинного обучения для решения задач по определению очагов возгорания» [1]. Авторы сравнивают модели, которые определяют наличие пожара на спутниковых снимках. Часть А включает название, аннотацию и ключевые слова со с. 127. Эталоном служит их опубликованный английский перевод со с. 126. В часть Б вошли четыре абзаца из подраздела «Случайный лес» на с. 134, всего 237 слов без чисел.

В эксперименте участвовали ChatGPT, DeepSeek и GigaChat. Каждая модель получила два запроса в отдельных чатах. Первый содержал короткую просьбу перевести текст на английский. Во втором были глоссарий и правила сохранения структуры, чисел и обозначений. Исходный текст в обоих запросах был одинаковым. Английский эталон понадобился только после получения ответов.

Глоссарий

В глоссарий вошли девять терминов из обеих частей текста. Названия алгоритмов и термины классификации сверены с документацией scikit-learn и TensorFlow, а названия каналов Landsat 8 — с материалами USGS.

Русский термин	Английский эквивалент	Часть	Источник
случайный лес	random forest	А, Б	scikit-learn [2]
логистическая регрессия	logistic regression	А, Б	scikit-learn [2]
свёрточная нейронная сеть	convolutional neural network	А	TensorFlow [3]
спектральный канал	spectral band	А, Б	USGS [4]
матрица ошибок	confusion matrix	А, Б	scikit-learn [2]
переобучение	overfitting	Б	scikit-learn [2]
дерево решений / дерево принятия решений	decision tree	Б	scikit-learn [2]
канал аэрозолей	coastal aerosol band	Б	USGS [4]
несбалансированный набор классов	imbalanced class distribution	Б	TensorFlow [3]

Оба запроса целиком приведены в приложениях А и Б. Английский эталон вынесен в приложение В.

2 Оценка переводов

BLEU и косинусное сходство рассчитаны только для части А.

Модель	Промпт	BLEU-4, %	Косинусное сходство
ChatGPT	Простой	54,67	0,8538
ChatGPT	С глоссарием	49,62	0,7882
DeepSeek	Простой	71,98	0,9607
DeepSeek	С глоссарием	73,96	0,9541
GigaChat	Простой	69,03	0,9459
GigaChat	С глоссарием	68,39	0,9295

Ручная проверка терминов

Ручная проверка охватывает девять терминов из частей А и Б. Каждый термин получил одну оценку за перевод с учётом всех употреблений. Точный эквивалент оценивался в 1 балл, понятный, но неточный или нестандартный вариант — в 0,5 балла, подмена понятия или ошибочная калька — в 0 баллов. В таблице 1 — простой промпт, 2 — промпт с глоссарием.

Термин	ChatGPT 1	ChatGPT 2	DeepSeek 1	DeepSeek 2	GigaChat 1	GigaChat 2
Случайный лес (А, Б)	random forest 1	random forest 1	random forest 1	random forest 1	random forest 1	random forest 1
Логистическая регрессия (А, Б)	logistic regression 1	logistic regression 1	logistic regression 1	logistic regression 1	logistic regression 1	logistic regression 1
Свёрточная нейронная сеть (А)	convolutional neural network 1	convolutional neural network 1	convolutional neural network 1	convolutional neural network 1	convolutional neural network 1	convolutional neural network 1
Спектральный канал (А, Б)	spectral bands 1	spectral bands 1	spectral channels 0,5	spectral bands 1	spectral bands 1	spectral bands 1
Матрица ошибок (А, Б)	confusion matrix 1	confusion matrix 1	confusion matrix 1	confusion matrix 1	confusion matrix 1	confusion matrix 1
Переобучение (Б)	overfitting 1	overfitting 1	overfitting 1	overfitting 1	overfitting 1	overfitting 1
Дерево решений (Б)	decision tree 1	decision tree 1	decision tree 1	decision tree 1	decision tree 1	decision tree 1
Канал аэрозолей (Б)	aerosol band 1	coastal aerosol band 1	aerosol channel 0,5	coastal aerosol band 1	aerosol channel 0,5	coastal aerosol band 1
Несбалансированный набор классов (Б)	class imbalance 1	imbalanced class distribution 1	imbalanced class set 0,5	imbalanced class distribution 1	imbalanced class set 0,5	imbalanced class distribution 1
Итого из 9	9	9	7,5	9	8	9

3 Разбор результатов и вывод

В простом переводе DeepSeek вариант spectral channels получил 0,5 балла в обеих частях. Смысл понятен, но в документации Landsat 8 используется spectral bands. За aerosol channel в части Б DeepSeek и GigaChat также получили по 0,5 балла. В документации первый канал Landsat 8 называется Coastal Aerosol [4]. Краткий вариант aerosol band у ChatGPT получил полный балл: из контекста ясно, о каком канале идёт речь.

Ещё по 0,5 получили DeepSeek и GigaChat за imbalanced class set в части Б. Здесь проблема связана с тем, сколько примеров относится к каждому классу, а слово set указывает на набор классов. Эту мысль точнее передают class imbalance и imbalanced class distribution [3]. Среди проверенных терминов оценок 0 не было. Неточные варианты выделены красным в приложении Г.

Из простых переводов лучше всего с терминами справился ChatGPT. Он набрал 9 из 9, DeepSeek получил 7,5, а GigaChat — 8. После добавления глоссария все три модели набрали 9 из 9. У DeepSeek изменились три варианта, у GigaChat — два. Для ChatGPT разницы по ручной оценке не было.

По близости к английскому эталону лидировал DeepSeek. Его лучший BLEU составил 73,96% с глоссарием, а лучшее косинусное сходство — 0,9607 с простым промптом. В эталоне стоят spectral channels и error matrix. Поэтому перевод с spectral bands и confusion matrix может получить меньше баллов за буквальное совпадение, даже если эти варианты подходят по смыслу. В этой работе глоссарий оказался полезен прежде всего для терминологии. Оба промпта проверялись на одной статье. Второй содержал глоссарий и дополнительные правила.

Источники

[1] Копытов А. П., Кузин Д. А. Методы машинного обучения для решения задач по определению очагов возгорания. Журнал СФУ. Техника и технологии. 2026. Т. 19, № 1. С. 126–138. Статья

[2] scikit-learn. Документация по машинному обучению. Random Forests · LogisticRegression · confusion_matrix · Decision Trees

[3] TensorFlow. Convolutional Neural Network · Classification on imbalanced data

[4] U.S. Geological Survey. Landsat 8 · Coastal/Aerosol Band 1

Приложение А Простой промпт

Переведи текст на английский язык.

Текст:
"""

Часть А

Методы машинного обучения для решения задач по определению очагов возгорания

Аннотация. В данной статье представлен анализ алгоритмов машинного обучения «Случайный лес», «Логистическая регрессия» и «Сверточная нейронная сеть». Проведен обзор научной и научно-технической литературы по теме исследования, проанализированы ключевые преимущества и ограничения рассмотренных алгоритмов. Особое внимание уделено применению алгоритмов в задачах классификации изображений, сбору данных и подготовке спутниковых снимков к обучению. Статья содержит практическую реализацию и сравнительный анализ эффективности алгоритмов в различных условиях. Цель статьи – предоставить понимание математических основ алгоритмов и практических аспектов применения алгоритмов машинного обучения в определении пожаров на спутниковых изображениях.

Ключевые слова: логистическая регрессия, случайный лес, сверточная нейронная сеть, спутниковые изображения, природный пожар, спектральные каналы, матрица ошибок, метрика ROC-AUC.

Часть Б

Случайный лес

Для сравнения с уже рассмотренным алгоритмом был взят ансамблевый алгоритм случайный лес. У моделей, основанных на данном алгоритме, не возникло эффекта переобучения даже на комбинации всех спектральных каналов изображений, метрика ROC составила 0,8572. Однако модель на комбинации 2–7 каналов показала большую точность, ROC = 0,8603. Параметры моделей: 200 деревьев принятия решений, стандартная балансировка весов классов. Для первой модели максимальная глубина дерева решений 15, минимальное число изображений в листе 2, минимальное число изображений в узле 5. Для второй – максимальная глубина дерева решений 20, минимальное число изображений в листе 5, минимальное число изображений в узле 2.

Матрицы ошибок для моделей, обученных на всех семи, а также шести спектральных каналах, не включающих канал аэрозолей, представлены на рис. 3 и 4 соответственно.

На матрицах ошибок (рис. 3 и 4) можно заметить, насколько неэффективно модели предсказывают класс 1 изображений с пожаром. Две трети таких изображений ошибочно отнесены к классу 0 без пожара, такой результат предсказания не приемлем для задачи обнаружения очагов огня для оперативного тушения. Модель случайного леса, обученная на всех спектральных каналах, дает более точный прогноз по первому классу, но и больше ошибочных предсказаний для нулевого класса. Стандартные методы балансировки классов не подходят в случае с алгоритмом случайный лес.

По итогу проверки на тестовых изображениях модели не увидели очагов пожара ни на одном изображении. Обучение на всех доступных спектральных каналах изображений не спасло ситуацию, те же методы борьбы с несбалансированным набором классов, что и для алгоритма логистической регрессии, оказывают меньший эффект. В связи с полученными результатами нецелесообразно дальнейшее рассмотрение метода случайный лес в качестве средства достижения поставленной задачи.
"""

Приложение Б Промпт с глоссарием

Переведи текст на английский язык для научной статьи по машинному обучению.

1. Используй общепринятую англоязычную терминологию.
2. Применяй эквиваленты из глоссария последовательно в обеих частях. Сохраняй единственное или множественное число по контексту.
3. Сохрани деление на части А и Б, заголовки, абзацы, числовые значения, обозначения и ссылки на рисунки.
4. Выведи только перевод, без вступления, пояснений и повторения глоссария.

Глоссарий:
- случайный лес — random forest
- логистическая регрессия — logistic regression
- свёрточная нейронная сеть — convolutional neural network
- спектральный канал — spectral band
- матрица ошибок — confusion matrix
- переобучение — overfitting
- дерево решений / дерево принятия решений — decision tree
- канал аэрозолей — coastal aerosol band
- несбалансированный набор классов — imbalanced class distribution

Текст:
"""

Часть А

Методы машинного обучения для решения задач по определению очагов возгорания

Аннотация. В данной статье представлен анализ алгоритмов машинного обучения «Случайный лес», «Логистическая регрессия» и «Сверточная нейронная сеть». Проведен обзор научной и научно-технической литературы по теме исследования, проанализированы ключевые преимущества и ограничения рассмотренных алгоритмов. Особое внимание уделено применению алгоритмов в задачах классификации изображений, сбору данных и подготовке спутниковых снимков к обучению. Статья содержит практическую реализацию и сравнительный анализ эффективности алгоритмов в различных условиях. Цель статьи – предоставить понимание математических основ алгоритмов и практических аспектов применения алгоритмов машинного обучения в определении пожаров на спутниковых изображениях.

Ключевые слова: логистическая регрессия, случайный лес, сверточная нейронная сеть, спутниковые изображения, природный пожар, спектральные каналы, матрица ошибок, метрика ROC-AUC.

Часть Б

Случайный лес

Для сравнения с уже рассмотренным алгоритмом был взят ансамблевый алгоритм случайный лес. У моделей, основанных на данном алгоритме, не возникло эффекта переобучения даже на комбинации всех спектральных каналов изображений, метрика ROC составила 0,8572. Однако модель на комбинации 2–7 каналов показала большую точность, ROC = 0,8603. Параметры моделей: 200 деревьев принятия решений, стандартная балансировка весов классов. Для первой модели максимальная глубина дерева решений 15, минимальное число изображений в листе 2, минимальное число изображений в узле 5. Для второй – максимальная глубина дерева решений 20, минимальное число изображений в листе 5, минимальное число изображений в узле 2.

Матрицы ошибок для моделей, обученных на всех семи, а также шести спектральных каналах, не включающих канал аэрозолей, представлены на рис. 3 и 4 соответственно.

На матрицах ошибок (рис. 3 и 4) можно заметить, насколько неэффективно модели предсказывают класс 1 изображений с пожаром. Две трети таких изображений ошибочно отнесены к классу 0 без пожара, такой результат предсказания не приемлем для задачи обнаружения очагов огня для оперативного тушения. Модель случайного леса, обученная на всех спектральных каналах, дает более точный прогноз по первому классу, но и больше ошибочных предсказаний для нулевого класса. Стандартные методы балансировки классов не подходят в случае с алгоритмом случайный лес.

По итогу проверки на тестовых изображениях модели не увидели очагов пожара ни на одном изображении. Обучение на всех доступных спектральных каналах изображений не спасло ситуацию, те же методы борьбы с несбалансированным набором классов, что и для алгоритма логистической регрессии, оказывают меньший эффект. В связи с полученными результатами нецелесообразно дальнейшее рассмотрение метода случайный лес в качестве средства достижения поставленной задачи.
"""

Приложение В Английский эталон

Опубликованная английская версия части А, с. 126 статьи [1].

Machine Learning Methods for Solving Fire Detection Problems

Abstract. This article presents an analysis of the machine learning algorithms «Random Forest», «Logistic Regression» and «Convolutional Neural Network». A review of scientific and technical literature on the topic of the study is conducted, the key advantages and limitations of the considered algorithms are analyzed. Particular attention is paid to the application of algorithms in image classification problems, data collection and preparation of satellite images for training. The article contains a practical implementation and comparative analysis of the efficiency of the algorithms in various conditions. The purpose of the article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning algorithms to detect fires in satellite images.

Keywords: logistic regression, random forest, convolutional neural network, satellite images, wildfire, spectral channels, error matrix, ROC-AUC metric.

Приложение Г Перевод 1

ChatGPT простой промпт

Часть А

Machine Learning Methods for Fire Detection

Abstract. This article presents an analysis of three machine learning algorithms: Random Forest, Logistic Regression, and Convolutional Neural Network. A review of scientific and technical literature on the research topic was conducted, and the key advantages and limitations of the algorithms under consideration were analyzed. Particular attention is paid to the application of these algorithms to image classification tasks, data collection, and the preprocessing of satellite imagery for model training. The article includes a practical implementation and a comparative analysis of the algorithms' performance under various conditions. The aim of this article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning methods to fire detection in satellite imagery.

Keywords: logistic regression, random forest, convolutional neural network, satellite imagery, wildfire, spectral bands, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

To compare the previously examined algorithm with another approach, the Random Forest ensemble learning algorithm was selected. Models based on this algorithm showed no signs of overfitting, even when trained on a combination of all spectral bands of the images, achieving a ROC-AUC score of 0.8572. However, the model trained on a combination of spectral bands 2–7 demonstrated better performance, with a ROC-AUC score of 0.8603. The model parameters were as follows: 200 decision trees and standard class weight balancing. For the first model, the maximum decision tree depth was 15, the minimum number of samples per leaf was 2, and the minimum number of samples required to split an internal node was 5. For the second model, the maximum decision tree depth was 20, the minimum number of samples per leaf was 5, and the minimum number of samples required to split an internal node was 2.

The confusion matrices for the models trained on all seven spectral bands and on six spectral bands excluding the aerosol band are presented in Figures 3 and 4, respectively.

The confusion matrices (Figures 3 and 4) demonstrate how poorly the models predict Class 1, which represents images containing fires. Approximately two-thirds of such images were incorrectly classified as Class 0, indicating the absence of fire. Such prediction results are unacceptable for the task of detecting fire locations to enable rapid firefighting response. The Random Forest model trained on all spectral bands provides more accurate predictions for Class 1 but also produces more incorrect predictions for Class 0. Standard class balancing methods are unsuitable for the Random Forest algorithm in this case.

The evaluation on the test images showed that neither model detected any fire locations in any of the images. Training on all available spectral bands did not improve the situation. Furthermore, the same methods used to address class imbalance in the Logistic Regression algorithm proved less effective for Random Forest. Based on these results, further consideration of the Random Forest algorithm as a means of achieving the research objective is not justified.

Приложение Г Перевод 2

ChatGPT промпт с глоссарием

Часть А

Machine Learning Methods for Wildfire Detection

Abstract. This paper presents an analysis of three machine learning algorithms: random forest, logistic regression, and convolutional neural network. A review of scientific and technical literature relevant to the research topic is conducted, and the key advantages and limitations of the algorithms are analyzed. Particular attention is paid to the application of these algorithms to image classification tasks, data collection, and the preprocessing of satellite imagery for model training. The paper includes practical implementations and a comparative analysis of the algorithms' performance under different conditions. The aim of this paper is to provide an understanding of the mathematical foundations of these algorithms and the practical aspects of applying machine learning algorithms to wildfire detection in satellite imagery.

Keywords: logistic regression, random forest, convolutional neural network, satellite imagery, wildfire, spectral bands, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

The random forest ensemble algorithm was selected for comparison with the previously examined algorithm. Models based on this algorithm showed no signs of overfitting, even when trained on a combination of all spectral bands of the images, achieving an ROC-AUC score of 0.8572. However, the model trained on a combination of spectral bands 2–7 demonstrated better performance, with an ROC-AUC score of 0.8603. The model parameters were as follows: 200 decision trees and standard class weight balancing. For the first model, the maximum decision tree depth was 15, the minimum number of images per leaf node was 2, and the minimum number of images required to split an internal node was 5. For the second model, the maximum decision tree depth was 20, the minimum number of images per leaf node was 5, and the minimum number of images required to split an internal node was 2.

The confusion matrices for the models trained on all seven spectral bands and on six spectral bands excluding the coastal aerosol band are presented in Figs. 3 and 4, respectively.

The confusion matrices (Figs. 3 and 4) demonstrate how poorly the models classify images belonging to class 1 (fire). Two-thirds of such images were incorrectly classified as class 0 (no fire). This classification performance is unacceptable for the task of detecting active fire locations to support rapid firefighting operations. The random forest model trained on all spectral bands provides more accurate predictions for class 1 but also produces more incorrect predictions for class 0. Standard class balancing methods are not suitable for the random forest algorithm in this case.

Evaluation on the test images revealed that neither model detected any fire locations in the images. Training on all available spectral bands did not resolve this issue, while the methods used to address the imbalanced class distribution in logistic regression proved less effective for the random forest algorithm. Based on these results, further consideration of the random forest algorithm as a means of achieving the research objective is not justified.

Приложение Г Перевод 3

DeepSeek простой промпт

Красным отмечены варианты, получившие 0,5 балла.

Часть А

Machine Learning Methods for Solving Problems of Identifying Fire Sources

Abstract. This article presents an analysis of the machine learning algorithms “Random Forest,” “Logistic Regression,” and “Convolutional Neural Network.” A review of scientific and scientific-technical literature on the research topic is conducted, and the key advantages and limitations of the considered algorithms are analyzed. Particular attention is paid to the application of the algorithms in image classification tasks, data collection, and preparation of satellite images for training. The article contains a practical implementation and comparative analysis of the effectiveness of the algorithms under various conditions. The purpose of the article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning algorithms in detecting fires in satellite images.

Keywords: logistic regression, random forest, convolutional neural network, satellite images, wildfire, spectral channels, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

For comparison with the algorithm already considered, the ensemble Random Forest algorithm was taken. Models based on this algorithm did not exhibit an overfitting effect even on the combination of all spectral channels of images; the ROC metric was 0.8572. However, the model on the combination of channels 2–7 showed higher accuracy, ROC = 0.8603. Model parameters: 200 decision trees, standard class weight balancing. For the first model, the maximum decision tree depth was 15, the minimum number of images in a leaf was 2, and the minimum number of images in a node was 5. For the second, the maximum decision tree depth was 20, the minimum number of images in a leaf was 5, and the minimum number of images in a node was 2.

The confusion matrices for the models trained on all seven and also six spectral channels not including the aerosol channel are presented in Fig. 3 and 4, respectively.

In the confusion matrices (Fig. 3 and 4), one can notice how inefficiently the models predict class 1 images with fire. Two-thirds of such images were mistakenly assigned to class 0 without fire; such a prediction result is unacceptable for the task of detecting fire sources for prompt extinguishing. The Random Forest model trained on all spectral channels gives a more accurate prediction for the first class, but also more erroneous predictions for the zero class. Standard class balancing methods are not suitable in the case of the Random Forest algorithm.

As a result of testing on test images, the models did not detect fire sources in any image. Training on all available spectral channels of images did not save the situation; the same methods for combating an imbalanced class set as for the logistic regression algorithm have a smaller effect. In connection with the obtained results, further consideration of the Random Forest method as a means of achieving the set task is inappropriate.

Приложение Г Перевод 4

DeepSeek промпт с глоссарием

Часть А

Machine Learning Methods for Solving Problems of Identifying Fire Outbreaks

Abstract. This article presents an analysis of the machine learning algorithms random forest, logistic regression, and convolutional neural network. A review of scientific and scientific-technical literature on the research topic is conducted, and the key advantages and limitations of the considered algorithms are analyzed. Particular attention is paid to the application of the algorithms in image classification tasks, data collection, and preparation of satellite images for training. The article contains a practical implementation and comparative analysis of the effectiveness of the algorithms under various conditions. The purpose of the article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning algorithms in identifying fires in satellite images.

Keywords: logistic regression, random forest, convolutional neural network, satellite images, wildfire, spectral bands, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

For comparison with the algorithm already considered, the ensemble algorithm random forest was taken. Models based on this algorithm did not exhibit the overfitting effect even on the combination of all spectral bands of the images; the ROC metric was 0.8572. However, the model on the combination of bands 2–7 showed higher accuracy, ROC = 0.8603. Model parameters: 200 decision trees, standard class weight balancing. For the first model, the maximum decision tree depth was 15, the minimum number of images in a leaf was 2, and the minimum number of images in a node was 5. For the second, the maximum decision tree depth was 20, the minimum number of images in a leaf was 5, and the minimum number of images in a node was 2.

The confusion matrices for the models trained on all seven and on six spectral bands not including the coastal aerosol band are presented in Fig. 3 and 4, respectively.

From the confusion matrices (Fig. 3 and 4), one can notice how inefficiently the models predict class 1 of images with fire. Two thirds of such images are erroneously assigned to class 0 without fire; such a prediction result is unacceptable for the task of detecting fire sources for prompt extinguishing. The random forest model trained on all spectral bands gives a more accurate prediction for the first class, but also more erroneous predictions for the zero class. Standard class balancing methods are not suitable in the case of the random forest algorithm.

As a result of testing on test images, the models did not detect fire sources in any image. Training on all available spectral bands of images did not save the situation; the same methods for combating imbalanced class distribution as for the logistic regression algorithm have a smaller effect. In connection with the obtained results, further consideration of the random forest method as a means of achieving the stated objective is inappropriate.

Приложение Г Перевод 5

GigaChat простой промпт

В ответе GigaChat было вступление и отдельные примечания. Здесь приведён сам перевод частей А и Б.

Красным отмечены варианты, получившие 0,5 балла.

Часть А

Machine Learning Methods for Solving Fire Detection Problems

Abstract. This article presents an analysis of the machine learning algorithms "Random Forest", "Logistic Regression", and "Convolutional Neural Network". A review of scientific and scientific-technical literature on the research topic was conducted, and the key advantages and limitations of the considered algorithms were analyzed. Special attention is paid to the application of algorithms in image classification tasks, data collection, and the preparation of satellite images for training. The article contains a practical implementation and a comparative analysis of the effectiveness of the algorithms under various conditions. The purpose of the article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning algorithms to fire detection on satellite images.

Keywords: logistic regression, random forest, convolutional neural network, satellite images, wildfire, spectral bands, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

For comparison with the already considered algorithm, the ensemble algorithm Random Forest was selected. Models based on this algorithm showed no signs of overfitting, even when using all spectral bands of the images; the ROC metric was 0.8572. However, the model using a combination of 2–7 bands achieved higher accuracy, ROC = 0.8603. Model parameters: 200 decision trees, standard class weight balancing. For the first model: maximum decision tree depth of 15, minimum number of images per leaf of 2, minimum number of images per node of 5. For the second: maximum decision tree depth of 20, minimum number of images per leaf of 5, minimum number of images per node of 2.

Confusion matrices for models trained on all seven, as well as six spectral bands (excluding the aerosol channel), are presented in Fig. 3 and Fig. 4, respectively.

From the confusion matrices (Fig. 3 and Fig. 4), it can be seen how inefficiently the models predict class 1 images containing fire. Two-thirds of such images are mistakenly assigned to class 0 (no fire); such a prediction result is unacceptable for the task of detecting fire sources for rapid extinguishment. The Random Forest model trained on all spectral bands provides a more accurate prediction for the first class, but also makes more erroneous predictions for the zero class. Standard class balancing methods are not suitable for the Random Forest algorithm.

As a result of testing on the test images, the models did not detect any fire sources on any of the images. Training on all available spectral bands did not improve the situation; the same methods for handling an imbalanced class set as used for the logistic regression algorithm have a lesser effect. Based on the obtained results, it is impractical to further consider the Random Forest method as a means of achieving the set task.

Приложение Г Перевод 6

GigaChat промпт с глоссарием

Часть А

Machine Learning Methods for Identifying Fire Hotspots

Abstract. This article presents an analysis of the machine learning algorithms random forest, logistic regression, and convolutional neural network. A review of scientific and scientific-technical literature on the research topic is provided, and the key advantages and limitations of the considered algorithms are analysed. Special attention is paid to the application of the algorithms in image classification tasks, data collection, and the preparation of satellite images for training. The article contains a practical implementation and a comparative analysis of the algorithms' effectiveness under various conditions. The purpose of the article is to provide an understanding of the mathematical foundations of the algorithms and the practical aspects of applying machine learning algorithms to detect wildfires in satellite images.

Keywords: logistic regression, random forest, convolutional neural network, satellite images, wildfire, spectral bands, confusion matrix, ROC-AUC metric.

Часть Б

Random Forest

To compare with the algorithm already considered, the ensemble random forest algorithm was selected. Models based on this algorithm did not exhibit overfitting even when using a combination of all spectral bands of the images; the ROC metric was 0.8572. However, the model using the combination of bands 2–7 achieved higher accuracy, ROC = 0.8603. Model parameters: 200 decision trees, standard class weight balancing. For the first model: maximum decision tree depth of 15, minimum samples per leaf of 2, minimum samples per split of 5. For the second: maximum decision tree depth of 20, minimum samples per leaf of 5, minimum samples per split of 2.

Confusion matrices for models trained on all seven spectral bands and on six spectral bands excluding the coastal aerosol band are shown in Fig. 3 and 4, respectively.

In the confusion matrices (Fig. 3 and 4), it can be observed how ineffective the models are at predicting class 1 (fire images). Two-thirds of such images are misclassified as class 0 (no fire); such a prediction outcome is not acceptable for the task of detecting fire hotspots for rapid suppression. The random forest model trained on all spectral bands provides more accurate predictions for class 1, but also more erroneous predictions for class 0. Standard methods for handling imbalanced class distribution are not suitable for the random forest algorithm.

Following testing on the test images, the models did not detect any fire hotspots in any of the images. Training on all available spectral bands did not remedy the situation; the same techniques for mitigating imbalanced class distribution used for the logistic regression algorithm proved less effective. In light of the obtained results, further consideration of the random forest method is not advisable.