Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №3

по дисциплине «Автоматизация научных исследований»

Проектирование схемы базы данных с помощью языковой модели

Выполнили студенты:
Нгуен Тхи Хань Хуен
Юдин Пётр
Зубов Глеб
Наумович Лаврентий
Группа: 5040102/60201

Санкт-Петербург
2026

Содержание

1 Цель работы **2**

2 Задание **2**

3 Выбор задания и распределение моделей **2**

3.1 Исходное условие задания 3

3.2 Распределение моделей в команде 4

4 Единая структура промпта **4**

5 Результаты проектирования (по моделям) **5**

5.1 Модель Deepseek 5

5.1.1 Исходная схема и предупреждения 5

5.1.2 Качественный разбор и исправление 6

5.1.3 Вывод по модели Deepseek 7

5.2 Модель GPT-6 8

5.2.1 Исходная схема и предупреждения 8

5.2.2 Качественный разбор и исправление 9

5.2.3 Оставшиеся проблемы и ограничения PostgreSQL 10

5.2.4 Вывод по модели GPT-6 11

5.3 Модель Qwen 11

5.3.1 Исходная схема и предупреждения 11

5.3.2 Качественный разбор и исправление 12

5.3.3 Вывод по модели Qwen 12

6 Сравнительный анализ моделей **12**

7 Вывод **13**

1 Цель работы

Целью лабораторной работы является изучение возможностей больших языковых моделей (LLM) при проектировании реляционных баз данных на основе текстового описания задачи, а также оценка качества полученных схем с точки зрения корректности структуры, связей между сущностями и соответствия функциональным требованиям.

2 Задание

В ходе выполнения лабораторной работы необходимо решить следующие задачи:

1. Выбрать предметную область и ознакомиться с исходным описанием задачи.
2. Сформировать запрос к выбранной большой языковой модели для получения первоначальной схемы базы данных в формате DBML.
3. Построить диаграмму базы данных с помощью сервиса `https://dbdiagram.io/` и проверить корректность полученного кода.
4. Провести качественный анализ первоначальной схемы, выявить возможные недостатки и ошибки проектирования.
5. Сформулировать замечания и передать их языковой модели для корректировки схемы.
6. Построить исправленную диаграмму и повторно оценить её соответствие исходным требованиям.
7. Сравнить первоначальный и исправленный варианты и сформулировать выводы о возможностях и ограничениях использования LLM.

3 Выбор задания и распределение моделей

Для выполнения лабораторной работы командой было выбрано **задание № 9 «Библиотека»**.

3.1 Исходное условие задания

Задание № 9 «Библиотека»

Имеется перечень всех изданий в библиотеке (с указанием количества экземпляров). Имеется список пользователей абонемента. На руки выдаётся не более трёх книг. Выдача книг осуществляется при отсутствии просрочек по возврату. Названия книг могут совпадать. Книга может иметь много авторов. Книга принадлежит некоторому жанру.

Требуется:

- поддержка оформления нового пользователя;
- поддержка пополнения фондов;
- поддержка выдачи/приёма/продления (не более трёх продлений) книг пользователям;
- поддержка поиска книг по автору и названию;
- генерация ругательного письма (при просрочке по возврату > 1 месяца);
- отчисление пользователей (при отсутствии долгов и активности более 1 года);
- генерация штрафной квитанции (при просрочке по возврату > 1 года, штраф — $3\times$ цены издания, книга считается утерянной);
- поддержка возмещения стоимости утерянной книги $(1 : 1)$;
- поддержка списания утерянных и невозвращённых книг.

Отчёты:

- наиболее популярные книги (за произвольный период);
- наиболее популярные авторы (за произвольный период);
- количество прочитанных книг на человека в год (с упорядочиванием по количеству);
- обобщённая статистика по жанровым предпочтениям за год;
- финансовый отчёт за год (основные фонды + штрафы).

3.2 Распределение моделей в команде

Таблица 1: Распределение языковых моделей между участниками команды

№	Участник команды	Языковая модель
1	Нгуен Тхи Хань Хуен	DeepSeek
2	Зубов Глеб	GPT-6 (ChatGPT)
3	Наумович Лаврентий	Qwen

4 Единая структура промпта

Для обеспечения сопоставимости результатов все участники группы использовали одинаковый первоначальный запрос к моделям.

Первоначальный промпт

По приведённому ниже заданию спроектируй реляционную схему базы данных.

Выдай полный код DBML для вставки в `https://dbdiagram.io/`.

Нужна только схема: таблицы, поля, типы данных, ключи и связи.

Все операции и отчёты из условия должны быть реализуемы на её основе.

SQL-запросы и код приложения не нужны.

Если необходимы допущения, явно отметь их в комментариях DBML.

Полное условие задания:

[ВСТАВИТЬ ПОЛНЫЙ ТЕКСТ ЗАДАНИЯ № 9]

5 Результаты проектирования (по моделям)

5.1 Модель Deepseek

5.1.1 Исходная схема и предупреждения

Полный код исходного DBML сохранен в файле `deepseek_1.txt`. На его основе была построена исходная диаграмма (рис. 1).

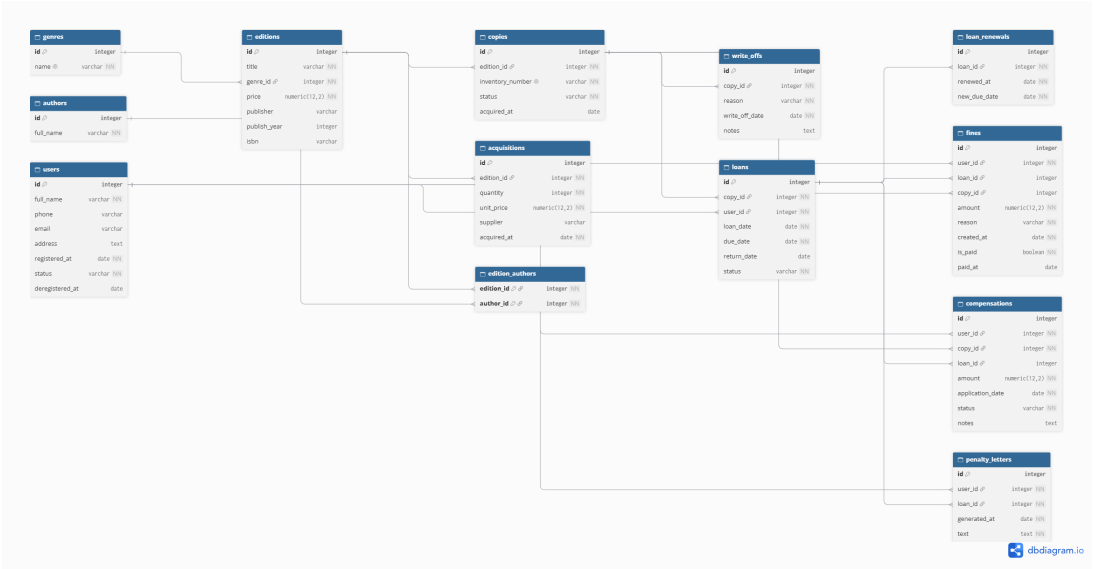


Рис. 1: Исходная диаграмма Deepseek

При проверке в `https://dbdiagram.io/` диаграмма успешно строится, однако валидатор выдаёт ряд предупреждений (рис. 2).



Рис. 2: Предупреждения валидатора для схемы Deepseek

Причина предупреждений — использование nullable-полей (допускающих `NULL`) в качестве внешних ключей. Валидатор требует строгого `NOT NULL` для связей (например, поля `fines.loan_id`, `fines.copy_id` и `compensations.loan_id` должны быть обязательными).

5.1.2 Качественный разбор и исправление

При детальном анализе исходной схемы были выявлены следующие технические недостатки:

1. **Проблемы с `NOT NULL`.** Поля `fines.loan_id`, `fines.copy_id` и `compensations.loan_id` допускали значение `NULL`. Это позволяло создать штраф или заявку на возмещение без привязки к конкретной выдаче или экземпляру, что ломало логику расчета штрафа (3× цены) и поиска утерянной книги. Также поле `copies.acquired_at` (дата поступления) было nullable, хотя каждая копия обязательно должна иметь дату поступления.

2. **Отсутствие индексов для внешних ключей (FK).** В исходной схеме многие

связи не были проиндексированы. Это привело бы к серьезным проблемам с производительностью при выполнении JOIN-запросов, проверке ограничений целостности и генерации отчетов (например, при поиске популярных авторов или подсчете штрафов пользователя).

На основе этих замечаний был сформирован корректирующий промпт. Во второй итерации Deepseek успешно переработала схему:

- Добавлены ограничения `NOT NULL` для полей `fines.loan_id`, `fines.copy_id`, `compensations.loan_id` и `copies.acquired_at`, что устранило предупреждения валидатора.
- Добавлены недостающие индексы для ускорения работы базы данных в таблицах: `edition_authors` (`author_id`), `loan_renewals` (`loan_id`), `fines` (`user_id`, `loan_id`, `copy_id`), `compensations` (`user_id`, `copy_id`, `loan_id`), а также в таблицах `write_offs`, `acquisitions` и `penalty_letters`.

Исправленный код сохранен в `deepseek_2.txt`, на его основе построена итоговая диаграмма (рис. 3).

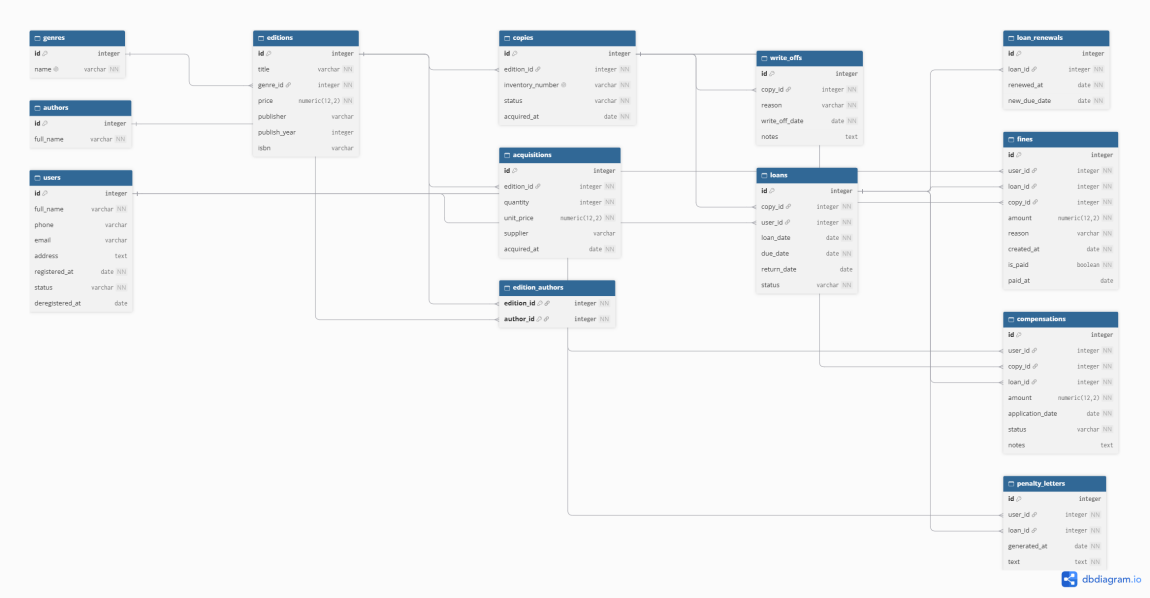


Рис. 3: Исправленная диаграмма Deepseek

5.1.3 Вывод по модели Deepseek

Модель Deepseek продемонстрировала отличное понимание предметной области еще на первой итерации, создав правильную нормализованную структуру (с разделением на издания и физические экземпляры). Вторая итерация была направлена на «шлифовку» схемы: устранение предупреждений валидатора (добавление `NOT NULL`) и оптимизацию производительности (добавление индексов на внешние ключи). Итоговая схема полностью покрывает требования задания и готова к реализации.

5.2 Модель GPT-6

5.2.1 Исходная схема и предупреждения

Полный код исходного DBML сохранен в файле `GPT_result_1.txt`. Модель сформировала базовый каркас с таблицами книг, авторов, экземпляров и операций. Синтаксических ошибок DBML, препятствующих построению диаграммы, не возникло. Однако при детальном анализе логики были выявлены серьёзные концептуальные недочёты (рис. 4).

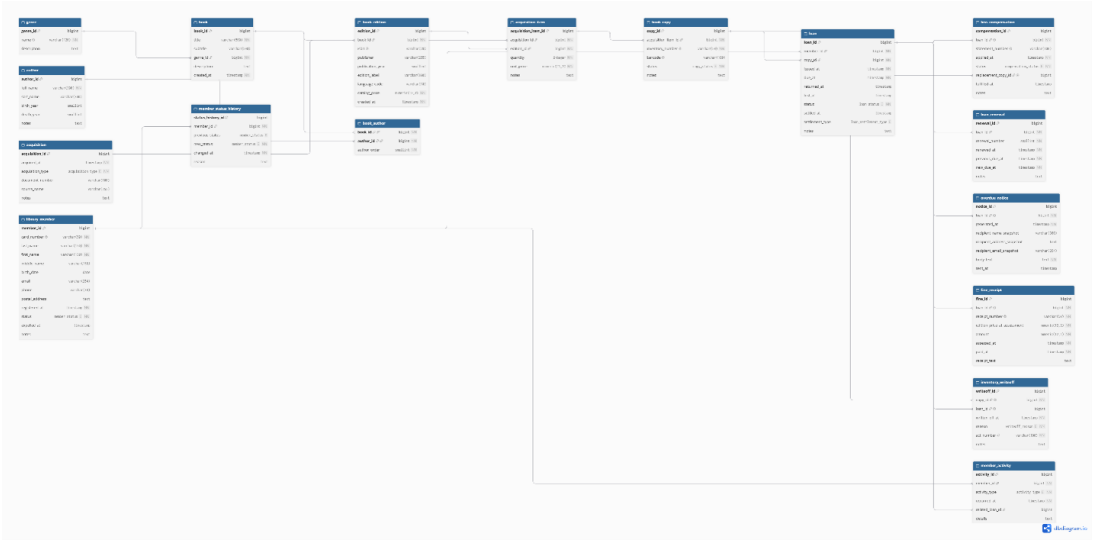


Рис. 4: Исходная диаграмма GPT-6

В первой версии схемы были обнаружены следующие проблемы:

- Количество экземпляров в `acquisition_item` не контролировалось относительно `book_copy` (в документах могло числиться больше книг, чем фактически зарегистрировано).
- Статусы `book_copy` и `loan` хранились независимо (возвращённая книга могла продолжать числиться выданной).
- Ограничение на три книги не обеспечивалось, а лимит на три продления существовал только в комментариях.
- Штраф и возмещение хранились в разных таблицах без взаимоисключения (можно было оформить оба обязательства за одну книгу).
- Не проверялось соответствие изданий при возмещении.
- Выдача и списание связывались независимо (списание могло относиться к неправильной выдаче).

- Активность читателя дублировалась в нескольких таблицах, что приводило к недостоверной истории при пропуске события.
- Не сохранялась история жанров и авторского состава, а финансовые документы можно было изменить задним числом.
- Для одной выдачи разрешалось только одно уведомление; не хватало проверок дат и денежных значений.

5.2.2 Качественный разбор и исправление

Для устранения этих недостатков был сформирован масштабный повторный запрос, включающий 12 направлений доработки (от согласованности статусов до сохранения истории финансовых операций). Во второй итерации GPT-6 существенно переработала схему (рис. 5):

- **Контроль выдачи:** Введена таблица `active_loan` с тремя допустимыми слотами для каждого читателя (обеспечивает лимит в 3 книги) и уникальностью `copy_id`.
- **Продления и штрафы:** Добавлены CHECK-ограничения на диапазон продлений 1–3. Штраф и возмещение объединены в единую таблицу `loss_resolution` с уникальным `loan_id`, что исключило двойное списание.
- **Историчность данных:** Добавлены исторические снимки характеристик книг на момент выдачи (`genre_id_at_issue`, `genre_name_at_issue`, `loan_author`), введена таблица `member_visit` и `member_status_history`.
- **Финансовая дисциплина:** Для невозможности изменения данных задним числом добавлена таблица корректировок `acquisition_adjustment`.
- **Связи и проверки:** Внедрены составные внешние ключи для проверки соответствия изданий, а также удалена уникальность `loan_id` в таблице уведомлений `overdue_notice` (теперь можно хранить историю повторных писем).

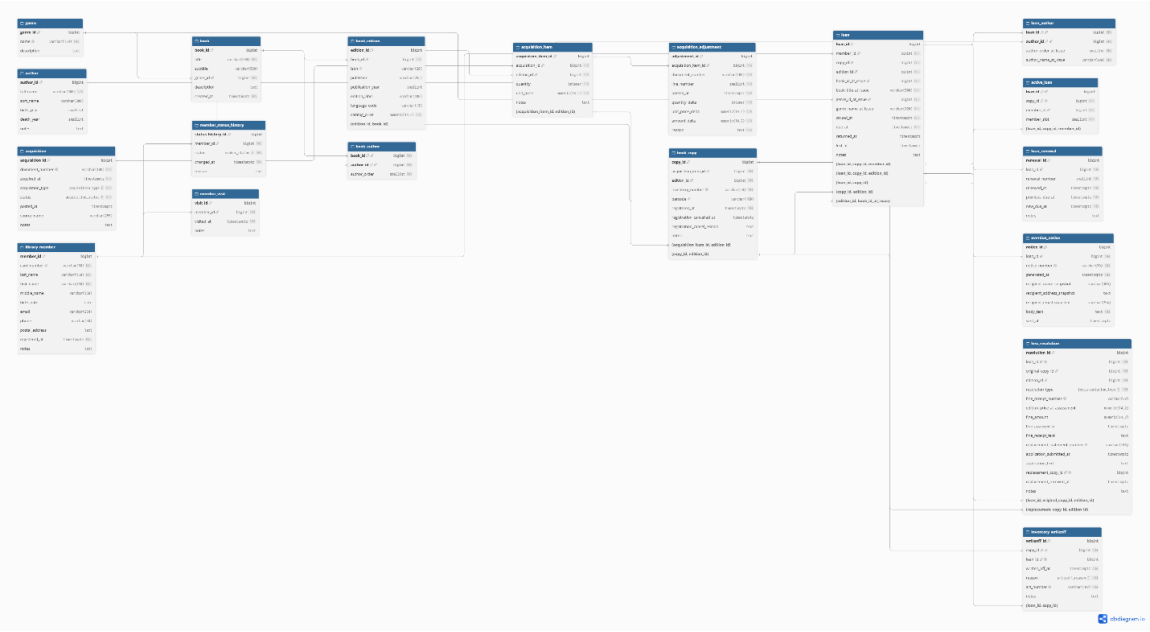


Рис. 5: Исправленная диаграмма GPT-6

5.2.3 Оставшиеся проблемы и ограничения PostgreSQL

Несмотря на серьёзный прогресс, повторная проверка выявила несколько оставшихся логических недочётов:

- Не учитывается `loan.lost_at` при определении последней активности читателя (его могут ошибочно признать неактивным).
- Нет проверки состояния выдачи при формировании уведомления (письмо может уйти после возврата книги).
- Не полностью определена последовательность оформления штрафа (требуется отдельная операция потери перед штрафом).
- Отсутствует возможность отмены заявления на возмещение.
- Не проверяется хронология некоторых операций (например, дата заявления раньше даты потери).

Более того, модель честно отметила, что часть бизнес-логики невозможно реализовать только средствами DBML. Для полноценной работы потребуется написание триггеров и транзакций на уровне PostgreSQL (блокировка строки читателя при выдаче, проверка отсутствия просрочек, отложенные триггеры для контроля количества экземпляров, контроль неизменяемости проведённых документов).

5.2.4 Вывод по модели GPT-6

Вторая версия схемы показала наивысшую глубину проработки среди всех участников. Она покрывает все основные операции и отчёты, а также предлагает продвинутые механизмы контроля целостности (исторические снимки, слоты выдачи). Схема пригодна для использования на уровне логического проектирования, но требует дополнительной программной реализации со стороны бэкенда.

5.3 Модель Qwen

5.3.1 Исходная схема и предупреждения

Валидатор dbdiagram.io выдал предупреждения, а при детальном анализе были выявлены серьёзные проблемы структуры. На рисунке 6 представлена исходная диаграмма.

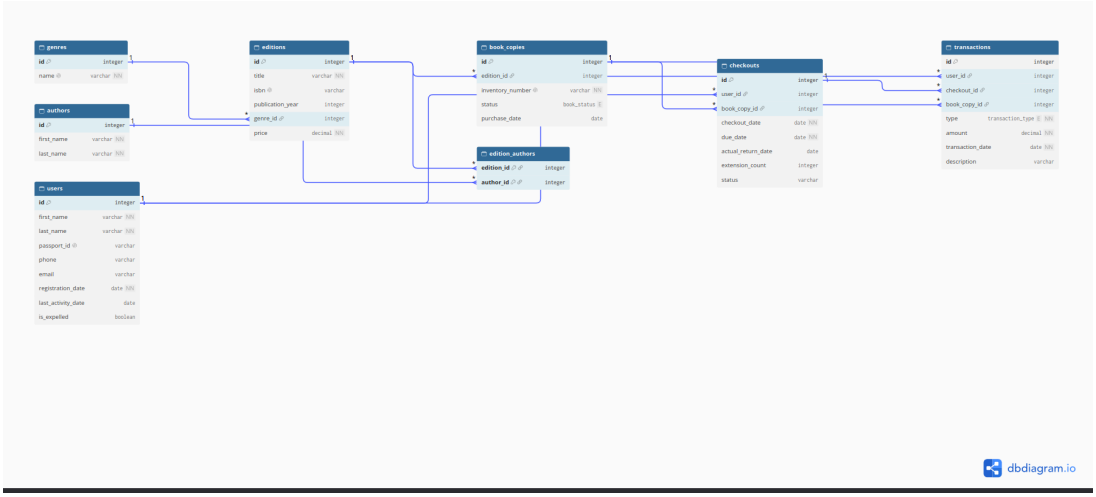


Рис. 6: Исходная диаграмма Qwen

Главные недостатки исходной схемы Qwen:

1. Издание может быть без жанра, экземпляр без издания, выдача без читателя или без конкретной книги. *Решение: добавление NOT NULL в соответствующие поля (это же являлось причиной предупреждений валидатора).*

2. `transactions.user_id` и `transactions.book_copy_id` являются дублями. *Решение: убрать данные дубли.*

3. `book_copies.status` показывает только текущее состояние. Если экземпляр списали в прошлом году, по одной текущей строке нельзя узнать, когда это случилось. *Решение: добавление даты списания экземпляра или историю статусов.*

5.3.2 Качественный разбор и исправление

Модели был отправлен корректирующий промпт с требованием добавить `NOT NULL` для обязательных связей (`editions.genre_id`, `book_copies.edition_id`, `checkouts.user_id`, `checkouts.book_copy_id`), убрать дублирующиеся поля и добавить дату списания (или историю статусов). Qwen успешно справилась с задачей: добавила требуемые ограничения и поля для отслеживания истории. Исправленный код сохранен в `qwen_2.txt`.

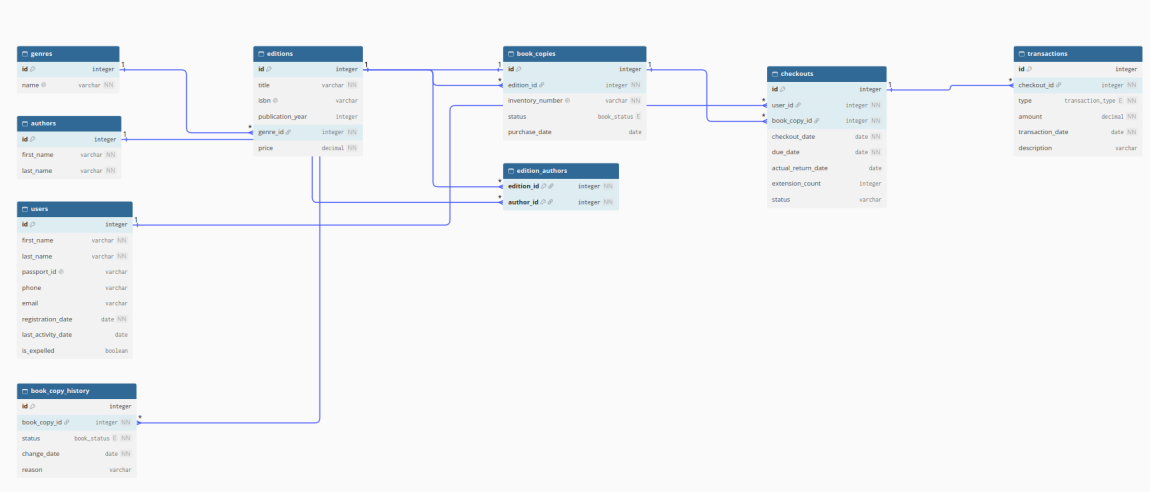


Рис. 7: Исправленная диаграмма Qwen

5.3.3 Вывод по модели Qwen

Qwen отлично справилась с точечными правками синтаксиса и нормализации данных. Однако её первоначальная схема была довольно поверхностной и не учитывала сложные сценарии (например, историю активности или финансовый аудит), которые другие модели (особенно GPT-6) проработали глубже.

6 Сравнительный анализ моделей

После получения результатов от всех участников команды был проведён сравнительный анализ трёх языковых моделей: DeepSeek, GPT-6 и Qwen. Оценка проводилась с учётом качества первоначальной схемы, способности моделей исправлять выявленные недостатки и полноты проработки логики предметной области.

Общие результаты. Все три модели смогли сформировать базовую структуру реляционной базы данных в формате DBML. При этом качество первоначальных схем и глубина проработки отдельных требований различались. В ходе анализа было установлено, что для получения корректной структуры недостаточно только сгенерировать DBML-код: необходимо дополнительно проверить обязательность связей, согласованность состояний сущностей и возможность сохранения истории операций.

Особенности отдельных моделей.

- **DeepSeek** продемонстрировала хорошее понимание предметной области уже на первой итерации. Модель правильно разделила издания и физические экземпляры книг. На второй итерации были добавлены ограничения `NOT NULL` для обязательных связей и индексы для внешних ключей. Основными преимуществами DeepSeek стали корректная базовая структура и успешное выполнение точечных исправлений.

- **GPT-6** показала наиболее глубокую проработку сложной бизнес-логики. После корректирующего запроса модель расширила схему механизмами учёта истории операций, контроля выдачи книг, продлений, потери экземпляров и финансовых корректировок. В частности, были добавлены исторические снимки характеристик книг, таблицы `member_visit` и `member_status_history`, а также механизм корректировок `acquisition_adjustment`. Однако даже после исправлений сохранились отдельные логические недочёты. Кроме того, часть требований невозможно обеспечить только средствами DBML: для полноценной реализации необходимы дополнительные триггеры и транзакции на уровне PostgreSQL.

- **Qwen** успешно справилась с исправлением конкретных структурных недостатков. Во второй версии были добавлены ограничения `NOT NULL` для обязательных связей, устранены дублирующиеся поля и предусмотрено отслеживание истории списания экземпляров. Вместе с тем первоначальная схема была менее детализированной и не охватывала некоторые сложные сценарии, связанные с историей активности читателей и финансовым аудитом.

Итог сравнения. Наиболее заметные различия между моделями проявились не столько в способности генерировать синтаксически корректный DBML-код, сколько в глубине понимания предметной области и качестве обработки корректирующих запросов. DeepSeek показала хорошие результаты при построении базовой структуры, GPT-6 — при моделировании сложных бизнес-процессов, а Qwen — при устранении конкретных ошибок и дополнении структуры необходимыми ограничениями.

Таким образом, результаты эксперимента показывают, что итеративное взаимодействие с языковой моделью и проверка полученной схемы человеком являются важными этапами проектирования базы данных.

7 Вывод

В ходе лабораторной работы были изучены возможности больших языковых моделей при проектировании реляционных баз данных на примере предметной области

«Библиотека». Были рассмотрены результаты работы моделей DeepSeek, GPT-6 и Qwen, получены первоначальные схемы в формате DBML и проведена их последующая корректировка на основе выявленных недостатков.

Проведённая работа показала, что языковые модели способны существенно упростить процесс разработки структуры базы данных, однако сгенерированные схемы требуют обязательной проверки. Не все ограничения предметной области и сложные бизнес-сценарии могут быть корректно учтены при первоначальной генерации.

Таким образом, наиболее эффективным является итеративный подход, при котором языковая модель используется для создания и корректировки схемы, а человек проверяет её логическую согласованность и соответствие требованиям задания. Полученные результаты подтверждают, что LLM могут выступать полезным инструментом поддержки проектирования баз данных, но не заменяют экспертный анализ.